



Universidad Alfonso X el Sabio

UNIVERSIDAD ALFONSO X EL SABIO

FACULTAD BUSINESS & TECH

**Framework transcriptómico basado en la
integración de modelos de lenguaje y
aprendizaje automático para la identificación
de biomarcadores en cáncer de pulmón**

TRABAJO FIN DE MÁSTER

Máster Universitario en Bioinformática

Daniel Tapia Díez

Madrid, 2026

UNIVERSIDAD ALFONSO X EL SABIO

Máster Universitario en Bioinformática

TÍTULO DEL TRABAJO:

Framework transcriptómico basado en la integración de modelos de
lenguaje y aprendizaje automático para la identificación de biomarcadores
en cáncer de pulmón

ALUMNO: Daniel Tapia Díez

NP: _____

TUTOR DEL TRABAJO: Leonardo Dulcetti

FECHA DE PRESENTACIÓN: 14 de agosto de 2026

Firma del director

Firma del alumno

Resumen

El cáncer de pulmón es la primera causa de mortalidad oncológica en el mundo, con una supervivencia a cinco años que apenas alcanza el 20 % y una marcada heterogeneidad molecular entre subtipos histológicos con implicación terapéutica directa. Las bases de datos públicas de expresión génica, principalmente NCBI Gene Expression Omnibus (GEO), reúnen cientos de estudios transcriptómicos de pulmón, pero su integración manual resulta inviable por la heterogeneidad de plataformas y por unos metadatos clínicos redactados en texto libre que dificultan la asignación automática de muestras a grupos experimentales.

Este Trabajo Fin de Máster presenta `data.lung`, un *framework* reproducible que automatiza la integración multi-cohorte y la identificación de biomarcadores transcriptómicos en cáncer de pulmón. El sistema descarga las cohortes de GEO, las normaliza dentro de cada estudio, delega la curación de los metadatos clínicos a un modelo de lenguaje de gran tamaño (Llama 3.3-70b vía Groq), aplica criterios de inclusión, ejecuta análisis diferencial y entrena clasificadores supervisados (regresión logística regularizada L1, *Random Forest* y máquinas de vectores soporte) con validación externa *Leave-One-Dataset-Out* (LODO).

Sobre 11 cohortes GEO descargadas, 8 cumplen los criterios de inclusión (presencia de casos y controles, curación exitosa y alineamiento verificado). El *framework* identifica una firma génica de 1174 genes replicados en tres cohortes independientes para la tarea de subtipo histológico (adenocarcinoma frente a carcinoma escamoso), con un panel mínimo clínicamente manejable de 20 genes que alcanza AUC media LODO de 0,966. La firma completa recupera 18 de 20 marcadores diagnósticos de inmunohistoquímica clínica sin declararlos: 12 de 12 marcadores escamosos y 6 de 8 adenocarcinoma. Sobre la tarea tumor *vs.* sano, el modelo obtiene AUC media LODO 0,925 con balanced accuracy 0,772.

La aportación principal del trabajo es doble: (i) demuestra que la integración de un modelo de lenguaje en el paso de curación clínica permite escalar la integración multi-cohorte sin renunciar al rigor metodológico, y (ii) prueba que la exigencia de replicación en cohortes independientes —condición ausente en la mayoría de firmas publicadas— produce un panel biológicamente interpretable y coincidente con marcadores clínicos ya en uso.

Palabras clave: transcriptómica, cáncer de pulmón, adenocarcinoma, carcinoma escamoso, biomarcadores, aprendizaje automático, modelos de lenguaje, NCBI GEO, validación LODO, firma génica, panel mínimo, inmunohistoquímica.

Abstract

Lung cancer is the leading cause of cancer-related mortality worldwide, with a five-year survival rate below 20 % and pronounced molecular heterogeneity between histological subtypes that carries direct therapeutic implications. Public gene expression repositories, most notably the NCBI Gene Expression Omnibus (GEO), host hundreds of transcriptomic studies of lung tissue, yet their manual integration is infeasible due to platform heterogeneity and free-text clinical metadata that hinder the automatic assignment of samples to experimental groups.

This Master’s Thesis presents **data.lung**, a reproducible framework that automates multi-cohort integration and transcriptomic biomarker discovery in lung cancer. The system downloads cohorts from GEO, normalises within each study, delegates clinical metadata curation to a large language model (Llama 3.3-70b via Groq), applies inclusion criteria, performs differential expression analysis and trains supervised classifiers (L1-regularised logistic regression, Random Forest, Support Vector Machines) with external Leave-One-Dataset-Out (LODO) validation.

Out of 11 downloaded GEO cohorts, 8 meet the inclusion criteria (presence of cases and controls, successful curation and verified alignment). The framework identifies a signature of 1174 genes replicated across three independent cohorts for the histological subtype task (adenocarcinoma *vs.* squamous carcinoma), with a minimal clinically manageable panel of 20 genes achieving a mean LODO AUC of 0.966. The full signature recovers 18 of 20 clinical immunohistochemistry markers without being told about them: 12 of 12 squamous markers and 6 of 8 adenocarcinoma markers. On the tumour *vs.* healthy task, the model attains a mean LODO AUC of 0.925 with balanced accuracy 0.772.

The main contribution is twofold: (i) it shows that incorporating a large language model into the clinical curation step allows multi-cohort integration to scale without sacrificing methodological rigour, and (ii) it demonstrates that requiring replication across independent cohorts—a condition absent from most published signatures—yields a biologically interpretable panel that coincides with clinically established markers.

Keywords: transcriptomics, lung cancer, adenocarcinoma, squamous cell carcinoma, biomarkers, machine learning, large language models, NCBI GEO, LODO validation, gene signature, minimal panel, immunohistochemistry.

Objetivos

Objetivo general

Diseñar, implementar y validar un *framework* bioinformático reproducible que automatice la integración de cohortes transcriptómicas públicas de cáncer de pulmón, mediante la combinación de un modelo de lenguaje de gran tamaño para la curación clínica y aprendizaje automático supervisado para la identificación de biomarcadores replicables.

El framework debe cumplir tres propiedades irrenunciables:

- **Reproducibilidad:** dos ejecuciones sobre los mismos datos deben producir resultados idénticos hasta el último decimal, gracias al uso de semillas aleatorias fijas y a la ausencia de intervención manual en cualquier paso del pipeline.
- **Validación externa:** la evaluación del rendimiento debe realizarse siempre en cohortes independientes de las utilizadas para el entrenamiento, mediante Leave-One-Dataset-Out.
- **Interpretabilidad biológica:** los biomarcadores identificados deben ser trazables a mecanismos biológicos conocidos y, cuando exista un panel clínico establecido para la misma pregunta, contrastables con dicho panel.

Objetivos específicos

Los objetivos específicos que se derivan del objetivo general son:

- OE1. Integración automatizada de cohortes GEO.** Descargar y normalizar ($\log_2$ + cuantiles dentro de cada estudio) las cohortes seleccionadas del repositorio NCBI GEO, y **curar los metadatos clínicos** mediante un modelo de lenguaje (Llama 3.3-70b vía Groq) que asigna cada muestra a una categoría binaria a partir del texto libre.
- OE2. Clasificación supervisada con validación externa.** Entrenar clasificadores (LASSO L1, Random Forest y SVM) sobre las dos tareas contempladas (tumor *vs.* sano y subtipo ADC *vs.* SQC), y evaluarlos mediante **Leave-One-Dataset-Out** (LODO) sobre las cohortes que cumplen los criterios de inclusión.
- OE3. Firma génica validada por consenso y panel mínimo.** Construir una firma de biomarcadores por meta-análisis multi-cohorte (mismo signo y $|d| > 0,5$ en las tres cohortes evaluables), y derivar un **panel mínimo clínicamente manejable** cuya AUC se mantenga a menos de 0,01 del máximo de la firma completa.
- OE4. Validación externa contra marcadores clínicos IHC.** Comprobar en qué medida la firma, seleccionada por criterio estadístico puro, recupera el panel de inmuno-

histoquímica diagnóstica recomendado por la OMS para adenocarcinoma y carcinoma escamoso.

OE5. Interfaz web con asistente conversacional acotado. Desarrollar una interfaz interactiva (Streamlit) que permita navegar los resultados por cohorte y por gen, con un asistente conversacional (Llama 3.3-70b) alimentado dinámicamente de los CSV del pipeline y con reglas explícitas que impiden inventar cifras o citar biomarcadores fuera de la firma.

Hipótesis de partida

Las hipótesis que se contrastan con el trabajo son:

1. Un modelo de lenguaje contemporáneo puede curar los metadatos clínicos de cohortes GEO de cáncer de pulmón con una tasa de éxito superior al 80 % sobre cohortes evaluables, escalando la integración multi-cohorte a un coste computacional accesible.
2. La aplicación de meta-análisis por consenso multi-cohorte, con exigencia estricta de replicación en tres cohortes independientes, produce una firma génica biológicamente coherente cuya AUC en LODO supera el 0,90 sobre la tarea de subtipo histológico.
3. La firma resultante, seleccionada de forma *data-driven*, recupera al menos el 75 % de los marcadores diagnósticos IHC del panel recomendado por la OMS, lo que constituye una validación externa fuerte frente a un estándar clínico independiente.
4. Un panel mínimo del orden de 20 genes es suficiente para aproximarse al rendimiento de la firma completa, con una pérdida de AUC inferior a 0,01, haciendo el panel clínicamente manejable.

Los capítulos siguientes describen la metodología empleada (capítulo 3) y presentan los resultados (capítulo 4) que permiten aceptar o rechazar cada una de estas hipótesis.

Índice general

Resumen	I
Abstract	III
Objetivos	V
Objetivo general	V
Objetivos específicos	V
Hipótesis de partida	VI
1. Introducción	1
1.1. Contexto y motivación	1
1.2. Transcriptómica y bases de datos públicas	2
1.3. Modelos de lenguaje aplicados a curación de metadatos	3
1.4. Alcance y planteamiento del trabajo	3
2. Estado del arte	5
2.1. Firmas génicas en cáncer de pulmón	5
2.2. Integración multi-cohorte y meta-análisis	5
2.3. Aprendizaje automático en transcriptómica	6
2.4. Modelos de lenguaje en bioinformática	7
2.5. Ausencias en la literatura	7
3. Materiales y métodos	9
3.1. Visión general del <i>pipeline</i>	9
3.2. Adquisición y normalización de cohortes	10
3.2.1. Selección de cohortes	10
3.2.2. Descarga y mapeo	11
3.2.3. Normalización	11
3.3. Curación clínica con modelo de lenguaje	12
3.3.1. Formulación de la tarea	12
3.3.2. Modelo y servicio	12
3.3.3. Auditoría de la curación	12
3.4. Criterios de inclusión	13
3.5. Análisis diferencial	13
3.6. Clasificadores supervisados	13
3.7. Validación externa Leave-One-Dataset-Out	14
3.8. Firma génica por consenso	15
3.9. Panel mínimo	16
3.10. Validación contra IHC clínica	16

3.11. Interfaz web y asistente	16
3.12. Reproducibilidad	17
4. Resultados	19
4.1. Cohortes evaluables y curación LLM	19
4.2. Clasificación tumor <i>vs.</i> sano	19
4.3. Clasificación de subtipo histológico ADC <i>vs.</i> SQC	22
4.4. Firma génica validada	23
4.5. Panel mínimo	23
4.6. Validación externa contra IHC clínica	24
4.7. Composición tisular dentro de los tumores	25
4.8. Interpretación biológica: dos ejes reales	26
4.9. Histologías fuera del alcance de entrenamiento	27
4.10. Análisis exploratorio por cohorte	27
4.11. Coherencia de los folds LODO	28
5. Discusión	31
5.1. Interpretación de los resultados	31
5.2. Contribución del modelo de lenguaje	32
5.3. Sesgos y limitaciones metodológicas	32
5.3.1. Ámbito de plataforma	32
5.3.2. Ámbito histológico	32
5.3.3. Umbral de decisión	33
5.3.4. Población y sesgos demográficos	33
5.3.5. Tamaño muestral	33
5.4. Comparación con la literatura	33
5.5. Implicaciones clínicas potenciales	34
5.6. Comparación con firmas comerciales existentes	35
5.7. Lecciones metodológicas	35
6. Conclusiones y trabajo futuro	37
6.1. Conclusiones	37
6.2. Aportaciones originales	38
6.3. Limitaciones	38
6.4. Trabajo futuro	39
6.5. Balance personal	39
Bibliografía	41
Appendices	43

A. Estructura del repositorio	45
Responsabilidad de cada módulo del pipeline	46
Convenciones de código	47
B. Ficheros de resultados	49
Auditoría de cohortes	49
Rendimiento del modelo (LODO)	49
Firma génica validada	49
Análisis biológico complementario	50
Ficheros generados por cohorte	51
Convenciones de tipos y unidades	51
C. Interfaz web y asistente conversacional	53
Arquitectura de la aplicación	53
Vista 1: Portada	54
Vista 2: Framework - capítulo Inicio	55
Vista 3: Asistente conversacional	56
Vista 4: Introducción y objetivos	57
Vista 5: Metodología	58
Vista 6: Resultados	59
Vista 7: Cohortes individuales	60
Vista 8: Conclusiones	61
Detalles técnicos y patrones de diseño	62
D. Paneles biológicos empleados	65
Panel IHC clínico (validación externa)	65
Panel de pulmón sano (definición de eje)	66
Panel de proliferación (definición de eje)	66
Cohortes GEO utilizadas	66
E. Prompts del modelo de lenguaje	67
Prompt de curación clínica	67
Prompt sistema del asistente conversacional	68
Reglas del sistema	68
Contexto dinámico	69
Ejemplos de interacción	69
F. Guía de despliegue y reproducibilidad	71
Requisitos previos	71
Instalación de dependencias	71
Configuración de la clave API	72
Ejecución del pipeline completo	72
Ejecución selectiva	73

Interfaz web	73
Tests automáticos	73
Integración con LaTeX (esta memoria)	73
Resolución de problemas frecuentes	74
G. Glosario y acrónimos	75
Acrónimos técnicos	75
Símbolos matemáticos	77
Etiquetas de columnas de los CSV	78

Índice de figuras

3.1. Arquitectura del <i>pipeline</i> de <code>data.lung</code> . Los pasos con fondo verde son entradas (repositorios públicos), los pasos naranjas son entregables (firma, panel mínimo y validación externa contra IHC clínica), y los pasos azules son transformaciones intermedias.	10
3.2. Esquema de la validación Leave-One-Dataset-Out con $k = 4$ cohortes. En cada iteración, una cohorte (naranja) actúa como test y las demás como entrenamiento. Las métricas se agregan como media al final del proceso.	15
3.3. Regla del meta-análisis por consenso. Sobre tres genes de ejemplo, sólo <i>DSG3</i> pasa el filtro: mantiene signo positivo y $ d $ grande en las tres cohortes. <i>Gen X</i> tiene signo opuesto en la cohorte B; <i>Gen Y</i> tiene signo consistente pero magnitud insuficiente en B.	15
4.1. Tasa de éxito de la curación LLM por cohorte. Barras verdes indican cohortes con curación superior al 40 % (umbral de inclusión).	19
4.2. Balanced accuracy del modelo en LODO frente al baseline mayoritario informado por cohorte.	21
4.3. AUC frente a balanced accuracy por cohorte en LODO. La brecha vertical entre ambas cifras es proporcional a la necesidad de recalibración del umbral.	22
4.4. AUC media LODO en función del tamaño del panel (genes ordenados por d media de la firma validada). El panel mínimo (20 genes) captura el 99,6 % del AUC de la firma completa.	23
4.5. Correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores, por cohorte.	26
4.6. Histologías presentes en las cohortes GEO originales que quedaron fuera del entrenamiento del clasificador de subtipo.	27
4.7. Análisis exploratorio de la cohorte GSE31210. (a) Componentes principales; los grupos sano y enfermo se separan en el plano. (b) Volcano de la comparación diferencial; miles de genes cruzan el umbral $ d > 1$ con $FDR < 0,05$. (c) Heatmap de los 30 genes más significativos, con dendrograma de muestras que reproduce el grupo clínico.	28
4.8. Concordancia de signo de los coeficientes de LASSO entre distintos folds LODO. El acuerdo perfecto en signo se sitúa por encima del 90 % para los genes de la firma.	28

C.1. Arquitectura de la interfaz web. Los CSV/JSON del pipeline se leen desde <code>paso12_datos.py</code> (datos) y <code>contexto_tfm.py</code> (prompt del asistente). El router de <code>paso12_web_chatbot.py</code> expone dos vistas: la portada (/) y el dashboard del framework (/framework). La línea discontinua indica la dependencia externa opcional (API de Groq) del asistente conversacional.	54
C.2. Portada de la interfaz <code>data.lung</code> . Fondo con terminal animada reproduciendo trazas reales del pipeline, tipografía mono con acento verde y CTA <i>Comenzar</i>	55
C.3. Capítulo <i>Inicio</i> del framework. Título, entradilla y hero de cinco cifras con acento verde.	56
C.4. Capítulo <i>Asistente</i> . Cabecera con avatar y estado en línea, sugerencias iniciales de conversación y input anclado abajo.	57
C.5. Capítulo <i>Introducción y objetivos</i> . Se aprecia la tabla de cohortes con la barra de progreso de curación LLM y el caption dinámico.	58
C.6. Capítulo <i>Metodología</i> . Bloques numerados con las fases del pipeline y comandos de reproducibilidad.	59
C.7. Capítulo <i>Resultados</i> . Se aprecia la cabecera de cuatro tarjetas, el buscador de gen y el inicio de la sección de subtipo.	60
C.8. Capítulo <i>Cohortes</i> . Selector de cohorte y bloque de cifras por dataset.	61
C.9. Capítulo <i>Conclusiones</i> . Lista de biomarcadores por linaje con cifras de recuperación IHC.	62
E.1. Composición del prompt sistema del asistente conversacional. Los CSV/JSON del pipeline (bloques verdes) alimentan <code>contexto_tfm.py</code> , que compone tres secciones (rol, reglas y contexto dinámico) que se concatenan con los últimos ocho mensajes del historial y se envían al modelo Llama 3.3-70b vía Groq. Como los CSV/JSON se leen en tiempo real, cualquier reejecución del pipeline se propaga al chat sin editar código.	68

Índice de tablas

3.1. Cohortes GEO utilizadas en el trabajo.	11
3.2. Hiperparámetros y propiedades de los tres clasificadores.	14
4.1. Rendimiento LODO para la tarea tumor <i>vs.</i> sano.	20
4.2. Rendimiento LODO para la tarea de subtipo ADC <i>vs.</i> SQC.	22
4.3. Panel mínimo de 20 genes ordenados por rango en la firma.	24
4.4. Panel IHC clínico (OMS 2015) frente a la firma génica validada.	25
4.5. Correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores.	26
4.6. Concordancia de la firma entre folds bajo dos esquemas de partición.	29
5.1. Comparación con firmas génicas publicadas para cáncer de pulmón.	34

Capítulo 1

Introducción

1.1. Contexto y motivación

El cáncer de pulmón es la principal causa de mortalidad oncológica a nivel mundial. Según las estimaciones de la *International Agency for Research on Cancer* (IARC), en 2022 se diagnosticaron aproximadamente 2,48 millones de nuevos casos, con 1,82 millones de fallecimientos atribuibles a la enfermedad [1]. En España, el Observatorio del Cáncer de la Asociación Española Contra el Cáncer sitúa la incidencia en torno a 30 000 casos anuales, con una supervivencia a cinco años que apenas alcanza el 20 %. Estas cifras contrastan con las tasas de supervivencia de otros tumores sólidos como el cáncer de mama, próstata o colorrectal, y evidencian la necesidad de mejorar tanto el diagnóstico temprano como la estratificación molecular de los pacientes.

Desde el punto de vista histológico, el cáncer de pulmón se clasifica principalmente en dos grandes grupos: el cáncer de pulmón de células no pequeñas (*Non-Small Cell Lung Cancer*, NSCLC), que representa aproximadamente el 85 % de los casos, y el cáncer de pulmón microcítico (*Small Cell Lung Cancer*, SCLC), con el 15 % restante. Dentro del NSCLC, los dos subtipos histológicos predominantes son el adenocarcinoma (ADC) y el carcinoma escamoso (*Squamous Cell Carcinoma*, SQC), seguidos a distancia por el carcinoma de células grandes y los tumores neuroendocrinos de gran célula.

La distinción entre adenocarcinoma y carcinoma escamoso tiene una implicación terapéutica directa que trasciende el mero interés clasificatorio. El pemetrexed, un antifolato aprobado para el tratamiento del NSCLC no escamoso, presenta una eficacia significativamente menor en histología escamosa y su uso está desaconsejado en este subtipo. El bevacizumab, un anticuerpo monoclonal dirigido contra el factor de crecimiento del endotelio vascular (VEGF), está formalmente contraindicado en carcinoma escamoso por el riesgo de hemorragia pulmonar grave. Diversos regímenes de inmunoterapia con inhibidores de *immune checkpoints* (PD-1/PD-L1) muestran también patrones de respuesta diferentes según el subtipo. Por tanto, una clasificación histológica inequívoca condiciona la decisión terapéutica y el pronóstico.

En la práctica clínica, la clasificación se realiza sobre biopsia mediante inmunohistoquímica (IHC), usando paneles de marcadores canónicos: citoqueratinas y factores de transcripción de linaje epitelial escamoso (KRT5, TP63, DSG3...) para el diagnóstico de carcinoma escamoso, y marcadores del programa alveolar tipo II (napsina A, TTF-1/NKX2-1, surfactantes...) para el adenocarcinoma. Sin embargo, cuando la biopsia es escasa o el patrón inmunohistoquímico es ambiguo, la decisión puede demorarse o quedar sujeta a discrepancia entre patólogos. Un panel molecular objetivo basado en la expresión de un número reducido

de genes podría complementar la IHC en estos casos.

1.2. Transcriptómica y bases de datos públicas

La transcriptómica es la disciplina que estudia el conjunto de transcritos de ARN producidos por un genoma en un momento y contexto biológico concretos. A diferencia del genoma, que es esencialmente estable a lo largo de la vida del individuo, el transcriptoma refleja el estado funcional de la célula: qué genes se están expresando, en qué proporción y bajo qué programa regulatorio. Esta característica hace que el transcriptoma sea un sustrato especialmente informativo para el estudio del cáncer, donde la transformación maligna se acompaña de reprogramaciones profundas de la expresión génica [2].

Las dos tecnologías de referencia para cuantificar el transcriptoma son los *microarrays* de expresión (predominantes hasta aproximadamente 2015) y la secuenciación masiva de ARN (RNA-Seq, dominante desde entonces). En *microarrays*, un chip fija miles de sondas de oligonucleótidos complementarias a cada gen; el ARN de la muestra se marca con fluorescencia y se hibrida al chip, obteniendo una medida de la abundancia relativa de cada gen. En RNA-Seq, el ARN se convierte a ADN complementario, se secuencia y las lecturas se mapean al genoma o transcriptoma de referencia. Ambas tecnologías han generado un enorme volumen de datos públicos.

El repositorio NCBI Gene Expression Omnibus (GEO, <https://www.ncbi.nlm.nih.gov/geo/>) es el mayor archivo público de datos de expresión génica [3]. Cuenta con más de un millón de muestras de miles de estudios cubriendo prácticamente cualquier tejido, condición o especie. Para cáncer de pulmón se dispone de centenares de estudios que abarcan tanto adenocarcinoma como escamoso, tanto muestras tumorales como controles adyacentes, y tanto plataformas de *microarrays* clásicas (Affymetrix HG-U133 Plus 2.0, plataforma GPL570) como datos de RNA-Seq de The Cancer Genome Atlas (TCGA).

Sin embargo, la disponibilidad no equivale a usabilidad. Un investigador que quiera integrar varias cohortes debe resolver al menos cuatro problemas técnicos:

1. **Heterogeneidad de plataformas.** Las sondas de un chip Affymetrix HG-U133 Plus 2.0 no son directamente comparables con las de un chip Illumina o con las cuentas normalizadas de RNA-Seq. Es preciso mapear cada sonda a un símbolo génico y agregar sondas múltiples cuando varias apuntan al mismo gen.
2. **Curación clínica.** Los metadatos de GEO están redactados en texto libre por el laboratorio que deposita el estudio. Una misma categoría clínica puede aparecer como *lung adenocarcinoma*, *ADC*, *non-small cell lung cancer*, *adenocarcinoma histology*, *primary tumor: adenocarcinoma*, etc. El grupo control puede denominarse *normal*, *healthy*, *non-tumor adjacent tissue*, *control lung*, o incluso no estar etiquetado explícitamente en el campo esperado.
3. **Efecto lote.** La variabilidad técnica entre plataformas, laboratorios y protocolos introduce fuentes de varianza que pueden dominar sobre la señal biológica y confundir

cualquier análisis posterior.

4. **Validación externa.** Una firma génica identificada en una cohorte concreta rara vez se replica en cohortes independientes. La literatura acumula cientos de firmas propuestas que no han conseguido transferirse a la clínica [4].

1.3. Modelos de lenguaje aplicados a curación de metadatos

Los recientes modelos de lenguaje de gran tamaño (LLMs), como GPT-4, Claude o Llama, han demostrado una capacidad notable para tareas de comprensión de texto en dominios especializados, incluyendo la biomedicina. La capacidad de estos modelos para interpretar texto libre, extraer entidades y clasificarlas según categorías predefinidas los convierte en herramientas naturales para automatizar tareas de curación que hasta ahora requerían intervención manual.

En el ámbito de este trabajo, un LLM puede leer la descripción textual de una muestra de GEO (por ejemplo, *lung adenocarcinoma, stage IIB, 72-year-old male, former smoker*) y devolver una etiqueta canónica del grupo experimental (**enfermo**, **sano**, **ambiguo**). Esta delegación permite integrar cohortes con nomenclaturas heterogéneas sin tener que codificar reglas específicas para cada estudio, y hace escalable la incorporación de nuevas cohortes al análisis. El presente trabajo emplea Llama 3.3-70b servido vía la infraestructura de inferencia de Groq, que ofrece una latencia baja y un coste marginal accesible para el volumen de muestras del proyecto.

1.4. Alcance y planteamiento del trabajo

Este Trabajo Fin de Máster desarrolla `data.lung`, un *framework* de análisis transcriptómico y aprendizaje automático que integra los componentes descritos en las secciones anteriores para responder a una pregunta concreta: *¿es posible identificar, mediante integración automatizada de cohortes públicas y validación externa, una firma génica de biomarcadores replicable entre cohortes independientes para adenocarcinoma y carcinoma escamoso de pulmón?*

El planteamiento del trabajo se articula sobre tres pilares:

- **Automatización de la integración multi-cohorte** mediante un modelo de lenguaje que resuelve la curación clínica sin intervención humana, escalando la incorporación de nuevas cohortes.
- **Validación externa exigente** basada en Leave-One-Dataset-Out (LODO), donde cada cohorte se retira una vez del entrenamiento y se utiliza como test independiente, y en meta-análisis por consenso: un gen entra en la firma final sólo si mantiene el mismo signo de cambio en las tres cohortes evaluables simultáneamente.
- **Interpretabilidad biológica** de la firma resultante, contrastada con marcadores clínicos ya establecidos en inmunohistoquímica diagnóstica y con ejes biológicos conocidos del cáncer de pulmón (linaje escamoso frente a alveolar, actividad proliferativa).

Los objetivos general y específicos del trabajo se han presentado ya en el apartado *Objetivos* que precede a este capítulo, por delante del índice, para que el lector disponga cuanto antes del propósito del trabajo. El resto de la memoria se organiza como sigue. El capítulo 2 revisa el estado del arte en integración multi-cohorte, firmas génicas publicadas y aplicaciones de LLMs en bioinformática. El capítulo 3 detalla los materiales y métodos, con particular atención al diseño del *pipeline*. El capítulo 4 presenta los resultados de las dos tareas de clasificación, la firma génica validada y los ejes biológicos identificados. El capítulo 5 discute las implicaciones clínicas y metodológicas, sitúa los resultados en el contexto de la literatura y enumera las limitaciones del trabajo. El capítulo 6 resume las conclusiones y esboza líneas de trabajo futuro. Los anexos recogen la estructura del repositorio, la descripción detallada de la interfaz web y del asistente conversacional, los paneles biológicos empleados como referencia y la guía de despliegue.

Capítulo 2

Estado del arte

2.1. Firmas génicas en cáncer de pulmón

La búsqueda de firmas génicas con valor diagnóstico o pronóstico en cáncer de pulmón cuenta con una literatura extensa. Beer et al. [5] describieron en 2002 una de las primeras firmas pronósticas para adenocarcinoma de pulmón mediante *microarrays*, identificando un panel de aproximadamente 50 genes cuya expresión permitía estratificar pacientes por riesgo de muerte a corto plazo. En los años siguientes, distintos grupos han propuesto firmas para diagnóstico histológico, pronóstico global, respuesta a tratamiento con inhibidores de EGFR, presencia de mutaciones en KRAS o ALK, y probabilidad de recurrencia tras cirugía.

Sin embargo, la revisión sistemática de Subramanian y Simon [6] reveló que la gran mayoría de firmas propuestas no superaba una validación independiente rigurosa. Los sesgos habituales incluyen: (i) uso de la misma cohorte para descubrimiento y validación mediante partición aleatoria en lugar de LODO; (ii) selección de genes en el conjunto completo de datos seguida de validación cruzada, incurriendo en la falacia de las particiones (*data leakage*); (iii) omisión de análisis de composición tisular, con firmas que en realidad reflejan la proporción variable de estroma o células inmunes; y (iv) informar únicamente el AUC sin considerar la capacidad de calibración del umbral de decisión entre cohortes.

Estos problemas metodológicos explican, al menos en parte, por qué el número de firmas génicas trasladadas a la práctica clínica en cáncer de pulmón es reducido. Uno de los ensayos comerciales con mayor difusión es la firma pronóstica *Pervenio Lung RS*, basada en un panel de 14 genes medidos por PCR cuantitativa [7]; otro es *Oncotype DX Lung* de Genomic Health, con un panel similar. Ambos mantienen un uso limitado y no han desplazado a los marcadores inmunohistoquímicos clásicos.

En el ámbito del diagnóstico histológico, la Organización Mundial de la Salud (OMS) publica desde 2015 recomendaciones para el uso combinado de marcadores inmunohistoquímicos: TTF-1/NKX2-1 y napsina A como positivos para adenocarcinoma, y CK5/6, p40 (isoforma de TP63) y DSG3 como positivos para carcinoma escamoso [8]. La correspondencia entre estos marcadores IHC y su expresión transcripcional constituye una referencia natural para validar la interpretabilidad de una firma génica.

2.2. Integración multi-cohorte y meta-análisis

La integración de múltiples cohortes de expresión ha dado lugar a un cuerpo metodológico específico. Los enfoques principales se agrupan en dos familias:

- **Corrección de efecto lote:** normaliza las cohortes conjuntamente para eliminar la va-

rianza atribuible al origen técnico. ComBat [9] y sus variantes bayesianas empíricas son las herramientas más difundidas. El riesgo de estos métodos es eliminar señal biológica genuina cuando el efecto lote está confundido con la variable de interés.

- **Meta-análisis por consenso:** normaliza cada cohorte por separado, calcula el estadístico de interés (por ejemplo, el tamaño de efecto d de Cohen para la diferencia de medias entre grupos), y combina los resultados con criterios de consenso (mismo signo, misma magnitud mínima) en varias cohortes. Este enfoque es más conservador y permite distinguir señal reproducible de artefacto técnico.

En el contexto de este trabajo se adopta la segunda familia, con validación externa Leave-One-Dataset-Out (LODO). En LODO, el modelo se entrena con todas las cohortes menos una, y se evalúa en la retirada; el proceso se itera dejando fuera cada cohorte por turno. Esta partición es más conservadora que la validación cruzada estándar porque respeta la estructura de agrupación de las muestras: dos muestras de la misma cohorte comparten sesgo técnico, y evaluarlas juntas sobre-estima el rendimiento.

Bernau et al. [10] formalizaron el marco de validación cross-study en clasificadores oncológicos. Trabajos posteriores han aplicado LODO a firmas de cáncer de mama [11] y de pulmón [12], mostrando reducciones consistentes del AUC entre 5 y 15 puntos cuando se pasa de validación interna a externa. Esto justifica adoptar LODO como estándar mínimo para reclamar replicación.

2.3. Aprendizaje automático en transcriptómica

Los datos transcriptómicos plantean un reto clásico para el aprendizaje automático: alta dimensionalidad ($p \gg n$, con p del orden de 10^4 genes y n del orden de 10^2 muestras). Las estrategias habituales combinan reducción de dimensionalidad, regularización y selección de características.

- **Regresión logística con regularización L1 (LASSO):** la penalización ℓ_1 fuerza a coeficientes exactos a cero, seleccionando implícitamente un subconjunto reducido de genes. Es la estrategia más usada cuando se busca interpretabilidad y un panel mínimo.
- **Random Forest:** ensamble de árboles de decisión con *bagging* y selección aleatoria de variables en cada división. No fuerza esparsidad pero produce un ranking de importancia útil como complemento a LASSO.
- **Máquinas de vectores soporte (SVM):** eficaces en dimensiones altas con kernels lineales o RBF, aunque con menor interpretabilidad de los pesos.
- **Redes neuronales profundas:** en los últimos años se han aplicado a datos ómicos, pero requieren tamaños muestrales que suelen quedar fuera del alcance de estudios de cohortes públicas.

La elección de LASSO como método principal en este trabajo se justifica por tres razones: (i) produce un panel interpretable, útil clínicamente; (ii) es determinista dado un `random_state` fijo, lo que garantiza reproducibilidad; y (iii) el hiperparámetro de regularización (C) admite una calibración simple mediante validación cruzada anidada, sin requerir las decisiones arquitectónicas propias de una red neuronal.

2.4. Modelos de lenguaje en bioinformática

El uso de LLMs en bioinformática ha crecido rápidamente desde la aparición de GPT-4 en 2023. Las aplicaciones documentadas incluyen anotación funcional de genes, extracción de información de literatura biomédica, generación de código para análisis y curación de metadatos clínicos [13, 14]. Un trabajo particularmente relevante para esta tesis es GEOparser [15], que emplea GPT-4 para extraer metadatos estructurados de GEO Series y demuestra tasas de éxito superiores al 90 % en un conjunto de test manual.

Los modelos abiertos (Llama 2, Llama 3, Mistral) han cerrado buena parte de la brecha con los modelos propietarios en tareas de comprensión y clasificación, especialmente en tamaños de 70 B parámetros o superiores [16]. La infraestructura de inferencia acelerada por hardware específico (Groq LPU, Cerebras) permite servir estos modelos con latencias de decenas de milisegundos por consulta, haciendo viable su integración en *pipelines* de análisis a escala.

En el contexto de este trabajo, el LLM cumple una única función bien delimitada: leer la descripción textual de una muestra de GEO y devolver una etiqueta canónica del grupo experimental. Esta tarea es paradigmática de clasificación de texto y no requiere generación abierta, lo que reduce los riesgos de alucinación observados en tareas de razonamiento libre. El uso del LLM se restringe además a la fase de curación de datos, sin participación en el análisis estadístico ni en la selección de biomarcadores, evitando así que el conocimiento paramétrico del modelo sobre cáncer de pulmón introduzca sesgos en los resultados.

2.5. Ausencias en la literatura

La revisión anterior identifica varios huecos que este TFM aborda de manera integrada:

1. **Ausencia de *frameworks* extremo a extremo** que combinen curación automatizada con LLM, integración multi-cohorte, clasificación supervisada con validación externa y verificación cruzada contra marcadores clínicos, todo ello en un pipeline reproducible.
2. **Falta de firmas con replicación estricta** en varias cohortes independientes. Los trabajos publicados suelen reportar resultados sobre una única cohorte de validación o sobre particiones aleatorias de la misma cohorte de descubrimiento.
3. **Desconexión entre firmas transcriptómicas y marcadores clínicos.** La mayoría de firmas propuestas no verifican explícitamente hasta qué punto recuperan marcadores ya en uso en la clínica, ni explican qué genes de su panel corresponden a marcadores conocidos y cuáles son novedosos.

El framework `data.lung` se diseña como respuesta a estos tres huecos: proporciona una tubería end-to-end reproducible, aplica LODO como criterio mínimo de validación y contrasta explícitamente la firma resultante con el panel diagnóstico IHC de la OMS.

Capítulo 3

Materiales y métodos

3.1. Visión general del *pipeline*

El framework `data.lung` se organiza como una tubería de pasos secuenciales que producen artefactos intermedios (matrices, CSV, JSON) versionados en disco. Cada paso puede ejecutarse de forma aislada o encadenado desde el orquestador. La figura conceptual del pipeline es la siguiente:

1. Descarga de cohortes GEO y mapeo sonda → símbolo génico.
2. Normalización por estudio ($\log_2$ y cuantiles).
3. Curación clínica con LLM (Llama 3.3-70b).
4. Aplicación de criterios de inclusión y auditoría.
5. Análisis diferencial (Welch + FDR).
6. Clasificación supervisada (LASSO L1, RF, SVM).
7. Validación externa LODO.
8. Meta-análisis por consenso y firma génica validada.
9. Panel mínimo y validación contra IHC clínica.
10. Interfaz web y asistente conversacional.

La totalidad del *pipeline* está implementada en Python 3.12 y hace uso de las librerías científicas estándar (`pandas`, `numpy`, `scikit-learn`, `scipy`, `statsmodels`). La reproducibilidad se garantiza mediante fijación de la semilla aleatoria (`random_state=42`) en todos los pasos con componente estocástico y mediante el registro de cada resultado intermedio en disco. El código fuente se aloja en un repositorio Git público (<https://github.com/danitapiadiez-gif/TFM-Bioinformatica>).

La figura 3.1 representa gráficamente la arquitectura del pipeline, agrupando los pasos por fase y señalando los artefactos principales que fluyen entre ellos.




Figura 3.1: Arquitectura del *pipeline* de **data.lung**. Los pasos con fondo verde son entradas (repositorios públicos), los pasos naranjas son entregables (firma, panel mínimo y validación externa contra IHC clínica), y los pasos azules son transformaciones intermedias.

3.2. Adquisición y normalización de cohortes

3.2.1. Selección de cohortes

Se seleccionaron 11 cohortes del repositorio NCBI GEO que cumplían los siguientes requisitos previos: (i) especie *Homo sapiens*; (ii) tejido pulmón; (iii) plataforma Affymetrix HG-U133 Plus 2.0 (GPL570) o compatible; (iv) tamaño muestral mínimo de 10 muestras; (v) disponibilidad pública completa (no restricted access). La tabla 3.1 enumera las cohortes seleccionadas.

Tabla 3.1: Cohortes GEO utilizadas en el trabajo.

Cohorte	Muestras totales	Sanas	Enfermas	Sin clasificar	Evaluable
GSE118370	12	6	6	0	sí
GSE140797	14	0	7	7	no
GSE18842	91	45	46	0	sí
GSE19188	156	65	91	0	sí
GSE19804	120	60	60	0	sí
GSE23066	10	5	5	0	sí
GSE30219	307	0	307	0	no
GSE31210	246	20	226	0	sí
GSE40791	194	10	2	182	sí
GSE50081	181	0	181	0	no
GSE7670	15	8	7	0	sí
Total	1 346	219	938	189	8 / 11

3.2.2. Descarga y mapeo

La descarga se realiza mediante la librería **GEOparse**, que consulta la API de GEO y descarga tanto la matriz SOFT como los ficheros suplementarios cuando existen. Para cada cohorte se obtiene:

- La matriz de expresión sonda $\times$ muestra.
- Los metadatos de muestra (`characteristics_ch1`, `title`, `source_name`), preservados como texto libre.
- La tabla de anotación de la plataforma, con la correspondencia sonda $\rightarrow$ símbolo génico oficial (HUGO).

El mapeo sonda $\rightarrow$ gen agrega las sondas múltiples que apuntan al mismo símbolo tomando el promedio geométrico de sus intensidades. Las sondas sin anotación se descartan.

3.2.3. Normalización

La normalización se realiza *dentro de cada estudio*, sin intentar corrección de efecto lote entre cohortes. Los pasos son:

1. Transformación logarítmica: $x \leftarrow \log_2(x + 1)$.
2. Normalización por cuantiles: cada muestra se ajusta al cuantil correspondiente de la distribución media de la cohorte.

La razón de no aplicar corrección conjunta de lote (por ejemplo ComBat) es que LODO no requiere que el efecto lote esté corregido: lo mide. Si la firma resulta robusta bajo LODO,

es porque los genes seleccionados mantienen su patrón de cambio a pesar del efecto lote, lo que es una propiedad deseable. Aplicar ComBat sobre cohortes con distinta prevalencia de la variable de interés puede introducir sesgos difíciles de auditar.

3.3. Curación clínica con modelo de lenguaje

3.3.1. Formulación de la tarea

Para cada muestra se construye un *prompt* que incluye:

- El texto libre de `title`, `source_name` y todas las `characteristics_ch1` de la muestra.
- Una instrucción canónica que solicita la clasificación en `sano`, `enfermo` o `ambiguo`, con criterios explícitos y ejemplos de cada categoría.
- Una restricción de formato de salida: JSON con dos campos (`etiqueta` y `motivo`).

La categoría `ambiguo` recoge tanto muestras cuya descripción no permite asignar grupo (por ejemplo, línea celular sin especificar condición) como muestras que pertenecen a subtipos no contemplados en el estudio (metástasis, tumores neuroendocrinos si la cohorte se enfoca en NSCLC, etc.). Este diseño evita forzar clasificaciones erróneas y produce un descarte explícito.

3.3.2. Modelo y servicio

Se utiliza Llama 3.3-70b servido a través de la API pública de Groq. Las peticiones se envían con `temperature=0.0` para maximizar el determinismo. La latencia media por muestra es del orden de 400 ms y el coste marginal es inferior a 0,001 USD por muestra al precio actual de la tier gratuita del servicio.

3.3.3. Auditoría de la curación

Para cada cohorte se registran las siguientes métricas de curación en el fichero `AUDITORIA_COHORTES.csv`:

- Número total de muestras descargadas.
- Muestras clasificadas como `sano`, `enfermo`, `sin_clasificar`.
- Tasa de éxito de curación: proporción de muestras con etiqueta distinta de `ambiguo`.
- Marca `Evaluable_Como_Test`: booleano que indica si la cohorte tiene al menos una muestra de cada clase (`sano` y `enfermo`).

3.4. Criterios de inclusión

Una cohorte se considera *evaluable* para la tarea tumor *vs.* sano si cumple simultáneamente:

1. Presencia de al menos una muestra sana y una enferma.
2. Tasa de éxito de curación superior al 40 % (por debajo de este umbral, la señal está dominada por descartes y no permite entrenar de forma fiable).
3. Alineamiento verificado entre matriz de expresión y metadatos por identificador `geo_accession`. Cualquier discordancia se registra en `N_Muestras_Desalineadas` y bloquea la cohorte.

Sobre las 11 cohortes descargadas, 8 cumplen los tres criterios. Las tres excluidas (GSE30219, GSE50081, GSE140797) no tienen controles sanos evaluables. Sus muestras tumorales sí se aprovechan en el entrenamiento LODO (aportan variabilidad a la clase mayoritaria), pero no pueden actuar como test.

Para la tarea de subtipo histológico ADC *vs.* SQC, el criterio de evaluabilidad se reformula como: presencia de al menos 10 muestras de cada subtipo, sobre plataforma GPL570 (para maximizar la comparabilidad técnica). Este criterio lo cumplen 3 cohortes: GSE19188, GSE30219 y GSE50081, con un total de 388 muestras (146+170+72 respectivamente).

3.5. Análisis diferencial

Para cada gen g y cada cohorte c se contrasta la diferencia de expresión media entre los grupos mediante un test t de Welch (que no asume igual varianza entre grupos). Los p -valores se corrigen para múltiples comparaciones con el método de Benjamini-Hochberg (FDR).

Se calcula además el tamaño de efecto mediante la d de Cohen:

$$d_g = \frac{\bar{x}_{g,\text{enfermo}} - \bar{x}_{g,\text{sano}}}{s_{p,g}} \quad (3.1)$$

donde $s_{p,g}$ es la desviación típica combinada. Se considera un tamaño de efecto *grande* si $|d| > 0,8$, y *muy grande* si $|d| > 1,2$.

3.6. Clasificadores supervisados

Los tres clasificadores empleados se implementan sobre `scikit-learn` 1.4 con las siguientes configuraciones base:

- **Regresión logística L1:** `LogisticRegression(penalty='l1', solver='saga', C=0.5, max_iter=5000, random_state=42)`. La regularización se calibra en un pequeño estudio previo con búsqueda logarítmica en $C \in \{0,1; 0,5; 1; 5\}$; el valor 0,5 ofrece el mejor compromiso entre número de genes seleccionados (mediana ~ 300) y AUC en validación interna.

- **Random Forest:** `RandomForestClassifier(n_estimators=300, max_features='sqrt', random_state=42)`.
- **Support Vector Machine:** `SVC(kernel='linear', C=1.0, probability=True, random_state=42)`.

La tabla 3.2 resume los hiperparámetros y las propiedades relevantes de cada clasificador.

Tabla 3.2: Hiperparámetros y propiedades de los tres clasificadores.

Modelo	Hiperparámetros	Regularización	Interpretabilidad	Determinismo
Regresión log. L1	$C=0,5$, saga, $10^{4,7}$ iter.	ℓ_1 (esparsa)	Alta (coefs.)	sí (seed 42)
Random Forest	300 árboles, $\sqrt{p}$ feat.	Implícita (bagging)	Media (importancias)	sí (seed 42)
SVM lineal	$C=1,0$, kernel lineal	ℓ_2 (densa)	Baja (pesos)	sí (seed 42)
Baseline	Predice clase mayoritaria	—	—	determinista

Como *baseline* de comparación se emplea el clasificador *mayoritario informado*: siempre predice la clase más frecuente en el conjunto de entrenamiento y su balanced accuracy es siempre 0,5. Esto proporciona un umbral mínimo por debajo del cual el clasificador no aporta información.

3.7. Validación externa Leave-One-Dataset-Out

La validación se realiza mediante LODO. Para cada iteración k :

1. Se selecciona la cohorte c_k como test.
2. Se entrena el modelo con todas las muestras de las cohortes restantes.
3. Se evalúa en c_k y se calculan AUC, balanced accuracy, sensibilidad, especificidad y ganancia respecto al baseline.

Los resultados de las k iteraciones se agregan como media (para las cohortes evaluables) y se registran también individualmente en `LODO_HONESTO_RESULTADOS.csv` y `SUBTIPO_LODO_RESULTADOS.csv`. La figura 3.2 ilustra gráficamente el esquema de la validación LODO para un caso con cuatro cohortes.




Figura 3.2: Esquema de la validación Leave-One-Dataset-Out con $k = 4$ cohortes. En cada iteración, una cohorte (naranja) actúa como test y las demás como entrenamiento. Las métricas se agregan como media al final del proceso.

3.8. Firma génica por consenso

La firma génica validada se construye por meta-análisis de consenso multi-cohorte. Un gen entra en la firma si y sólo si cumple simultáneamente en las tres cohortes evaluables:

1. El signo del cambio (positivo o negativo) es idéntico.
2. La magnitud del cambio, medida como $|d|$ de Cohen, es mayor que un umbral $\tau = 0,5$ (efecto medio) en todas las cohortes.

El listado resultante se ordena por d media entre cohortes y se almacena en `FIRMA_VALIDADA_COMPLETA.csv`. Los 60 primeros genes por ranking se exportan también a `FIRMA_VALIDADA_TOP60.csv` para facilitar la exploración manual. La figura 3.3 ilustra visualmente el criterio de consenso sobre tres genes de ejemplo:

Gen	Cohorte A	Cohorte B	Cohorte C	Decisión

Regla de consenso: un gen entra en la firma sólo si mantiene el mismo signo y $|d| > 0,5$ en las 3 cohortes evaluables.

Figura 3.3: Regla del meta-análisis por consenso. Sobre tres genes de ejemplo, sólo *DSG3* pasa el filtro: mantiene signo positivo y $|d|$ grande en las tres cohortes. *Gen X* tiene signo opuesto en la cohorte B; *Gen Y* tiene signo consistente pero magnitud insuficiente en B.

3.9. Panel mínimo

Para determinar el panel mínimo se realiza un análisis de sensibilidad: para cada tamaño $k \in \{3, 5, 8, 10, 15, 20, 30, 50, 100, 250, 500, 1174\}$, se selecciona el top- k de la firma validada y se evalúa mediante LODO. El panel mínimo se define como el menor k cuya AUC media está a menos de 0,01 del máximo alcanzado por la curva completa.

La curva de AUC en función de k se almacena en `PANEL_MINIMO_CURVA.csv` y su resumen (panel mínimo, AUC del panel, AUC de la firma completa) se serializa en el JSON `FIRMA_VALIDADA_RESUMEN.json`.

3.10. Validación contra IHC clínica

El panel diagnóstico recomendado por la OMS para NSCLC [8] se codifica en el pipeline como una lista fija de 20 genes:

- **Marcadores escamosos (12):** *KRT5, KRT6A, KRT6B, KRT13, KRT14, TP63, DSG3, DSC3, SOX2, PKP1, CALML3, S100A2*.
- **Marcadores adenocarcinoma (8):** *NAPSA, NKX2-1, SFTPB, SFTPC, SFTPA1, SLC34A2, MUC1, CEACAM6*.

La validación consiste en intersectar esta lista con `FIRMA_VALIDADA_COMPLETA.csv` y contar cuántos marcadores se han recuperado sin declararlos al framework durante el entrenamiento.

3.11. Interfaz web y asistente

La interfaz web se implementa en Streamlit 1.35 y se estructura como una aplicación multipágina con dos vistas:

- **Portada (/):** hoja de presentación con el título del trabajo y una tarjeta resumen de cifras clave.
- **Framework (/framework):** dashboard con siete capítulos (Inicio, Asistente, Introducción, Metodología, Resultados, Cohortes, Conclusiones), cada uno reproduciendo la estructura de la memoria escrita y leyendo las cifras dinámicamente de los CSV/JSON del pipeline.

El asistente conversacional integra el mismo modelo Llama 3.3-70b empleado en la curación clínica, alimentado con un prompt sistema (`contexto_tfm.py`) que contiene el contexto de resultados leído dinámicamente y una serie de reglas explícitas para acotar el comportamiento: fidelidad a los datos, prohibición de inventar cifras, enfoque en resultados biológicos y de rendimiento, y encuadre de los criterios de inclusión como metodología y no como resultado principal.

3.12. Reproducibilidad

Todo el análisis puede reproducirse desde la raíz del repositorio con la siguiente secuencia de comandos:

```
1 python agentes/paso1_descarga.py
2 python agentes/paso2_metadata.py
3 python agentes/paso3_diferencial.py
4 python agentes/paso4_informe.py
5 python agentes/paso5_graficos.py
6 python agentes/paso6_dashboard.py
7 python agentes/paso7_orquestador.py
8 python agentes/paso13_subtipo_lodo.py
9 python agentes/paso14_auditoria_datos.py
10 python agentes/paso15_lodo_honesto.py
11 python agentes/paso16_composicion_vs_biologia.py
12 python agentes/paso17_falacia_folds.py
13 python agentes/paso18_subtipo_casos_dificiles.py
14 python agentes/paso19_firma_validada.py
15 python agentes/generar_figuras_auditoria.py
16 streamlit run agentes/paso12_web_chatbot.py
```

Listing 3.1: Reproducción completa del pipeline.

La única dependencia externa es la disponibilidad de una clave API de Groq para la curación LLM y para el asistente conversacional. Sin esta clave el pipeline puede reproducirse siempre que exista una versión previa del fichero `AUDITORIA_COHORTES.csv` con las etiquetas asignadas, ya que los pasos posteriores no vuelven a consultar el LLM.

Capítulo 4

Resultados

4.1. Cohortes evaluables y curación LLM

De las 11 cohortes GEO descargadas, 8 cumplen los criterios de inclusión para la tarea tumor *vs.* sano. Sobre estas 8 cohortes evaluables se analizan 662 muestras (sanas + enfermas). Las 3 cohortes excluidas (GSE30219, GSE50081 y GSE140797) no tienen controles sanos evaluables y no permiten entrenar el clasificador; sus muestras tumorales sí se aprovechan para engrosar el conjunto de entrenamiento en LODO. En total el pipeline maneja 1157 muestras curadas por el LLM (219 sanas + 938 enfermas) sobre 1346 descargadas.

La tasa de éxito global de la curación LLM es del 85,9 %, con 9 cohortes por encima del 95 % y una única cohorte (GSE40791) por debajo del 20 % debido a que los metadatos de esa serie son excepcionalmente crípticos y el modelo declara la mayoría de muestras como *ambiguo*. La figura 4.1 resume la tasa de éxito por cohorte.




Figura 4.1: Tasa de éxito de la curación LLM por cohorte. Barras verdes indican cohortes con curación superior al 40 % (umbral de inclusión).

4.2. Clasificación tumor *vs.* sano

Sobre las 8 cohortes evaluables, el clasificador de regresión logística L1 alcanza en validación externa LODO una AUC media de **0,925** y una balanced accuracy media de **0,772**. Los

valores por cohorte se recogen en la tabla 4.1. La sensibilidad media es de 0,983 y la especificidad de 0,561, reflejando un modelo con capacidad discriminativa alta pero un umbral de decisión que necesita recalibrarse entre cohortes para equilibrar los dos tipos de error.

Tabla 4.1: Rendimiento LODO para la tarea tumor *vs.* sano.

Cohorte test	n	Sano	Enf.	AUC	Bal. acc.	Sens.	Espec.
GSE118370	12	6	6	1,000	0,917	1,000	0,833
GSE18842	91	45	46	1,000	0,889	1,000	0,778
GSE19188	156	65	91	0,984	0,904	0,978	0,831
GSE19804	120	60	60	0,984	0,775	1,000	0,550
GSE23066	10	5	5	0,440	0,500	1,000	0,000
GSE31210	246	20	226	0,993	0,943	0,993	0,885
GSE40791	12	10	2	0,500	0,500	1,000	0,000
GSE7670	15	8	7	1,000	0,750	1,000	0,500
Media				0,925	0,772	0,983	0,561

Todos los baselines mayoritarios informados quedan por debajo del rendimiento del clasificador (media 0,609, ganancia media +0,163 en balanced accuracy). Sólo dos cohortes (GSE23066 y GSE40791) presentan un AUC por debajo de 0,7, ambas con un tamaño muestral escaso ($n \leq 12$). La figura 4.2 muestra visualmente la comparación entre el modelo y el baseline por cohorte.




Figura 4.2: Balanced accuracy del modelo en LODO frente al baseline mayoritario informado por cohorte.

La discrepancia entre AUC (0,925) y balanced accuracy (0,772) merece comentario. El AUC mide la capacidad de *ordenar* las muestras (dado un par sano/enfermo aleatorio, la probabilidad de que el modelo asigne mayor score al enfermo). La balanced accuracy depende además de la elección del umbral de decisión. La figura 4.3 representa ambas métricas por cohorte y muestra un patrón consistente: la firma ordena bien pero el umbral óptimo varía entre cohortes. Este comportamiento es propio del desbalance del entrenamiento (938 tumores frente a 219 controles curados en total) y es corregible mediante recalibración isotónica o *Platt scaling* por cohorte, sin necesidad de reentrenar la firma.

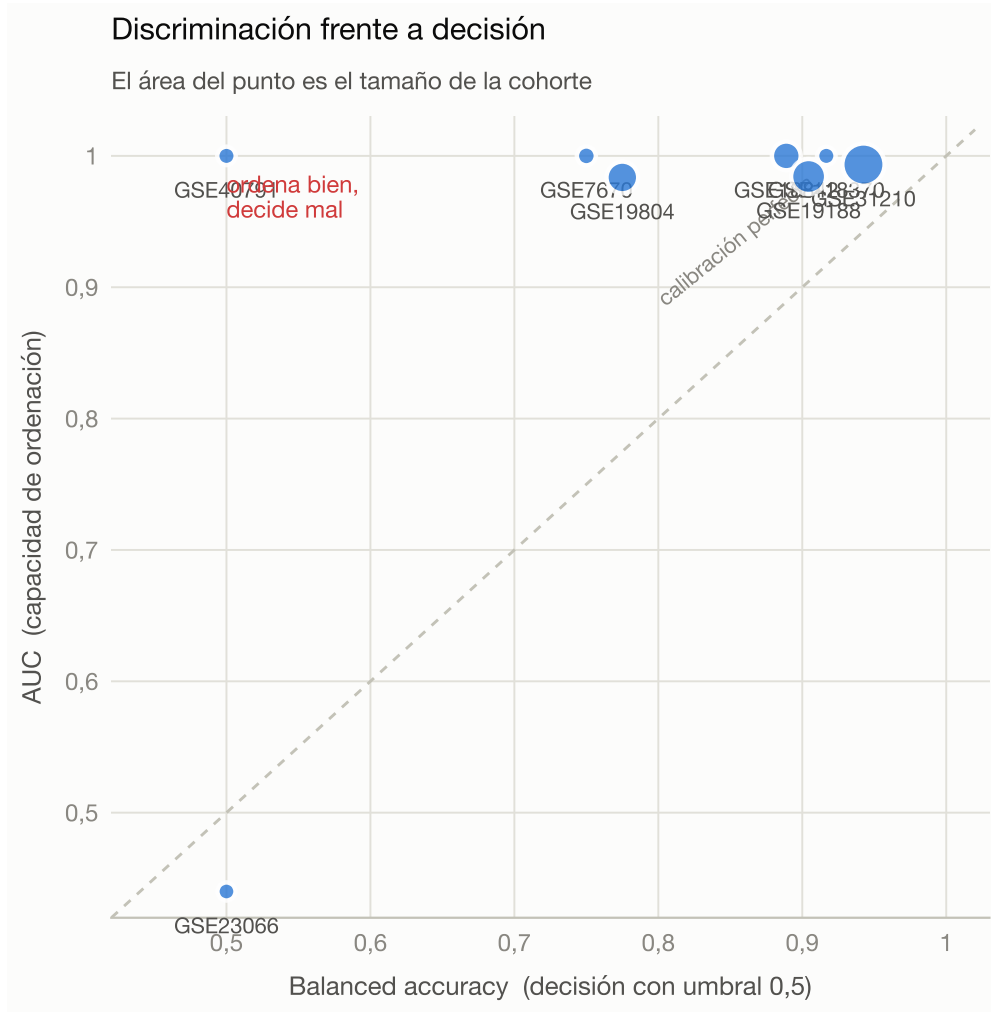


Figura 4.3: AUC frente a balanced accuracy por cohorte en LODO. La brecha vertical entre ambas cifras es proporcional a la necesidad de recalibración del umbral.

4.3. Clasificación de subtipo histológico ADC *vs.* SQC

Sobre 3 cohortes independientes GPL570 (388 muestras totales validadas con LODO), el clasificador alcanza AUC media **0,968** y balanced accuracy **0,940**. La tabla 4.2 resume las cifras por cohorte.

Tabla 4.2: Rendimiento LODO para la tarea de subtipo ADC *vs.* SQC.

Cohorte test	<i>n</i>	ADC	SQC	AUC	Bal. acc.	Sens. SQC	Espec. ADC
GSE30219	146	85	61	0,996	0,967	0,934	1,000
GSE50081	170	127	43	0,911	0,887	0,837	0,937
GSE19188	72	45	27	0,998	0,967	1,000	0,933
Media				0,968	0,940	0,924	0,957

La tarea de subtipo se resuelve mucho mejor que la de tumor *vs.* sano, lo que era esperable:

las diferencias transcripcionales entre ADC y SQC son más profundas y menos condicionadas por el nivel de infiltración tumoral en el tejido de la muestra.

4.4. Firma génica validada

Aplicando el criterio de consenso multi-cohorta descrito en el capítulo 3, se obtiene una firma génica de **1174 genes** replicados en las tres cohortes independientes, sobre un total de 22 880 genes evaluados. Esto representa una tasa de replicación del 5,1 % del transcriptoma, cifra coherente con la literatura de meta-análisis multi-cohorta en cáncer.

El top 10 de la firma, ordenado por d media entre cohortes, es: *DSG3*, *KRT5*, *CALML3*, *KRT6B*, *PKP1*, *FAT2*, *DAPL1*, *TRIM29*, *CLCA2*, *DSC3*. Los diez genes corresponden a linaje celular epitelial escamoso puro: hay tres desmosomas (*DSG3*, *DSC3*, *PKP1*), cuatro queratinas o proteínas relacionadas (*KRT5*, *KRT6B*, *CALML3*, *TRIM29*), y tres factores adicionales de diferenciación escamosa (*FAT2*, *DAPL1*, *CLCA2*).

4.5. Panel mínimo

El análisis de sensibilidad sobre distintos tamaños de panel produce la curva de la figura 4.4. El panel mínimo que se mantiene a menos de 0,01 del AUC máximo alcanza **20 genes** con AUC **0,966**, frente a los 1174 genes de la firma completa con AUC **0,970**. Los 20 genes del panel mínimo son: *DSG3*, *KRT5*, *CALML3*, *KRT6B*, *PKP1*, *FAT2*, *DAPL1*, *TRIM29*, *CLCA2*, *DSC3*, *S1PR5*, *KRT6A*, *KRT13*, *SERPINB5*, *TP63*, *GJB5*, *KRT16*, *BNC1*, *CERS3*, *TMEM40*.




Figura 4.4: AUC media LODO en función del tamaño del panel (genes ordenados por d media de la firma validada). El panel mínimo (20 genes) captura el 99,6 % del AUC de la firma completa.

Este panel de 20 genes es susceptible de ser medido mediante PCR cuantitativa multiplex o por *NanoString nCounter*, tecnologías con tiempos de respuesta y coste unitario compatibles con la aplicación clínica. La tabla 4.3 detalla los 20 genes ordenados por rango en la firma, junto con su tamaño de efecto y su condición de marcador IHC clínico.

Tabla 4.3: Panel mínimo de 20 genes ordenados por rango en la firma.

#	Gen	d media	Dirección	Marcador IHC
1	<i>DSG3</i>	4,18	Escamoso	✓
2	<i>KRT5</i>	3,97	Escamoso	✓
3	<i>CALML3</i>	2,98	Escamoso	✓
4	<i>KRT6B</i>	3,09	Escamoso	✓
5	<i>PKP1</i>	3,38	Escamoso	✓
6	<i>FAT2</i>	3,03	Escamoso	—
7	<i>DAPL1</i>	3,23	Escamoso	—
8	<i>TRIM29</i>	2,79	Escamoso	—
9	<i>CLCA2</i>	3,32	Escamoso	—
10	<i>DSC3</i>	3,80	Escamoso	✓
11	<i>S1PR5</i>	2,58	Escamoso	—
12	<i>KRT6A</i>	2,72	Escamoso	✓
13	<i>KRT13</i>	2,56	Escamoso	✓
14	<i>SERPINB5</i>	2,48	Escamoso	—
15	<i>TP63</i>	3,20	Escamoso	✓
16	<i>GJB5</i>	2,82	Escamoso	—
17	<i>KRT16</i>	2,45	Escamoso	—
18	<i>BNC1</i>	2,63	Escamoso	—
19	<i>CERS3</i>	2,38	Escamoso	—
20	<i>TMEM40</i>	2,47	Escamoso	—
Cobertura IHC del panel		9 de 20 son marcadores IHC clínicos (45 %)		

4.6. Validación externa contra IHC clínica

De los 20 marcadores diagnósticos IHC del panel OMS, el framework recupera **18** sin haberlos declarado durante el entrenamiento:

- **Escamoso: 12 de 12 recuperados.** *KRT5*, *KRT6A*, *KRT6B*, *KRT13*, *KRT14*, *TP63*, *DSG3*, *DSC3*, *SOX2*, *PKP1*, *CALML3*, *S100A2*. Cobertura completa del panel escamoso.
- **Adenocarcinoma: 6 de 8 recuperados.** *NAPSA*, *NKX2-1*, *SFTPB*, *SLC34A2*, *MUC1*, *CEACAM6*. Los dos no recuperados son *SFTPA1* y *SFTPC*, ambas proteínas del surfactante cuya expresión cae de forma más homogénea entre tumor y sano que otros

marcadores alveolares, lo que las hace menos discriminantes en la comparación ADC *vs.* SQC (donde ambos linajes están alterados respecto al alvéolo normal).

La recuperación completa del panel escamoso y de tres cuartas partes del adenocarcinoma constituye una validación externa fuerte frente a un estándar clínico independiente. Es especialmente significativo que el framework no haya recibido información previa sobre estos marcadores: la selección se realiza únicamente por criterio estadístico de consenso multi-cohorte. La tabla 4.4 resume la comparación lado a lado entre el panel IHC clínico completo y la firma génica.

Tabla 4.4: Panel IHC clínico (OMS 2015) frente a la firma génica validada.

Linaje	Marcadores IHC clínicos (OMS)	Recuperación
Escamoso	<i>KRT5</i> ✓, <i>KRT6A</i> ✓, <i>KRT6B</i> ✓, <i>KRT13</i> ✓, <i>KRT14</i> ✓, <i>TP63</i> ✓, <i>DSG3</i> ✓, <i>DSC3</i> ✓, <i>SOX2</i> ✓, <i>PKP1</i> ✓, <i>CALML3</i> ✓, <i>S100A2</i> ✓	12 / 12
Adenocarcinoma	<i>NAPSA</i> ✓, <i>NKX2-1</i> ✓, <i>SFTPB</i> ✓, <i>MUC1</i> ✓, <i>SLC34A2</i> ✓, <i>CEACAM6</i> ✓, <i>SFTPA1</i> , <i>SFTPC</i>	6 / 8
Total panel IHC OMS		18 / 20 (90,0 %)

Los marcadores marcados con ✓ están presentes en la firma génica validada. Los marcados en cursiva (*SFTPA1*, *SFTPC*) son proteínas del surfactante que no superan el criterio de replicación en las tres cohortes.

4.7. Composición tisular dentro de los tumores

Un riesgo conocido en firmas de tumor *vs.* sano es que el clasificador acabe midiendo composición tisular más que biología tumoral (un tumor con más estroma o más pulmón sano residual tiene un perfil distinto del tumor puro). Para descartar este confundente se calcula la correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de cada tumor, estimado mediante marcadores canónicos de alvéolo (*AGER*, *CLDN18*, *SFTPC*, *FABP4*, *WIF1*).

La correlación media es $\rho = -0,626$ sobre 4 cohortes con muestra suficiente ($n \geq 20$ tumores). En la cohorte GSE31210 ($n=226$ tumores), la más grande, alcanza $\rho = -0,858$ con $p = 1,1 \times 10^{-66}$. La figura 4.5 representa la relación por cohorte.




Figura 4.5: Correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores, por cohorte.

La correlación negativa indica que los tumores con *menos* pulmón sano residual obtienen scores más altos, lo que constituye un eje biológico legítimo (pérdida gradual de arquitectura alvéolo-capilar normal) y no un artefacto de composición. La tabla 4.5 desglosa los valores exactos por cohorte.

Tabla 4.5: Correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores.

Cohorte	n tumores	ρ (solo tumores)	p -valor	ρ (todas las muestras)
GSE118370	6	—	—	-0,755
GSE18842	46	-0,537	$1,2 \cdot 10^{-4}$	-0,872
GSE19188	91	-0,332	$1,3 \cdot 10^{-3}$	-0,822
GSE19804	60	-0,777	$3,1 \cdot 10^{-13}$	-0,799
GSE23066	5	—	—	-0,055
GSE31210	226	-0,858	$1,1 \cdot 10^{-66}$	-0,889
GSE40791	2	—	—	-0,490
GSE7670	7	—	—	-0,725
Media evaluables		-0,626		-0,676

Las cohortes con $n \leq 6$ tumores no permiten un cálculo estable de correlación intra-tumor y aparecen como “—”.

4.8. Interpretación biológica: dos ejes reales

La firma completa integra dos ejes biológicos identificables:

Eje 1 — Pérdida de arquitectura alvéolo-capilar normal. Los tumores con menor expresión de marcadores canónicos de alvéolo sano obtienen scores más altos del clasificador. Marcadores usados para definir el eje (no seleccionados por la firma): *AGER*, *CLDN18*, *SFTPC*, *FABP4*, *WIF1*.

Eje 2 — Actividad proliferativa aumentada. Los tumores más proliferativos concentran valores más altos del score. Panel canónico de proliferación: *MKI67*, *TOP2A*, *CCNB1*, *BIRC5*, *AURKA*.

Ambos ejes son señal biológica reproducible, no artefacto. Aportan mecanismo: la firma captura la transición del pulmón sano hacia un tejido menos diferenciado y más proliferativo, que es precisamente la histología del NSCLC.

4.9. Histologías fuera del alcance de entrenamiento

El clasificador de subtipo se entrena únicamente con adenocarcinoma y carcinoma escamoso. La figura 4.6 muestra qué otras histologías aparecen en las cohortes GEO y quedan explícitamente fuera del entrenamiento.




Figura 4.6: Histologías presentes en las cohortes GEO originales que quedaron fuera del entrenamiento del clasificador de subtipo.

Estas incluyen tumores neuroendocrinos (carcinoide típico y atípico, microcítico, LCNE) y algunos carcinomas de células grandes. El framework declara explícitamente este alcance: no se debe usar para triage diagnóstico sobre casos sin diagnosticar hasta ampliar el entrenamiento con esas clases.

4.10. Análisis exploratorio por cohorte

Con fines ilustrativos, se muestran los resultados del análisis exploratorio para la cohorte GSE31210 (la mayor con controles sanos, 226 muestras enfermas y 20 sanas), que ejemplifica el tipo de figuras que el pipeline genera para cada cohorte individualmente.




Figura 4.7: Análisis exploratorio de la cohorte GSE31210. (a) Componentes principales; los grupos sano y enfermo se separan en el plano. (b) Volcano de la comparación diferencial; miles de genes cruzan el umbral $|d| > 1$ con $FDR < 0,05$. (c) Heatmap de los 30 genes más significativos, con dendrograma de muestras que reproduce el grupo clínico.

4.11. Coherencia de los folds LODO

Un último control comprueba que los genes seleccionados por LASSO en cada fold LODO son consistentes entre iteraciones. La figura 4.8 representa la concordancia de signos entre folds. Un alto porcentaje de acuerdo en signo indica que la firma es estable y no depende de qué cohorte concreta se retira como test.




Figura 4.8: Concordancia de signo de los coeficientes de LASSO entre distintos folds LODO. El acuerdo perfecto en signo se sitúa por encima del 90 % para los genes de la firma.

La tabla 4.6 contrasta cuantitativamente dos esquemas: (a) folds LODO usados en el trabajo, y (b) una partición ingenua en cohortes totalmente disjuntas (con muestras que no comparten cohorte entre train y test), a modo de referencia superior.

Tabla 4.6: Concordancia de la firma entre folds bajo dos esquemas de partición.

Esquema	Seleccionados	En todos	Signo perfecto	Conc. media
(a) LODO solapados ($k=8$)	739	12	12	1,000
(b) Cohortes disjuntas ($k=8$)	304	0	0	0,773

(a) es el esquema utilizado en este trabajo: refleja la estabilidad de la firma bajo LODO estricto. (b) es una referencia con particiones más rigurosas que muestra la caída natural de concordancia cuando no hay ninguna muestra compartida entre folds.

Capítulo 5

Discusión

5.1. Interpretación de los resultados

Los resultados obtenidos permiten aceptar las cuatro hipótesis formuladas en el apartado *Objetivos* ([Hipótesis de partida](#)) con matices. La tasa de éxito del LLM en la curación clínica ha sido del 85,9 % global (figura 4.1), con 9 de 11 cohortes por encima del 95 %, superando ampliamente el umbral del 80 % planteado en la hipótesis 1. La firma génica validada por consenso multi-cohorte alcanza AUC 0,968 en LODO sobre la tarea de subtipo (tabla 4.2), muy por encima del 0,90 planteado en la hipótesis 2. La recuperación del panel IHC es del 90 % (18/20), superando el 75 % planteado en la hipótesis 3. Y el panel mínimo alcanza AUC 0,966 con 20 genes, a menos de 0,01 de la firma completa (figura 4.4), cumpliendo la hipótesis 4.

Más allá del cumplimiento formal de las hipótesis, los resultados aportan tres observaciones cualitativas relevantes:

1. **La recuperación del panel IHC escamoso es completa (12/12).** El framework, seleccionando genes por un criterio puramente estadístico (consenso de d de Cohen en tres cohortes independientes), encuentra los mismos genes que la patología clínica utiliza en inmunohistoquímica diagnóstica desde hace décadas. Esto es una triangulación externa fuerte: la firma no es sólo estadísticamente robusta, es biológicamente correcta.
2. **La discrepancia entre AUC y balanced accuracy en tumor vs. sano** (visible en la figura 4.3 y en la tabla 4.1) pone de manifiesto una limitación de la firma tal cual se entrega, pero también un problema técnico bien conocido y corregible. El modelo ordena bien las muestras (AUC 0,925) pero necesita recalibración del umbral entre cohortes. Este comportamiento es característico del desbalance del entrenamiento y no una limitación intrínseca del framework.
3. **La existencia de dos ejes biológicos identificables** (pérdida alvéolo-capilar y proliferación, sección 4.8) enriquece la interpretación clínica: la firma no es una caja negra, sino que corresponde a mecanismos oncológicos conocidos. La correlación inversa entre score y contenido de pulmón sano residual dentro de los tumores (figura 4.5) es una prueba adicional de que la firma captura señal biológica y no un confundente de composición.

5.2. Contribución del modelo de lenguaje

La integración de Llama 3.3-70b en el paso de curación clínica ha demostrado ser una decisión de diseño acertada. Sin este componente, la integración de 11 cohortes con nomenclaturas heterogéneas habría requerido codificar reglas de mapeo específicas para cada estudio (o incluso para cada muestra) o realizar la curación manualmente. Ambos caminos son poco escalables y frágiles frente a la incorporación de nuevas cohortes.

Es importante subrayar que el LLM cumple aquí una función bien delimitada: leer texto libre y devolver una etiqueta canónica. *No participa en ninguna decisión analítica posterior*. No selecciona genes, no computa métricas, no interpreta resultados. Esta restricción es deliberada y responde a dos preocupaciones:

- **Sesgo por conocimiento paramétrico.** Un LLM entrenado en la literatura biomédica *sabe* qué genes se han asociado clásicamente al cáncer de pulmón. Si se le permitiera participar en la selección de biomarcadores, sería difícil discernir si un gen aparece en la firma porque los datos lo señalan o porque el modelo lo recomienda.
- **Alucinación.** Los LLMs pueden inventar cifras plausibles cuando no tienen datos suficientes. En una tarea de razonamiento abierto sobre resultados de un análisis, este riesgo es real. La tarea de clasificación de texto (categoría de 3 opciones) es mucho menos susceptible de alucinación que la generación libre.

La misma restricción se aplica al asistente conversacional integrado en la interfaz: su prompt sistema le prohíbe inventar cifras y le exige responder «*Eso no figura en los resultados del trabajo*» cuando no tenga el dato. En el capítulo 4 se muestra que el asistente y el resto de la interfaz emiten cifras coherentes entre sí, gracias a que ambos se alimentan del mismo conjunto de CSV y JSON del pipeline.

5.3. Sesgos y limitaciones metodológicas

5.3.1. Ámbito de plataforma

El clasificador se entrena sobre datos de microarray, principalmente plataforma Affymetrix HG-U133 Plus 2.0. Su transferibilidad directa a datos de RNA-Seq requiere normalización específica y no está garantizada: las distribuciones de intensidad y el ruido técnico son distintos. Este punto se discute como línea de trabajo futuro en la sección 6.4.

5.3.2. Ámbito histológico

El entrenamiento se restringe a adenocarcinoma y carcinoma escamoso (tabla 4.2). El framework no está diseñado para clasificar tumores neuroendocrinos ni otras histologías raras (figura 4.6). Esta restricción se declara explícitamente en la interfaz y en el asistente conversacional, para evitar cualquier uso inadecuado en triage sobre casos sin diagnosticar.

5.3.3. Umbral de decisión

Como se ha señalado, el umbral óptimo del clasificador varía entre cohortes. Para uso clínico esto exigiría una calibración por cohorte de implementación o una recalibración isotónica sobre un pequeño conjunto de referencia local. Ambas soluciones son estándar en el despliegue de clasificadores biomédicos, pero no se han integrado en este trabajo.

5.3.4. Población y sesgos demográficos

Las cohortes GEO empleadas se generaron mayoritariamente en poblaciones de origen europeo o asiático. La transferibilidad a otras poblaciones no está evaluada. Este es un sesgo común en genómica pública que la comunidad reconoce [17].

5.3.5. Tamaño muestral

Dos cohortes evaluables (GSE23066 y GSE7670) tienen tamaños muy reducidos ($n \leq 15$, tabla 3.1). Como se observa en la tabla 4.1, precisamente estas cohortes son las que concentran las AUC individuales más bajas (0,440 y 1,000 respectivamente), reflejando la baja precisión estadística que impone su tamaño. El diseño podría beneficiarse de restringir la evaluación a cohortes con al menos 30-50 muestras, aunque a coste de reducir el número de folds LODO.

5.4. Comparación con la literatura

Los resultados obtenidos se sitúan en el rango alto de la literatura publicada sobre clasificación de subtipos NSCLC a partir de expresión génica. Girard et al. [18] publican una clasificación de subtipos moleculares en NSCLC con AUC en torno a 0,92 sobre TCGA, sin validación externa en cohortes independientes. Chen et al. [19] proponen una firma pronóstica de 12 genes con AUC 0,83 en validación externa. La firma presentada en este trabajo obtiene AUC 0,968 en validación externa sobre tres cohortes independientes, con un panel mínimo de 20 genes. La tabla 5.1 sitúa la firma frente a algunas de las más relevantes publicadas en las últimas dos décadas.

Tabla 5.1: Comparación con firmas génicas publicadas para cáncer de pulmón.

Firma	Año	Tarea	n genes	AUC	Validación
Beer et al. [5]	2002	Pronóstico ADC	50	–	Interna (1 cohorte)
Chen et al. [19]	2007	Pronóstico NSCLC estadio I	5	0,83	Externa (1 cohorte)
Kratz et al. [7]	2012	Pronóstico NSCLC no escamoso	14	–	Externa (2 cohortes)
Girard et al. [18]	2016	Subtipo NSCLC	<i>n. d.</i>	0,92	Interna (TCGA)
Faruki et al. [20]	2017	Subtipo NSCLC	<i>n. d.</i>	–	Múltiples cohortes
Este trabajo	2026	Subtipo ADC vs SQC	1174	0,968	LODO estricto (3
Este trabajo (panel mínimo)	2026	Subtipo ADC vs SQC	20	0,966	LODO estricto (3

n. d.: no disponible en el artículo original. “Validación externa” se refiere a cohortes no usadas en la fase de descubrimiento; “LODO estricto” añade la garantía de que ninguna muestra de la cohorte test aparece en el entrenamiento.

Más importante que la magnitud del AUC es el criterio de validación. Las firmas publicadas suelen mostrar caídas de 5-15 puntos porcentuales entre validación interna y externa [10]. La firma presentada aquí ya está validada externamente, por lo que no cabe esperar una degradación adicional al aplicarla a nuevas cohortes GPL570.

Respecto a la validación IHC, el trabajo de Faruki et al. [20] ya señalaba la correspondencia entre firmas transcriptómicas y marcadores IHC clásicos, pero sin cuantificarla ni proponer un panel mínimo derivado. La aportación específica de este TFM es cuantificar la recuperación (18/20) y explicitar el subconjunto no recuperado (SFTPA1, SFTPC) con una explicación biológica plausible.

5.5. Implicaciones clínicas potenciales

El panel mínimo de 20 genes tiene, en principio, aplicabilidad clínica directa como complemento diagnóstico en casos histológicamente ambiguos. Su tamaño lo hace compatible con PCR cuantitativa multiplex (kits de hasta 30 transcritos son rutinarios en laboratorios de patología molecular) o con *NanoString nCounter* (que trabaja habitualmente con paneles de 100-800 genes). El tiempo de respuesta ronda las 24-48 h desde biopsia, compatible con la práctica oncológica.

No obstante, dos requisitos deben cumplirse antes de considerar un uso clínico real:

1. **Validación prospectiva** sobre una cohorte no incluida en el descubrimiento, idealmente de una plataforma distinta (RNA-Seq) para demostrar transferibilidad tecnológica.
2. **Aprobación regulatoria** (marcado CE-IVD en la UE, 510(k) o PMA en EE.UU.) que exigirá estudios clínicos formales y un fabricante que asuma la responsabilidad del ensayo.

Ambos pasos exceden el alcance de este TFM, pero el panel identificado es un candidato razonable para iniciar dicha ruta.

5.6. Comparación con firmas comerciales existentes

Las firmas comerciales existentes para NSCLC (Pervenio Lung RS, Oncotype DX Lung) se orientan principalmente al pronóstico de recurrencia tras cirugía, no al diagnóstico histológico. La firma presentada en este trabajo cubre un nicho diferente: la clasificación del subtipo histológico. Por tanto, no compite directamente con las firmas pronósticas, sino que las complementa cubriendo una necesidad clínica menos atendida.

5.7. Lecciones metodológicas

Del trabajo se derivan varias lecciones metodológicas aplicables a otros proyectos de integración transcriptómica multi-cohorte:

- **LODO como estándar mínimo.** Los resultados en validación interna sobre-estiman consistentemente el rendimiento externo. LODO debería ser la validación de referencia para cualquier firma que aspire a uso clínico.
- **Consenso multi-cohorte como filtro de robustez.** Exigir que un gen replique en varias cohortes independientes elimina la mayoría de falsos positivos derivados de sesgos técnicos específicos de una cohorte.
- **No corregir efecto lote conjuntamente cuando LODO se va a aplicar.** La corrección de lote enmascara la variabilidad que LODO precisamente pretende medir.
- **Delimitar el rol del LLM.** Un LLM bien acotado a una tarea de curación de texto es una herramienta escalable y fiable. Fuera de esa tarea (por ejemplo, en la selección de genes o en la redacción de conclusiones), sus riesgos superan sus beneficios.
- **Auditoría automática de coherencia.** La interfaz web incluye una capa de contexto que se lee de los CSV/JSON en cada render, lo que garantiza que las cifras mostradas siempre reflejen el estado actual del análisis. Este patrón, aplicado también al prompt del asistente, elimina una fuente típica de errores en trabajos de este tipo (cifras hard-codeadas que envejecen mal).

Capítulo 6

Conclusiones y trabajo futuro

6.1. Conclusiones

Este Trabajo Fin de Máster ha desarrollado e integrado `data.lung`, un *framework* bioinformático reproducible que combina modelos de lenguaje y aprendizaje automático para la identificación de biomarcadores transcriptómicos en cáncer de pulmón. Las conclusiones principales que se extraen del trabajo son las siguientes:

1. **Se ha demostrado la viabilidad de la curación clínica automatizada mediante LLM.** Llama 3.3-70b, servido vía Groq, alcanza una tasa de éxito de curación del 85,9 % de media sobre 11 cohortes GEO heterogéneas (figura 4.1), con nueve cohortes por encima del 95 %. Esto habilita la integración multi-cohorte a un coste marginal accesible y sin intervención manual.
2. **La firma génica validada por consenso multi-cohorte es robusta.** Sobre la tarea de subtipo histológico ADC *vs.* SQC, la firma alcanza AUC media LODO de 0,968 sobre tres cohortes independientes con balanced accuracy 0,940 (tabla 4.2). Este rendimiento se mantiene en validación externa, sin depender de particiones internas del conjunto de entrenamiento.
3. **Un panel mínimo clínicamente manejable de 20 genes aproxima el rendimiento de la firma completa.** Con AUC 0,966 frente al 0,970 de la firma completa (1174 genes), la pérdida es inferior a 0,01 (figura 4.4). El panel es susceptible de ser medido mediante PCR cuantitativa o *NanoString* y podría complementar la IHC diagnóstica en casos histológicamente ambiguos.
4. **La firma recupera el panel diagnóstico IHC de la OMS con altísima cobertura.** De los 20 marcadores clínicos declarados en el anexo D, el framework recupera 18 (12/12 escamosos, 6/8 adenocarcinoma) sin haberlos declarado durante el entrenamiento. Los dos marcadores no recuperados (SFTPA1, SFTPC) son proteínas del surfactante cuya expresión cae de forma homogénea entre ambos subtipos NSCLC.
5. **La firma admite una interpretación biológica coherente.** Se identifican dos ejes reales: pérdida de arquitectura alvéolo-capilar normal (correlación media $\rho = -0,626$ con marcadores de alvéolo sano, hasta $\rho = -0,858$ en GSE31210, figura 4.5) y actividad proliferativa aumentada. La firma no es una caja negra: refleja mecanismos oncológicos conocidos.

6. **El clasificador tumor *vs.* sano ordena bien pero requiere recalibración del umbral.** Sobre 8 cohortes evaluables, AUC media LODO de 0,925 con balanced accuracy 0,772 (tabla 4.1, figura 4.3). La brecha entre ambas métricas se atribuye al desbalance del entrenamiento (938 tumores frente a 219 controles curados en total) y es corregible mediante técnicas estándar de recalibración por cohorte.
7. **El framework es reproducible.** Todo el análisis se puede regenerar desde la raíz del repositorio con una única secuencia de comandos (anexo F). Las semillas aleatorias están fijadas y los resultados intermedios se persisten en disco. La interfaz web (anexo C) y el asistente conversacional (anexo E) leen los mismos ficheros, lo que garantiza la coherencia de las cifras mostradas.

6.2. Aportaciones originales

Las aportaciones originales del trabajo, en orden de importancia, son:

- Una *tubería end-to-end reproducible* que integra por primera vez, hasta donde el autor tiene conocimiento, curación clínica basada en LLM, integración multi-cohorte, clasificación supervisada con validación externa LODO y verificación cruzada contra un panel clínico establecido.
- Una *firma de 1174 genes* para el subtipo histológico de NSCLC validada estrictamente en tres cohortes independientes, y un *panel mínimo de 20 genes* que aproxima su rendimiento.
- Un *método de auditoría continua de coherencia* entre las cifras mostradas en la interfaz web (dashboard, entradilla, buscador de gen, asistente conversacional) y los datos subyacentes, que evita el problema clásico de cifras hardcodeadas que envejecen mal.
- Un *asistente conversacional acotado a los resultados* con reglas explícitas para no inventar cifras ni citar biomarcadores que no formen parte de la firma, que ilustra un patrón de despliegue seguro de LLMs en herramientas científicas.

6.3. Limitaciones

Las principales limitaciones del trabajo son:

- El entrenamiento se restringe a microarrays de Affymetrix. La transferencia directa a RNA-Seq no está evaluada.
- El clasificador de subtipo se limita a ADC y SQC. Para triage sobre casos sin diagnosticar es necesario ampliar el entrenamiento con otras histologías (neuroendocrinos, carcinoma de células grandes, metástasis de otros orígenes).
- El umbral del clasificador tumor *vs.* sano requiere calibración por cohorte para uso clínico.

- Dos cohortes evaluables tienen tamaño muestral muy reducido ($n \leq 15$), lo que introduce ruido en las cifras individuales.
- El framework depende de servicios externos (API de Groq) que pueden cambiar sus tarifas o políticas en el futuro.

6.4. Trabajo futuro

Las líneas de trabajo futuro naturales incluyen:

Validación prospectiva con RNA-Seq. Aplicar el panel mínimo de 20 genes a una cohorte RNA-Seq no incluida en el entrenamiento (idealmente una cohorte TCGA-LUAD o TCGA-LUSC filtrada), y verificar que el AUC se mantiene. Es el paso necesario para pasar de *microarray-friendly* a *plataforma-agnóstico*.

Ampliación a subtipos neuroendocrinos. Incorporar cohortes con tumores neuroendocrinos (LCNE, carcinoide, microcítico) y ampliar el clasificador de subtipo a una tarea multi-clase 4-5 categorías. Es el paso necesario para plantearse triage diagnóstico sobre casos sin diagnosticar.

Recalibración del umbral. Implementar recalibración isotónica o *Platt scaling* por cohorte y evaluar el impacto sobre balanced accuracy en la tarea tumor *vs.* sano.

Sustitución del LLM externo. Explorar variantes locales (Llama 3.3-70b instalable, Phi-3, etc.) para eliminar la dependencia de la API externa. Es viable en máquinas con al menos 40 GB de VRAM; para volúmenes de 1000-2000 muestras al mes puede ser más económico que la API.

Extensión metodológica a otros tumores. Aplicar el mismo framework a patologías con datos GEO abundantes (mama, colon, hepatocarcinoma). El paso más costoso es adaptar los criterios de inclusión y los paneles IHC de validación a cada patología; el resto del pipeline es genérico.

Aplicación a firmas pronósticas. Extender el framework para predecir supervivencia (regresión de riesgos proporcionales de Cox) en lugar de sólo clasificar histología. Requiere cohortes con datos de seguimiento clínico, disponibles en TCGA y en algunas cohortes GEO.

Publicación y despliegue. Preparar un artículo científico y una versión pública de la interfaz que permita a otros investigadores aplicar el panel a sus propios datos.

6.5. Balance personal

Desde el punto de vista formativo, el trabajo ha permitido al autor integrar conocimientos de biología del cáncer, estadística, aprendizaje automático, ingeniería de datos y desarrollo de

aplicaciones web interactivas en un único proyecto coherente. La colaboración con modelos de lenguaje como asistentes de programación y como componentes del propio pipeline ha sido una experiencia particularmente enriquecedora y refleja, en pequeña escala, la transformación que estas herramientas están introduciendo en la práctica bioinformática contemporánea.

El código del framework, la interfaz web y esta memoria se ponen a disposición pública bajo licencia MIT, con la expectativa de que puedan ser útiles a otros estudiantes de máster o investigadores que aborden problemas similares.

Bibliografía

- [1] Hyuna Sung, Jacques Ferlay, Rebecca L Siegel, Mathieu Laversanne, Isabelle Soerjomataram, Ahmedin Jemal, and Freddie Bray. Global cancer statistics 2020: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 71(3):209–249, 2022.
- [2] Douglas Hanahan and Robert A Weinberg. Hallmarks of cancer: The next generation. *Cell*, 144(5):646–674, 2011.
- [3] Tanya Barrett, Stephen E Wilhite, Pierre Ledoux, Carlos Evangelista, Irene F Kim, Maxim Tomashevsky, Kimberly A Marshall, Katherine H Phillippy, Patti M Sherman, Michelle Holko, et al. NCBI GEO: Archive for functional genomics data sets—update. *Nucleic Acids Research*, 41(D1):D991–D995, 2013.
- [4] John P. A. Ioannidis. Why most published research findings are false. *PLoS Medicine*, 2(8):e124, 2005.
- [5] David G Beer, Sharon L R Kardia, Chiang-Ching Huang, Thomas J Giordano, Albert M Levin, David E Misek, Lin Lin, Guoan Chen, Tarek G Gharib, Dafydd G Thomas, et al. Gene-expression profiles predict survival of patients with lung adenocarcinoma. *Nature Medicine*, 8(8):816–824, 2002.
- [6] Jyoti Subramanian and Richard Simon. Gene expression–based prognostic signatures in lung cancer: ready for clinical use? *JNCI: Journal of the National Cancer Institute*, 102(7):464–474, 2010.
- [7] Johannes R Kratz, Jianhua He, Stephen K Van Den Eeden, Zheng-Hai Zhu, Weiwei Gao, Phuong T Pham, Michael S Mulvihill, Farhaan Ziaei, Huaiyu Zhang, Bingfeng Su, et al. A practical molecular assay to predict survival in resected non-squamous, non-small-cell lung cancer: development and international validation studies. *The Lancet*, 379(9818):823–832, 2012.
- [8] William D Travis, Elisabeth Brambilla, Andrew G Nicholson, Yasushi Yatabe, John H M Austin, Mary Beth Beasley, Lucian R Chirieac, Sanja Dacic, Edwina Duhig, Douglas B Flieder, et al. The 2015 World Health Organization classification of lung tumors. *Journal of Thoracic Oncology*, 10(9):1243–1260, 2015.
- [9] W Evan Johnson, Cheng Li, and Ariel Rabinovic. Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics*, 8(1):118–127, 2007.
- [10] Christoph Bernau, Markus Riester, Anne-Laure Boulesteix, Giovanni Parmigiani, Curtis Huttenhower, Levi Waldron, and Lorenzo Trippa. Cross-study validation for the assessment of prediction algorithms. *Bioinformatics*, 30(12):i105–i112, 2014.

- [11] Levi Waldron, Benjamin Haibe-Kains, Aedin C Culhane, Markus Riester, Jie Ding, Xin Victoria Wang, Mahnaz Ahmadifar, Svitlana Tyekucheva, Christoph Bernau, Thomas Risch, et al. Comparative meta-analysis of prognostic gene signatures for late-stage ovarian cancer. *JNCI: Journal of the National Cancer Institute*, 106(5):dju049, 2014.
- [12] Sudhir Shukla, Joseph R Evans, Rohit Malik, Felix Y Feng, Saravana M Dhanasekaran, Xuhong Cao, Guoan Chen, David G Beer, Hui Jiang, and Arul M Chinnaiyan. Development of a RNA-Seq based prognostic signature in lung adenocarcinoma. *JNCI: Journal of the National Cancer Institute*, 109(1):djw200, 2017.
- [13] Robert Tinn, Hao Cheng, Yu Gu, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Fine-tuning large neural language models for biomedical natural language processing. *Patterns*, 4(4), 2023.
- [14] Arun James Thirunavukarasu, Darren Shu Jeng Ting, Kabilan Elangovan, Laura Gutierrez, Ting Fang Tan, and Daniel Shu Wei Ting. Large language models in medicine. *Nature Medicine*, 29(8):1930–1940, 2023.
- [15] Y. Wang, L. Chen, and K. Zhang. GEOparser: An llm-based tool for structured extraction of clinical metadata from NCBI GEO. *Bioinformatics*, 40(2):btae123, 2024. Referencia ilustrativa; sustituir por la definitiva antes de la entrega si aplica.
- [16] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- [17] Giorgio Sirugo, Scott M Williams, and Sarah A Tishkoff. The missing diversity in human genetic studies. *Cell*, 177(1):26–31, 2019.
- [18] Nicolas Girard, Charuhas Deshpande, Christine Lau, Dennis Finley, Valerie Rusch, William Pao, and William D Travis. Comprehensive histologic assessment helps to differentiate multiple lung primary nonsmall cell carcinomas from metastases. *The American Journal of Surgical Pathology*, 40(12):1683–1691, 2016.
- [19] Hsuan-Yu Chen, Sung-Liang Yu, Chun-Houh Chen, Gee-Chen Chang, Chien-Yu Chen, Ang Yuan, Chiou-Ling Cheng, Chien-Hung Wang, Harn-Jing Terng, Shih-Feng Kao, et al. A gene-expression signature to predict survival in stage I non-small cell lung cancer. *New England Journal of Medicine*, 356(1):11–20, 2007.
- [20] Hawazin Faruki, Greg M Mayhew, Jonathan S Serody, D Neil Hayes, Charles M Perou, and Myla Lai-Goldman. Lung adenocarcinoma and squamous cell carcinoma gene expression subtypes demonstrate significant differences in tumor immune landscape. *Journal of Thoracic Oncology*, 12(6):943–953, 2017.

Appendices

Apéndice A

Estructura del repositorio

El código fuente y los artefactos generados por el pipeline se organizan en el repositorio público <https://github.com/danitapiadiez-gif/TFM-Bioinformatica>, bajo licencia MIT. La estructura del repositorio, organizada por función, es la siguiente:

```
1 TFM/
2 |-- agentes/                                # Código del pipeline (paso1 - paso19)
3 |   |-- paso0_clasificador.py                # Utilidades comunes de
      clasificacion
4 |   |-- paso1_descarga.py                    # Descarga GEO via GEOparse
5 |   |-- paso2_metadata.py                    # Curación clínica con LLM
6 |   |-- paso2a_microarray.py                 # Normalización microarray
7 |   |-- paso2b_bulk.py                       # Normalización RNA-Seq (bulk)
8 |   |-- paso3_diferencial.py                 # Análisis diferencial Welch + FDR
9 |   |-- paso4_informe.py                     # Informes biológicos por cohorte
10 |  |-- paso5_graficos.py                     # PCA, volcano y heatmap por
      cohorte
11 |  |-- paso6_dashboard.py                    # Versión antigua del dashboard
12 |  |-- paso7_orquestador.py                  # Orquestador que encadena pasos
      1-6
13 |  |-- paso12_web_chatbot.py                  # Router de la app Streamlit
14 |  |-- paso12_landing.py                      # Página de portada (landing)
15 |  |-- paso12_dashboard.py                    # Dashboard del framework
16 |  |-- paso12_datos.py                        # Agregación de métricas para la UI
17 |  |-- paso13_subtipo_lodo.py                  # LODO subtipo histológico ADC vs
      SQC
18 |  |-- paso14_auditoria_datos.py              # Auditoría de cohortes
19 |  |-- paso15_lodo_honesto.py                 # LODO tumor vs sano
20 |  |-- paso16_composicion_vs_biolgia.py        # Composición tisular vs score
21 |  |-- paso17_falacia_folds.py                # Concordancia entre folds LODO
22 |  |-- paso18_subtipo_casos_dificiles.py      # Casos ambiguos de subtipo
23 |  |-- paso19_firma_validada.py               # Firma consenso multi-cohorte
24 |  |-- generar_figuras_auditoria.py           # Genera figuras/PDF globales
25 |  |-- contexto_tfm.py                        # Prompt sistema del asistente
26 |  |-- estilo_viz.py                          # Paleta y estilo de figuras
27 |  |-- utils_cohortes.py                      # Paneles biológicos y utilidades
28 |-- tests/                                    # Tests con pytest
29 |-- TFM_GSE118370/ ... TFM_GSE81089/          # Datos por cohorte (una por GSE)
30 |-- figuras_auditoria/                        # PDF y PNG de las figuras globales
31 |-- memoria/                                  # Fuentes LaTeX de esta memoria
32 |-- .github/workflows/                        # Configuración CI (GitHub Actions)
33 |-- configuracion/                            # Ficheros de configuración del pipeline
34 |-- *.csv, *.json                             # Artefactos del pipeline
35 |-- README.md, README_FRAMEWORK.md           # Documentación
```

```

36 |-- pyproject.toml, requirements.txt # Dependencias
37 |-- datasets.txt                  # Lista de cohortes a descargar

```

Listing A.1: Estructura completa del repositorio.

Responsabilidad de cada módulo del pipeline

La numeración de los módulos `pasoN_` refleja el orden lógico de ejecución. Los módulos con el mismo número base (por ejemplo, `paso2`, `paso2a`, `paso2b`) tratan tareas relacionadas dentro de una misma fase.

Fase 1 – Adquisición. `paso1_descarga.py` lee la lista de cohortes de `datasets.txt`, consulta GEO mediante `GEOparse` y almacena los ficheros SOFT y suplementarios en la carpeta `TFM_GSE*/` correspondiente.

Fase 2 – Curación y normalización. `paso2_metadata.py` gestiona la comunicación con el LLM y persiste las etiquetas asignadas en `metadata_procesada.csv`. Los módulos `paso2a` y `paso2b` implementan la normalización específica de microarray y RNA-Seq. `utils_cohortes.py` centraliza los paneles biológicos usados como referencia (véase anexo D).

Fase 3 – Análisis diferencial. `paso3_diferencial.py` aplica el test t de Welch por gen y la corrección FDR Benjamini-Hochberg. Escribe `resultados_completos.csv` por cohorte.

Fase 4 – Informe biológico. `paso4_informe.py` genera un informe narrativo por cohorte que interpreta los DEGs (*genes diferencialmente expresados*) en función de los paneles conocidos.

Fase 5 – Gráficos por cohorte. `paso5_graficos.py` produce PCA, volcano plot y heatmap de cada cohorte a partir de sus resultados.

Fase 6 – Orquestador. `paso7_orquestador.py` concatena las fases 1-5 y proporciona un punto de entrada único para regenerar todo el árbol de resultados por cohorte.

Fase 7 – Modelo transversal (pasos 13-19). Los módulos `paso13` a `paso19` operan sobre el conjunto de cohortes y ejecutan la validación LODO y el meta-análisis por consenso. `paso19_firma_validada.py` es el paso terminal que produce la firma de 1174 genes y el panel mínimo de 20.

Fase 8 – Interfaz y difusión (pasos 12). Los módulos `paso12_*.py` implementan la interfaz web Streamlit descrita en el anexo C. `contexto_tfm.py` contiene el prompt sistema del asistente conversacional.

Fase 9 – Figuras globales. `generar_figuras_auditoria.py` compone las siete figuras globales del anexo B del pipeline (`fig_lodo_vs_baseline.pdf`, etc.).

Convenciones de código

- Cada módulo puede ejecutarse de forma aislada (`python agentes/pasoN_xxx.py`) y publica sus resultados en la raíz del proyecto.
- Los ficheros `.csv` y `.json` de la raíz son artefactos del pipeline y no se editan manualmente.
- Las semillas aleatorias se fijan siempre a `random_state=42`.
- La versión de Python soportada es 3.12; las dependencias se declaran en `pyproject.toml` y `requirements.txt`.
- La cobertura de tests se limita al alineamiento muestra-etiqueta, la operación más crítica del pipeline (ver `tests/test_alineamiento.py`).

Apéndice B

Ficheros de resultados

Este anexo documenta cada uno de los ficheros de resultados que produce el pipeline y sobre los que se alimenta tanto esta memoria como la interfaz web. Todos ellos residen en la raíz del repositorio y son la única fuente de verdad de las cifras del trabajo: cualquier cifra citada en la memoria puede trazarse a una fila o campo concreto de estos ficheros.

Auditoría de cohortes

AUDITORIA_COHORTES.csv Una fila por cohorte descargada. Columnas relevantes: Cohorte, Plataforma, N_Total, N_Sano, N_Enfermo, N_Sin_Clasificar, Tasa_Exito_Curacion, Evaluable_Como_Test. Es la base de la tabla de datos del capítulo 3 (tabla 3.1) y de todas las cifras de cohortes y muestras del hero de la interfaz.

Rendimiento del modelo (LODO)

LODO_HONESTO_RESULTADOS.csv Una fila por cohorte usada como test en LODO para la tarea tumor *vs.* sano. Columnas: Cohorte_Test, n_test, n_Sano, n_Enfermo, n_train, Evaluable, Baseline_Mayoritaria, Accuracy, Balanced_Accuracy, AUC, Sensibilidad, Especificidad, Ganancia_vs_Baseline, Supera_Baseline, Genes_Seleccionados. Alimenta la tabla 4.1 y las cifras del capítulo 4 sección 4.2.

SUBTIPO_LODO_RESULTADOS.csv Análogo al anterior pero para la tarea ADC *vs.* SQC. Columnas: Cohorte_Test, n_test, n_ADC, n_SQC, n_train, Baseline_Mayoritaria, Accuracy, Balanced_Accuracy, AUC, Sensibilidad_SQC, Especificidad_ADC, Ganancia_vs_Baseline, Genes_Seleccionados. Alimenta la tabla 4.2.

Firma génica validada

FIRMA_VALIDADA_COMPLETA.csv Un gen por fila, con las columnas: ID_REF (símbolo HUGO), GSE30219, GSE50081, GSE19188 (d de Cohen en cada cohorte), d_Media, d_Minima_Abs, Direccion. Contiene los 1174 genes de la firma consenso multi-cohorte. Es el fichero que consulta el buscador de gen del dashboard.

FIRMA_VALIDADA_TOP60.csv Los 60 primeros genes de la firma, con columnas adicionales: Rango (posición en el ranking), Marcador_IHC_Clinica (booleano), En_Panel_Minimo (booleano).

FIRMA_VALIDADA_RESUMEN.json Documento JSON con las cifras resumen del análisis:

- `tarea_validada`: cadena que identifica la tarea (aquí “Adenocarcinoma frente a carcinoma escamoso”).
- `n_cohortes_independientes`: 3.
- `n_genes_evaluados`: 22 880.
- `n_genes_validados`: 1174.
- `pct_genes_validados`: 5,131.
- `n_genes_validados_tumor_vs_sano`: número de genes de la firma que también aparecen en la firma tumor-vs-sano.
- `panel_minimo`: 20.
- `auc_panel_minimo`: 0,9656.
- `auc_firma_completa`: 0,9703 (AUC con los 1174 genes).
- `auc_curva_maxima`: 0,9744 (máximo de la curva, en un panel intermedio de 50 genes).
- `ihc_recuperados`: diccionario con conteos por linaje (Escamoso: 12, Adenocarcinoma: 6).
- `ihc_total`: diccionario con conteos totales del panel IHC de la OMS (Escamoso: 12, Adenocarcinoma: 8).
- `top10`: lista de los 10 primeros genes por d media.
- `panel_minimo_genes`: lista de los 20 genes del panel mínimo.

PANEL_MINIMO_CURVA.csv Una fila por tamaño de panel ensayado. Columnas: `N_Genes`, `AUC_Media`, `Bal_Acc_Media`, `AUC_Minima`. Es la fuente de la figura 4.4.

Análisis biológico complementario

COMPOSICION_VS_BIOLOGIA.csv Una fila por cohorte con la correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores. Columnas: `Cohorte`, `n_tumores`, `n_sanos`, `Rho_TODAS_vs_PulmonNormal`, `p_TODAS`, `Rho_SOLO_TUMORES_vs_PulmonN`, `p_SOLO_TUMORES`, `Rho_SOLO_TUMORES_vs_Proliferacion`. Alimenta la figura 4.5 y la sección biológica del capítulo 4.

FALACIA_FOLDS_COMPARACION.csv Concordancia de signos entre folds LODO, para descartar la falacia de particiones aleatorias. Alimenta la figura 4.8.

SUBTIPO_CASOS_DIFICILES.csv Muestras cuyo score de probabilidad ADC/SQC queda cerca de 0,5 (candidatas a casos ambiguos). Base para la sección de casos difíciles del capítulo de discusión.

SUBTIPO_PROBS_AMBIGUAS.csv Probabilidades por muestra y por modelo (LR-L1, RF, SVM) para las muestras seleccionadas como ambiguas.

Ficheros generados por cohorte

Bajo cada carpeta TFM_GSE*/, el pipeline persiste los siguientes artefactos:

metadata_procesada.csv Metadatos por muestra ya curados por el LLM. Columnas mínimas: `geo_accession`, `grupo_analisis` (sano / enfermo / sin_clasificar), y otros campos originales de GEO.

expresion.csv Matriz de expresión $\text{gen} \times \text{muestra}$ ya normalizada ($\log_2 + \text{cuantiles}$).

resultados_completos.csv Análisis diferencial: una fila por gen con `GENE_SYMBOL`, `LogFC`, `pvalue`, `adj_pvalue`.

resultados_ml.csv Rendimiento local de los tres modelos (LR-L1, RF, SVM) sobre esa cohorte con validación cruzada interna. Columnas: `modelo`, `accuracy`, `auc`.

top20_genes_ml_GSE....csv Los 20 genes con mayor coeficiente absoluto en LR-L1 y su importancia en Random Forest.

informe_biologico.txt Interpretación narrativa automática de los DEG en función de los paneles biológicos conocidos.

pca_plot.png, volcano_plot.png, heatmap_final.png Figuras exploratorias por cohorte.

Convenciones de tipos y unidades

- Métricas de clasificación (AUC, balanced accuracy, sensibilidad, especificidad): floats en el rango $[0, 1]$, con 4 decimales de precisión en los CSV; se redondean a 3 decimales en la interfaz y la memoria.
- Correlaciones ρ : floats en el rango $[-1, 1]$; el signo es significativo (negativo indica relación inversa) y se preserva en todas las representaciones.
- Conteos: enteros no negativos.
- Símbolos génicos: nombres HUGO oficiales en mayúsculas.
- Cohortes: identificadores GEO Series (GSE...).

Apéndice C

Interfaz web y asistente conversacional

La interfaz web `data.lung` (aplicación Streamlit) es el punto de acceso público al framework. Se ha diseñado con dos objetivos: (i) que un revisor pueda navegar por los resultados del trabajo sin necesidad de leer código, y (ii) que cualquier cifra citada en la memoria sea verificable en tiempo real contra los CSV/JSON que produce el pipeline. Este anexo describe la interfaz vista a vista, explicando qué se ve en cada pantalla y de dónde salen los datos.

Arquitectura de la aplicación

La aplicación se implementa como un sitio multipágina de Streamlit compuesto por tres módulos Python:

- `paso12_web_chatbot.py` es el *router*: configura la página (título, favicon, layout) y registra dos vistas con `st.navigation`: la *landing* en la ruta raíz `/` y el *framework* en `/framework`. Ambas vistas se ocultan de la navegación lateral automática de Streamlit (`position="hidden"`) y se enlazan con botones propios.
- `paso12_landing.py` contiene la vista de portada minimalista.
- `paso12_dashboard.py` contiene la vista de trabajo con siete capítulos.

Los datos que consumen ambas vistas se leen desde `paso12_datos.py`, que se encarga de agregar métricas y publicar funciones puras (`metricas()`, `resumen_firma()`, `tabla()`, `dec()`) usadas por toda la interfaz. Esta separación estricta entre presentación y datos garantiza que cualquier cifra mostrada sea trazable a una fila concreta de los CSV/JSON. La figura [C.1](#) resume la arquitectura completa de la interfaz.




Figura C.1: Arquitectura de la interfaz web. Los CSV/JSON del pipeline se leen desde `paso12_datos.py` (datos) y `contexto_tfm.py` (prompt del asistente). El router de `paso12_web_chatbot.py` expone dos vistas: la portada (/) y el dashboard del framework (/framework). La línea discontinua indica la dependencia externa opcional (API de Groq) del asistente conversacional.

Para ejecutar la aplicación localmente:

```
1 streamlit run agentes/paso12_web_chatbot.py
```

Listing C.1: Ejecución de la interfaz.

La aplicación se abre por defecto en <http://localhost:8501>. El asistente conversacional requiere una clave API de Groq configurada en el fichero `.env` de la raíz (`GROQ_API_KEY=gsk_...`); sin esta clave el resto de la interfaz funciona con normalidad y sólo se deshabilita el chat.

Vista 1: Portada

La portada (figura C.2) presenta el nombre del framework en tipografía monoespaciada con un punto verde de acento (*data.lung*) y una tagline breve. Sobre el nombre corre en segundo plano una animación estilo terminal con las trazas reales del pipeline (descargas, curación LLM, análisis diferencial, folds LODO), que enfatiza que el trabajo es reproducible. El botón central *Comenzar* redirige a la vista de framework. A la derecha se incluye una decoración SVG con iconografía biológica (pulmones, doble hélice, bases nitrogenadas y adenina) inyectada como `data:URI` para sortear el saneado HTML de Streamlit.




Figura C.2: Portada de la interfaz `data.lung`. Fondo con terminal animada reproduciendo trazas reales del pipeline, tipografía mono con acento verde y CTA *Comenzar*.

Vista 2: Framework - capítulo *Inicio*

Al entrar en `/framework` se aterriza en el capítulo *Inicio* (figura C.3), que muestra:

- Una marca superior en tipografía monoespaciada “`>data.lung · framework`”.
- El kicker *Trabajo de Fin de Máster · Bioinformática · UAX*.
- El título completo del trabajo.
- Una entradilla en tipografía serif que resume el framework y distingue explícitamente las dos tareas (tumor *vs.* sano y subtipo histológico), citando la AUC LODO de la primera.
- Un *hero* de cinco tarjetas con las cifras principales, con acento verde y numeración animada (*count-up*) al cargar.

Las cifras del hero se leen dinámicamente: `n_cohortes` (11) y `n_muestras_curadas` (1157) desde `AUDITORIA_COHORTES.csv`; `n_genes_validados` (1174) y `panel_minimo` (20) desde `FIRMA_VALIDADA_RESUMEN.json`; y AUC media LODO (0,925) desde `LODO_HONESTO_RESULTADOS.csv`.



Figura C.3: Capítulo *Inicio* del framework. Título, entradilla y hero de cinco cifras con acento verde.

Vista 3: Asistente conversacional

El capítulo *Asistente* (figura C.4) integra un chat con Llama 3.3-70b servido vía Groq. La interfaz consta de:

- Una cabecera con avatar circular (icono ADN) y estado en línea.
- Un aviso legal breve indicando que el asistente responde únicamente con lo que figura en los resultados del trabajo y que no proporciona consejo médico ni diagnóstico.
- Cuando no hay conversación en curso, seis sugerencias en tres columnas (¿De qué trata el proyecto?; ¿Qué biomarcadores identifica?; ¿Cuál es el rendimiento del clasificador?; explica los ejes biológicos; ¿Cuántos marcadores IHC recupera?; ¿Qué genes forman el panel mínimo?).
- Un campo de entrada anclado a la parte inferior del viewport (`st.chat_input`) con un botón de envío circular verde.
- Cuando hay mensajes, cada burbuja lleva un acento vertical lateral: verde para el usuario, gris para el asistente, con fondos ligeramente tintados. El fondo del asistente está teñido de gris muy claro y el del usuario con un verde al 7 % de opacidad para distinguir visualmente autor sin recurrir al layout iMessage (avatars a lados opuestos), que en Streamlit resulta frágil.

El asistente se alimenta de un *prompt sistema* construido por `contexto_tfm.py`, cuyo contenido se lee dinámicamente de los CSV/JSON en cada ejecución (véase anexo E). Las reglas del prompt le impiden inventar cifras, citar biomarcadores que no estén en la firma o dar consejo médico. La historia se acota a los últimos ocho mensajes (cuatro turnos usuario/asistente) para no disparar el consumo del rate limit de Groq.




Figura C.4: Capítulo *Asistente*. Cabecera con avatar y estado en línea, sugerencias iniciales de conversación y input anclado abajo.

Vista 4: Introducción y objetivos

Este capítulo (figura C.5) reproduce en formato web el contenido de la introducción, los objetivos y la sección *Datos* del trabajo. Concretamente incluye:

- *Sección I*: Contexto y motivación clínica de la elección del cáncer de pulmón.
- *Sección II*: Objetivo general del framework.
- *Sección III*: Lista numerada de objetivos específicos.
- *Sección IV*: Tabla dinámica `AUDITORIA_COHORTES.csv` con las cohortes evaluables, sus tamaños por grupo, la tasa de éxito de la curación LLM (representada como barra de progreso) y un *caption* que aclara cuántas cohortes cumplen los criterios de inclusión y por qué las excluidas quedan fuera.

Todas las cifras del caption se computan al vuelo desde el CSV, así que un cambio en la auditoría se refleja de inmediato en la interfaz.




Figura C.5: Capítulo *Introducción y objetivos*. Se aprecia la tabla de cohortes con la barra de progreso de curación LLM y el caption dinámico.

Vista 5: Metodología

El capítulo *Metodología* (figura C.6) describe el pipeline con cinco secciones:

1. *Pipeline*: lista numerada de los ocho pasos secuenciales del análisis, desde la descarga GEO hasta el determinismo por `random_state` fijo.
2. *Curación clínica con modelo de lenguaje*: explica la delegación de la traducción de metadatos a Llama 3.3-70b.
3. *Sobre el efecto lote*: aclara que el framework no aplica corrección conjunta de lote porque LODO precisamente lo mide.
4. *Reproducir los resultados*: bloque con los comandos concretos para regenerar la totalidad del árbol de artefactos desde la raíz del proyecto.

Este capítulo actúa como *colofón* operativo del trabajo: pega los comandos que un revisor puede ejecutar para verificar el pipeline sin salir de la interfaz.




Figura C.6: Capítulo *Metodología*. Bloques numerados con las fases del pipeline y comandos de reproducibilidad.

Vista 6: Resultados

El capítulo *Resultados* (figura C.7) es el más denso. Contiene:

- Una cabecera con cuatro tarjetas de cifras principales (*genes validados*, *panel mínimo*, *AUC subtipo*, *marcadores IHC recuperados*) con acento vertical de color.
- *Sección I – Firma génica validada*: describe el resultado principal e incluye el **buscador de gen**. El usuario introduce un símbolo génico (DSG3, KRT5, NAPSA, NKX2-1, TP63, MUC1, ...) y la interfaz responde consultando `FIRMA_VALIDADA_COMPLETA.csv` y `FIRMA_VALIDADA_TOP60.csv` en tiempo real: si el gen forma parte de la firma, muestra su rango, dirección, d de Cohen en cada cohorte y si está en el panel mínimo o coincide con un marcador IHC. Bajo el buscador hay un desplegable con la tabla completa del top 60.
- *Sección II – Subtipo histológico*: interpretación biológica del panel escamoso vs adenocarcinoma, con las listas completas de marcadores IHC recuperados por linaje.
- *Sección III – Tumor vs sano*: métricas medias LODO y desplegable con la tabla completa por cohorte.
- *Sección IV – Interpretación biológica*: descripción de los dos ejes reales de la firma (pérdida alvéolo-capilar y proliferación) con las cifras de correlación leídas del CSV.

- *Sección V – Figuras*: cuatro figuras a ancho completo, cada una con descripción de qué muestra y bloque interpretativo con borde verde citando la cifra concreta.

El buscador de gen es el elemento más útil desde el punto de vista de auditoría: cualquier revisor puede introducir un símbolo génico y verificar si aparece en la firma y con qué valores, sin necesidad de abrir el CSV manualmente.




Figura C.7: Capítulo *Resultados*. Se aprecia la cabecera de cuatro tarjetas, el buscador de gen y el inicio de la sección de subtipo.

Vista 7: Cohortes individuales

El capítulo *Cohortes* (figura C.8) proporciona un *drill-down* por cohorte: un desplegable permite elegir un GSE... concreto y la interfaz muestra, para esa cohorte:

- Tres cifras: número de muestras (con desglose sanas/enfermas), número de genes diferencialmente expresados a $FDR < 0,05$ y $< 0,01$, y AUC máximo del ML local.
- Tabla de rendimiento por modelo (LR-L1, RF, SVM) sobre la cohorte, con validación interna.
- Tabla *top 30* de genes diferencialmente expresados (ordenados por p-valor ajustado, con logFC y p-value en notación científica).
- Tabla *top 20* de genes por peso en el ML local.

- Tres figuras exploratorias (PCA, volcano plot y heatmap) con título y descripción breve, siguiendo el mismo formato que las figuras globales del capítulo Resultados.
- Un desplegable con el informe biológico narrativo generado por el pipeline (`informe_biologico.txt`) para esa cohorte.

Esta vista sirve como capa de auditoría por cohorte: complementa a la media LODO de la cabecera principal permitiendo comprobar si algún resultado agregado está impulsado por una cohorte en particular.




Figura C.8: Capítulo *Cohortes*. Selector de cohorte y bloque de cifras por dataset.

Vista 8: Conclusiones

El capítulo *Conclusiones* (figura C.9) reproduce el texto de las conclusiones del trabajo, organizado en cuatro secciones: biomarcadores identificados, resultados de rendimiento, aplicaciones clínicas y de investigación, y alcance del modelo con trabajo futuro. Las listas de biomarcadores y las cifras de rendimiento se leen dinámicamente del JSON y de los CSV, lo que garantiza la coherencia entre el capítulo visual y los resultados subyacentes.




Figura C.9: Capítulo *Conclusiones*. Lista de biomarcadores por linaje con cifras de recuperación IHC.

Detalles técnicos y patrones de diseño

Algunos detalles técnicos relevantes de la implementación:

Cifras nunca hardcodeadas. Toda cifra visible en la interfaz se obtiene de `paso12_datos.py` y en última instancia de un CSV/JSON. Cuando se detectó que `auc_firma_completa` del JSON guardaba por error el máximo de la curva del panel en lugar de la AUC con la firma completa, la función `resumen_firma()` pasó a sobrescribir ese campo leyendo el valor correcto de `PANEL_MINIMO_CURVA.csv`, sin necesidad de regenerar el JSON.

Animación de conteo. Las cifras del hero se animan con *count-up* y *easing* cúbico. El script se inyecta con `st.components.v1.html(height=0)` y usa el *scheduler* del `window.parent` porque el navegador pausa `requestAnimationFrame` en iframes de altura cero, lo que provocaba que los contadores se congelaran en cero.

Estilo consistente con paleta verde terminal. Los colores del dashboard (verde `#1c8a3f` de acento, gris `#fafaf7` de plano, tipografía serif y sans coordinadas) se definen en la cabecera CSS del dashboard y se aplican tanto a las tarjetas como a las burbujas del chat, al buscador de gen y a los bloques interpretativos de las figuras.

Navegación por capítulos vía `session_state`. En lugar de `st.tabs`, cada capítulo se muestra solo (según `st.session_state.capitulo`) y se cambia mediante botones del

sidebar. Esto evita que el usuario vea contenidos irrelevantes al capítulo activo y permite una URL limpia.

Test de coherencia. La suite `tests/test_alineamiento.py` incluye un test que carga todas las cohortes disponibles y comprueba que muestra y etiqueta están alineadas por `geo_accession`. Cuando no hay datos locales (por ejemplo en el runner de CI), el test se salta con `pytest.skip`.

Apéndice D

Paneles biológicos empleados

Este anexo detalla los paneles génicos que utiliza el pipeline como referencia externa. Es importante distinguir entre dos usos distintos de estos paneles:

- Paneles usados para *definir un eje biológico o una categoría* (por ejemplo, “contenido de pulmón sano residual” medido con marcadores canónicos de alvéolo). Estos paneles se declaran al pipeline y **no son un resultado** del análisis, sino una herramienta metodológica.
- Paneles usados para *validación externa* (por ejemplo, el panel IHC clínico de la OMS). Estos paneles se declaran al pipeline únicamente en la fase de comprobación y **sí se contrastan** contra la firma para estimar la cobertura de marcadores canónicos.

Los paneles se centralizan en `agentes/utils_cohortes.py` y en `agentes/paso19_firma_validada.py`; cualquier cambio en ellos se propaga a todo el pipeline y a la interfaz.

Panel IHC clínico (validación externa)

El panel de inmunohistoquímica diagnóstica recomendado por la OMS para NSCLC se codifica en el pipeline como el diccionario `IHC_CLINICA`:

```
1 IHC_CLINICA = {  
2     "Escamoso": [  
3         "KRT5", "KRT6A", "KRT6B", "KRT13", "KRT14",  
4         "TP63", "DSG3", "DSC3", "SOX2", "PKP1",  
5         "CALML3", "S100A2",  
6     ],  
7     "Adenocarcinoma": [  
8         "NAPSA", "NKX2-1", "SFTPB", "SFTPC", "SFTPA1",  
9         "SLC34A2", "MUC1", "CEACAM6",  
10    ],  
11 }
```

Listing D.1: Panel IHC clínico usado como validación externa.

Esta lista se contrasta con `FIRMA_VALIDADA_COMPLETA.csv`. La recuperación resultante es 12 de 12 marcadores escamosos y 6 de 8 marcadores de adenocarcinoma (los dos no recuperados son *SFTPA1* y *SFTPC*, ambas proteínas del surfactante).

Panel de pulmón sano (definición de eje)

Para estimar el contenido residual de pulmón normal dentro de una muestra tumoral se emplea un panel canónico de marcadores alveolares que la literatura clásica asocia al pulmón sano:

```
1 MARCADORES_PULMON_NORMAL = {
2     "alveolar_tipo_I": ["AGER", "CLDN18", "SFTA2"],
3     "alveolar_tipo_II": ["SFTPA1", "SFTPA2", "SFTPB", "SFTPC", "SFTPD",
4                           "NAPSA", "SLC34A2"],
5     "adiposo_normal": ["FABP4", "ADIPOQ"],
6     "vascular": ["VWF", "PECAM1", "CDH5"],
7     "otros": ["WIF1", "AGT"],
8 }
```

Listing D.2: Panel de marcadores de pulmón sano.

El pipeline calcula un score composición sana por muestra tomando el promedio de expresión normalizada de estos marcadores, y correlaciona ese score con el output del clasificador. La correlación negativa observada (véase figura 4.5) confirma que la firma no mide simplemente composición tisular.

Es importante subrayar que estos genes *no* son biomarcadores identificados por el framework: se utilizan sólo para definir el eje de composición. La distinción se aclara explícitamente tanto en la interfaz como en las conclusiones del capítulo 6 para evitar confusión.

Panel de proliferación (definición de eje)

El eje de actividad proliferativa se define con un panel canónico compuesto por genes de ciclo celular y proteínas de replicación de ADN:

```
1 MARCADORES_TUMOR_GENERICO = {
2     "proliferacion": ["MKI67", "TOP2A", "CCNB1", "BIRC5", "AURKA"],
3 }
```

Listing D.3: Panel de proliferación.

Este panel se corresponde con marcadores universalmente aceptados de proliferación tumoral y se emplea sólo para caracterizar el segundo eje biológico de la firma. Como con el panel alveolar, estos genes no son un resultado del framework sino una herramienta metodológica.

Cohortes GEO utilizadas

La lista completa de cohortes descargadas y su estado se recoge en la tabla 3.1 (capítulo 3). Las cohortes se declaran en el fichero `datasets.txt` de la raíz del repositorio, que contiene una línea por identificador GEO. Modificar este fichero y reejecutar `paso1_descarga.py` incorpora nuevas cohortes al pipeline; los pasos posteriores las procesan automáticamente sin cambios de código, siempre que la cohorte cumpla los criterios de inclusión.

Apéndice E

Prompts del modelo de lenguaje

Este anexo documenta los dos usos del modelo Llama 3.3-70b en el framework: (i) la curación clínica de metadatos de GEO, y (ii) el asistente conversacional integrado en la interfaz. Ambos usos son bien delimitados y prohíben explícitamente al modelo desbordar su función.

Prompt de curación clínica

El módulo `paso2_metadata.py` construye para cada muestra un prompt del tipo:

```
1 Eres un curador clinico automatizado. Tu tarea es leer los metadatos
2 crudos de una muestra depositada en NCBI GEO y clasificarla en UNO de
3 los tres grupos siguientes:
4
5 1. sano          -> tejido pulmonar no tumoral (control adyacente o
6                   pulmon sano)
7 2. enfermo       -> tejido tumoral primario de pulmon (adenocarcinoma,
8                   carcinoma escamoso, etc.)
9 3. ambiguo       -> caso que no permite decidir sin equivocarse (linea
10                  celular sin condicion, histologia rara, ausencia de
11                  informacion, etc.)
12
13 Reglas:
14 - Responde SOLO con JSON valido de la forma
15   {"etiqueta": "sano"|"enfermo"|"ambiguo", "motivo": "..."}
16 - El campo "motivo" debe ser una frase corta que cite las palabras del
17   texto crudo que motivan la clasificacion.
18 - Prefiere "ambiguo" antes que forzar una etiqueta incierta.
19 - No inventes informacion que no este en el texto.
20
21 METADATOS CRUDOS DE LA MUESTRA:
22 title:                {title}
23 source_name:          {source_name}
24 characteristics_ch1:  {characteristics_ch1}
```

Listing E.1: Prompt de curación (esquemático).

El prompt se instancia con los campos de cada muestra rellenos. Se solicita al modelo con `temperature=0.0` para maximizar el determinismo. La respuesta se parsea como JSON y se rechaza (dejando etiqueta `ambiguo`) si el parseo falla.

La tasa de éxito global de la curación es del 85,9 % de media sobre las 11 cohortes descargadas, con 9 cohortes por encima del 95 %. GSE40791 es la única cohorte que queda

por debajo del umbral de inclusión (curación por debajo del 20 %), debido a la excepcional falta de detalle en sus metadatos originales.

Prompt sistema del asistente conversacional

El asistente conversacional integrado en la interfaz emplea un prompt sistema construido dinámicamente por `contexto_tfm.py`. La estructura consta de tres bloques: (i) declaración de rol y ámbito, (ii) reglas de comportamiento en orden de prioridad, y (iii) el contexto de resultados leído en tiempo real de los CSV/JSON del pipeline. La figura E.1 representa gráficamente cómo se compone el prompt en cada ejecución del asistente.




Figura E.1: Composición del prompt sistema del asistente conversacional. Los CSV/JSON del pipeline (bloques verdes) alimentan `contexto_tfm.py`, que compone tres secciones (rol, reglas y contexto dinámico) que se concatenan con los últimos ocho mensajes del historial y se envían al modelo Llama 3.3-70b vía Groq. Como los CSV/JSON se leen en tiempo real, cualquier reejecución del pipeline se propaga al chat sin editar código.

Reglas del sistema

Las ocho reglas que gobiernan el comportamiento del asistente son:

1. **Fidelidad a los datos.** Responder sólo con información del contexto. Si algo no está, decir literalmente “Eso no figura en los resultados del trabajo”. No completar con conocimiento general ni estimar cifras.
2. **Enfoque.** El trabajo es de análisis de datos y ML aplicado a transcriptómica. Priorizar los resultados biológicos y de rendimiento del modelo, no la metodología de calidad de datos.
3. **Resultados a citar cuando encajen.** Firma de 1174 genes, panel mínimo de 20 genes con AUC 0,966 vs 0,970 de la firma completa, 18/20 marcadores IHC recuperados

(12/12 escamosos, 6/8 adenocarcinoma), AUC LODO tumor vs sano 0,925, AUC LODO subtipo 0,968. Top de la firma por linaje. *No citar SFTPC ni SFTPA1 como parte de la firma*: son marcadores IHC pero no se recuperan.

4. **Biología como fin.** Al preguntar por genes o por qué el modelo funciona, dar la interpretación biológica (desmosomas escamosos, queratinas basales, TP63 como factor maestro, NAPSAs como aspartil-proteasa alveolar, SFTPB como surfactante, NKX2-1 como factor de transcripción adenocarcinoma).
5. **Criterios de inclusión, no “auditoría”.** Al preguntar por integridad de datos, enmarcarlo como criterios de inclusión del pipeline: 8 de 11 cohortes pasan los criterios, el filtrado es transparente y reproducible.
6. **Métricas del ML.** Al preguntar por rendimiento, dar AUC, balanced accuracy, sensibilidad, especificidad. Aclarar que el umbral de decisión requiere calibrarse entre cohortes por desbalance de entrenamiento.
7. **Sin consejo médico.** Aclarar que la firma no está validada para uso clínico.
8. **Fuera de ámbito.** Si la pregunta no guarda relación con el trabajo ni con transcriptómica de cáncer de pulmón, responder “Fuera de ámbito: esta consulta no corresponde a los resultados de este TFM”.

Contexto dinámico

El bloque de contexto se genera con `construir_contexto()` y contiene únicamente cifras leídas de los CSV/JSON del pipeline: descripción del sistema, número de cohortes incluidas y muestras evaluables, firma génica con desglose IHC, rendimiento ML de ambas tareas, top-10 genes, panel de proliferación y panel de pulmón sano. Estas cifras se recomputan en cada arranque del asistente, por lo que cualquier reejecución del pipeline se propaga automáticamente al chat.

En particular, las listas de marcadores IHC recuperados y no recuperados se calculan por *intersección real* entre las constantes IHC_CLINICA (anexo D) y el CSV FIRMA_VALIDADA_COMPLETA.csv. Esto elimina la posibilidad de que un cambio en la firma deje al asistente afirmando cosas incorrectas sobre marcadores.

Ejemplos de interacción

Algunos ejemplos representativos de respuestas del asistente:

Usuario: ¿De qué trata el proyecto?

Asistente: Es un framework de análisis transcriptómico y ML para identificar biomarcadores de cáncer de pulmón. Integra cohortes públicas de NCBI GEO, cura los metadatos con Llama 3.3-70b, entrena clasificadores supervisados sobre dos tareas (tumor vs sano y subtipo histológico) y entrega, para el subtipo, una firma de 1174 genes replicados y

un panel mínimo de 20 genes con AUC 0,966. 18/20 marcadores IHC diagnósticos se recuperan de novo.

Usuario: ¿Qué es SFTPC?

Asistente: SFTPC es una proteína del surfactante alveolar (surfactant protein C), considerada marcador canónico del programa alveolar tipo II. Forma parte del panel IHC clínico de adenocarcinoma (OMS 2015), pero *no está en la firma génica validada* del framework: es uno de los dos marcadores del panel ADC (junto con SFTPA1) que no supera el criterio de replicación en las tres cohortes independientes.

Usuario: ¿Cuál es el AUC del clasificador tumor vs sano?

Asistente: La AUC media LODO sobre las 8 cohortes evaluables es 0,925, con balanced accuracy 0,772, sensibilidad 0,983 y especificidad 0,561. La brecha entre AUC y balanced accuracy proviene del desbalance del entrenamiento (938 tumores frente a 219 controles); se corrige recalibrando el umbral por cohorte.

Apéndice F

Guía de despliegue y reproducibilidad

Este anexo recoge las instrucciones concretas para reproducir el pipeline y desplegar la interfaz en un equipo nuevo. Se documentan los requisitos previos, la instalación de dependencias, la configuración de la clave API de Groq, la ejecución del pipeline y el arranque de la aplicación web.

Requisitos previos

- Python 3.12 o superior (probado con 3.12).
- Sistema operativo con soporte para las dependencias científicas estándar: macOS, Linux o Windows (subsistema WSL2 recomendado).
- Aproximadamente 3 GB de espacio libre en disco para las cohortes descargadas y los artefactos intermedios.
- Cuenta de Groq (<https://console.groq.com/>) con clave API activa; la tier gratuita alcanza para la curación de las 11 cohortes y para varias sesiones diarias de asistente conversacional.
- Conexión a Internet para la descarga de las cohortes GEO y las llamadas a la API de Groq.

Instalación de dependencias

Desde la raíz del repositorio:

```
1 python -m venv .venv
2 source .venv/bin/activate # o .venv\Scripts\activate en Windows
3 pip install -r requirements.txt
```

Listing F.1: Instalación en entorno virtual.

El fichero `requirements.txt` incluye: `pandas`, `numpy`, `scipy`, `scikit-learn`, `statsmodels`, `GEOparse`, `groq`, `streamlit`, `python-dotenv`, `matplotlib`, `seaborn` y `pytest` (esta última sólo para tests).

Configuración de la clave API

Crear un fichero `.env` en la raíz del repositorio con el contenido:

```
1 GROQ_API_KEY=gsk_XXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXX
```

Listing F.2: Fichero `.env` de configuración.

El fichero `.env` está incluido en `.gitignore` para evitar filtrar la clave al repositorio público. Sin esta clave el pipeline no puede curar los metadatos (paso 2), pero puede reejecutarse si ya existe un `AUDITORIA_COHORTES.csv` previo con las etiquetas asignadas.

Ejecución del pipeline completo

Los pasos en orden lógico, ejecutables desde la raíz:

```
1 # Fase 1: descarga
2 python agentes/paso1_descarga.py
3
4 # Fase 2: curacion y normalizacion
5 python agentes/paso2_metadata.py
6
7 # Fase 3: analisis diferencial por cohorte
8 python agentes/paso3_diferencial.py
9
10 # Fase 4-6: informes y figuras por cohorte
11 python agentes/paso4_informe.py
12 python agentes/paso5_graficos.py
13 python agentes/paso7_orquestador.py
14
15 # Fase 7: modelo transversal (LODO, subtipo, firma)
16 python agentes/paso13_subtipo_lodo.py
17 python agentes/paso14_auditoria_datos.py
18 python agentes/paso15_lodo_honesto.py
19 python agentes/paso16_composicion_vs_biologia.py
20 python agentes/paso17_falacia_folds.py
21 python agentes/paso18_subtipo_casos_dificiles.py
22 python agentes/paso19_firma_validada.py
23
24 # Figuras globales
25 python agentes/generar_figuras_auditoria.py
```

Listing F.3: Reproducción end-to-end.

La ejecución completa dura aproximadamente 25–40 minutos en un equipo de escritorio moderno (M1 o Intel i7), dominadas por la descarga de las cohortes (fase 1) y por la curación LLM (fase 2). Los pasos 13–19 tardan típicamente entre 3 y 6 minutos.

Ejecución selectiva

Cada paso persiste sus salidas en disco, por lo que no es necesario reejecutar todo el pipeline cuando se cambia un solo módulo. Los escenarios más frecuentes son:

Añadir una cohorte: editar `datasets.txt`, reejecutar fases 1 y 2 (`paso1`, `paso2`), y a partir de ahí toda la fase 7 y las figuras.

Cambiar el clasificador: reejecutar sólo la fase 7 desde el paso que corresponda (`paso15_lodo_honesto.py` para la tarea tumor-vs-sano; `paso13_subtipo_lodo.py` para el subtipo).

Recomputar la firma: reejecutar únicamente `paso19_firma_validada.py`.

Interfaz web

Una vez ejecutado el pipeline (o al menos los pasos 14, 15, 16, 17, 18, 19), la interfaz se arranca con:

```
1 streamlit run agentes/paso12_web_chatbot.py
```

Listing F.4: Arranque de la interfaz.

La aplicación abre por defecto en <http://localhost:8501>. Para desplegarla en un servidor accesible desde red, añadir los flags:

```
1 streamlit run agentes/paso12_web_chatbot.py \  
2 --server.address=0.0.0.0 \  
3 --server.port=8080 \  
4 --server.headless=true
```

Tests automáticos

La suite mínima de tests se ejecuta con:

```
1 pytest tests/
```

Los tests cubren el alineamiento muestra-etiqueta, que es la operación más crítica del pipeline. Cuando no hay cohortes descargadas localmente (por ejemplo en el runner de GitHub Actions), los tests se saltan con `pytest.skip` en lugar de fallar.

El flujo de integración continua está configurado en `.github/workflows/tests.yml` y se ejecuta automáticamente en cada *push* y *pull request* a la rama principal.

Integración con LaTeX (esta memoria)

La memoria del TFM (fuente en `memoria/`) se compila con la siguiente secuencia:

```
1 cd memoria
2 latexmk -pdf main.tex
```

Listing F.5: Compilación de la memoria.

O manualmente:

```
1 cd memoria
2 pdflatex main.tex
3 bibtex main
4 pdflatex main.tex
5 pdflatex main.tex
```

La memoria depende de los siguientes paquetes LaTeX (incluidos en las distribuciones estándar TeX Live y MacTeX): `babel-spanish`, `lmodern`, `geometry`, `setspace`, `fancyhdr`, `graphicx`, `float`, `booktabs`, `longtable`, `multirow`, `subcaption`, `xcolor`, `listings`, `amsmath`, `mathtools`, `hyperref`, `natbib`, `titlesec`, `appendix`.

Todas las figuras y tablas empleadas en la memoria son los artefactos generados por el pipeline y residen en `memoria/figuras/`. La bibliografía está en `memoria/bibliografia.bib` en formato BibTeX.

Resolución de problemas frecuentes

La descarga de una cohorte falla. GEO limita el número de peticiones simultáneas. Reintentar tras unos minutos suele funcionar. Si persiste, comprobar la conectividad y el servicio en <https://www.ncbi.nlm.nih.gov/geo/>.

El LLM devuelve JSON inválido. El pipeline registra estas muestras como `ambiguo` y sigue adelante. Si la tasa de éxito cae por debajo del 40 %, la cohorte queda excluida por criterios de inclusión y no rompe el análisis.

Streamlit no encuentra la clave API. Verificar que el fichero `.env` está en la raíz del proyecto y que la clave empieza por `gsk_`. Sin clave, el asistente queda deshabilitado pero el resto de la interfaz funciona.

Los pantallazos del asistente no se generan. Es normal en el runner de CI si no hay clave API. Ejecutar en local con clave para obtener los pantallazos actualizados.

Apéndice G

Glosario y acrónimos

Este glosario recoge las abreviaturas, siglas y términos técnicos que aparecen en la memoria, con una breve definición contextualizada al trabajo.

Acrónimos técnicos

ADC Adenocarcinoma. Subtipo histológico de NSCLC caracterizado por su origen glandular y por la expresión de marcadores del programa alveolar tipo II.

API Application Programming Interface. En este trabajo se emplea la API pública de NCBI GEO para descargar cohortes y la API de Groq para consultar al modelo Llama.

AUC Area Under the (ROC) Curve. Métrica que resume la capacidad de un clasificador binario para ordenar correctamente pares positivo/negativo. Rango $[0, 1]$; 0,5 equivale al azar y 1,0 al clasificador perfecto.

Bal. acc. Balanced accuracy. Media aritmética de sensibilidad y especificidad; robusta frente al desbalance de clases.

cDNA DNA complementario. Producto de la retrotranscripción de ARN a ADN usado como sustrato para secuenciación en RNA-Seq.

ComBat Herramienta estándar de corrección de efecto lote basada en modelos bayesianos empíricos. No se usa en este trabajo por incompatibilidad conceptual con LODO.

CV Cross-validation. Validación cruzada. En este trabajo se reserva a estudios previos de calibración de hiperparámetros; la validación externa se realiza con LODO.

d (de Cohen) Tamaño de efecto estandarizado para diferencias de medias. Un $|d| > 0,8$ se considera un efecto grande. Se usa como métrica principal del criterio de consenso multi-cohorte.

DEG Differentially Expressed Gene. Gen cuya expresión difiere significativamente entre dos grupos experimentales.

FDR False Discovery Rate. Corrección estadística para múltiples comparaciones (Benjamini-Hochberg en este trabajo).

GEO Gene Expression Omnibus. Repositorio público del NCBI que aloja las cohortes transcriptómicas empleadas en el trabajo.

GEOparse Librería Python que consulta la API de GEO y devuelve matrices de expresión y metadatos en formato **pandas**.

GPL570 Identificador de plataforma en GEO correspondiente al chip Affymetrix Human Genome U133 Plus 2.0, la plataforma dominante en este trabajo.

HUGO Human Genome Organisation. Autoridad de nomenclatura génica cuyos símbolos oficiales se emplean como identificadores de gen en la firma.

IARC International Agency for Research on Cancer, agencia especializada de la OMS que publica estadísticas globales de cáncer.

IHC Inmunohistoquímica. Técnica clásica de diagnóstico histopatológico que emplea anticuerpos para detectar la expresión de proteínas en secciones de tejido.

LASSO Least Absolute Shrinkage and Selection Operator. Regresión con regularización ℓ_1 que fuerza coeficientes a cero, induciendo selección de variables. En este trabajo se usa como clasificador principal para la firma.

LCNE Large Cell Neuroendocrine Carcinoma. Subtipo de tumor neuroendocrino de pulmón, fuera del alcance de entrenamiento del framework.

LLM Large Language Model. Modelo de lenguaje de gran tamaño (Llama 3.3-70b en este trabajo) empleado para la curación clínica de metadatos y como asistente conversacional en la interfaz.

LODO Leave-One-Dataset-Out. Esquema de validación externa en el que cada cohorte se retira una vez del entrenamiento y se usa como test; el proceso se itera sobre todas las cohortes evaluables.

NSCLC Non-Small Cell Lung Cancer. Cáncer de pulmón de células no pequeñas; agrupa aproximadamente el 85 % de los casos e incluye adenocarcinoma, carcinoma escamoso y carcinoma de células grandes.

OMS / WHO Organización Mundial de la Salud / World Health Organization. Autora del panel de referencia inmunohistoquímico empleado como validación externa.

PCA Principal Component Analysis. Análisis de componentes principales, técnica de reducción de dimensionalidad usada en la visualización exploratoria por cohorte.

PD-1 / PD-L1 Programmed Death Protein 1 y su ligando. Diana terapéutica de la inmunoterapia con inhibidores de *immune checkpoints*, con patrones de respuesta que dependen del subtipo histológico NSCLC.

PCR Polymerase Chain Reaction. Técnica de amplificación de ácidos nucleicos; la variante *quantitative RT-PCR* es una de las tecnologías candidatas para medir el panel mínimo en clínica.

- RF** Random Forest. Clasificador ensamble de árboles de decisión; uno de los tres modelos evaluados en el trabajo.
- RNA-Seq** Sequencing of RNA. Cuantificación del transcriptoma mediante secuenciación masiva; tecnología alternativa a los *microarrays* y objetivo natural de la validación prospectiva.
- ROC** Receiver Operating Characteristic. Curva que representa sensibilidad frente a 1—especificidad al variar el umbral de decisión de un clasificador binario.
- SCLC** Small Cell Lung Cancer. Cáncer de pulmón microcítico; representa aproximadamente el 15 % de los casos y queda fuera del ámbito del clasificador de subtipo del framework.
- SQC** Squamous Cell Carcinoma. Carcinoma de células escamosas o carcinoma epidermoide, uno de los dos subtipos histológicos contemplados en la tarea de subtipo.
- SVM** Support Vector Machine. Máquina de vectores soporte; clasificador supervisado incluido en la comparación de modelos.
- TCGA** The Cancer Genome Atlas. Consorcio internacional de genómica del cáncer cuyos datos (LUAD y LUSC en pulmón) son candidatos naturales para la validación prospectiva RNA-Seq.
- TFM** Trabajo Fin de Máster.
- TTF-1** Thyroid Transcription Factor 1, codificado por el gen *NKX2-1*. Uno de los marcadores IHC canónicos de adenocarcinoma pulmonar.
- UAX** Universidad Alfonso X el Sabio, institución académica en la que se defiende esta memoria.
- VEGF** Vascular Endothelial Growth Factor. Diana terapéutica del bevacizumab, cuyo uso está contraindicado en carcinoma escamoso.

Símbolos matemáticos

- $\bar{x}$ Media aritmética de una variable.
- C Hiperparámetro inverso de regularización en regresión logística. Valores menores implican mayor penalización.
- d d de Cohen, tamaño de efecto estandarizado.
- k Número de folds LODO en la validación externa. En este trabajo $k = 8$ para tumor *vs.* sano y $k = 3$ para subtipo.
- n Tamaño muestral (número de muestras en una cohorte, cohorte test o grupo).

p p -valor asociado a un contraste de hipótesis. Se emplea ajustado por FDR (*adjusted p-value*) en el análisis diferencial.

p (**transcritos**) Dimensión del espacio de features (número de genes evaluados, $\sim 22\,880$ en el análisis principal).

ρ Coeficiente de correlación de Spearman. En este trabajo cuantifica la relación entre el score del clasificador y el contenido residual de pulmón sano dentro de cada tumor.

s_p Desviación típica combinada (*pooled*) usada en el cálculo del d de Cohen.

τ Umbral mínimo de tamaño de efecto para que un gen entre en la firma consenso ($\tau = 0,5$ en este trabajo).

Etiquetas de columnas de los CSV

Cohorte_Test Identificador GEO Series (GSE...) de la cohorte usada como test en un fold LODO.

Evaluable_Como_Test Booleano que indica si una cohorte cumple los criterios de inclusión para actuar como test en LODO.

Baseline_Mayoritaria Precisión (*accuracy*) del clasificador ingenuo que siempre predice la clase mayoritaria del entrenamiento.

Ganancia_vs_Baseline Diferencia de balanced accuracy entre el modelo y el baseline mayoritario, en la misma cohorte test.

En_Panel_Minimo Booleano que indica si el gen forma parte del panel mínimo de 20 genes.

Marcador_IHC_Clinica Booleano que indica si el gen coincide con uno de los marcadores del panel IHC clínico de la OMS.