

UAX

Universidad Alfonso X el Sabio

UNIVERSIDAD ALFONSO X EL SABIO

FACULTAD BUSINESS & TECH

**Framework transcriptómico basado en la
integración de modelos de lenguaje y
aprendizaje automático para la identificación
de biomarcadores en cáncer de pulmón**

TRABAJO FIN DE MÁSTER

Máster Universitario en Bioinformática

Daniel Tapia Díez

Madrid, 2026

UNIVERSIDAD ALFONSO X EL SABIO

Máster Universitario en Bioinformática

TÍTULO DEL TRABAJO:

Framework transcriptómico basado en la integración de modelos de
lenguaje y aprendizaje automático para la identificación de biomarcadores
en cáncer de pulmón

ALUMNO: Daniel Tapia Díez

NP: _____

TUTOR DEL TRABAJO: Leonardo Dulcetti

FECHA DE PRESENTACIÓN: 14 de agosto de 2026

Firma del director

Firma del alumno

Resumen

El cáncer de pulmón es la primera causa de mortalidad oncológica en el mundo, con una supervivencia a cinco años que apenas alcanza el 20 % y una marcada heterogeneidad molecular entre subtipos histológicos con implicación terapéutica directa. Las bases de datos públicas de expresión génica, principalmente NCBI Gene Expression Omnibus (GEO), reúnen cientos de estudios transcriptómicos de pulmón, pero su integración manual resulta inviable por la heterogeneidad de plataformas y por unos metadatos clínicos redactados en texto libre que dificultan la asignación automática de muestras a grupos experimentales.

Este Trabajo Fin de Máster presenta `data.lung`, un *framework* reproducible que automatiza la integración multi-cohorte y la identificación de biomarcadores transcriptómicos en cáncer de pulmón. El sistema descarga las cohortes de GEO, las normaliza dentro de cada estudio, delega la curación de los metadatos clínicos a un modelo de lenguaje de gran tamaño (Llama 3.3-70b vía Groq), aplica criterios de inclusión, ejecuta análisis diferencial y entrena clasificadores supervisados (regresión logística regularizada L1, *Random Forest* y máquinas de vectores soporte) con validación externa *Leave-One-Dataset-Out* (LODO).

Sobre 11 cohortes GEO descargadas, 8 cumplen los criterios de inclusión (presencia de casos y controles, curación exitosa y alineamiento verificado). El *framework* identifica una firma génica de 1174 genes replicados en tres cohortes independientes para la tarea de subtipo histológico (adenocarcinoma frente a carcinoma escamoso), con un panel mínimo clínicamente manejable de 20 genes que alcanza AUC media LODO de 0,966. La firma completa recupera 18 de 20 marcadores diagnósticos de inmunohistoquímica clínica sin declararlos: 12 de 12 marcadores escamosos y 6 de 8 adenocarcinoma. Sobre la tarea tumor *vs.* sano, el modelo obtiene AUC media LODO 0,925 con balanced accuracy 0,772.

La aportación principal del trabajo es doble: (i) demuestra que la integración de un modelo de lenguaje en el paso de curación clínica permite escalar la integración multi-cohorte sin renunciar al rigor metodológico, y (ii) prueba que la exigencia de replicación en cohortes independientes —condición ausente en la mayoría de firmas publicadas— produce un panel biológicamente interpretable y coincidente con marcadores clínicos ya en uso.

Palabras clave: transcriptómica, cáncer de pulmón, adenocarcinoma, carcinoma escamoso, biomarcadores, aprendizaje automático, modelos de lenguaje, NCBI GEO, validación LODO, firma génica, panel mínimo, inmunohistoquímica.

Abstract

Lung cancer is the leading cause of cancer-related mortality worldwide, with a five-year survival rate below 20 % and pronounced molecular heterogeneity between histological subtypes that carries direct therapeutic implications. Public gene expression repositories, most notably the NCBI Gene Expression Omnibus (GEO), host hundreds of transcriptomic studies of lung tissue, yet their manual integration is infeasible due to platform heterogeneity and free-text clinical metadata that hinder the automatic assignment of samples to experimental groups.

This Master’s Thesis presents **data.lung**, a reproducible framework that automates multi-cohort integration and transcriptomic biomarker discovery in lung cancer. The system downloads cohorts from GEO, normalises within each study, delegates clinical metadata curation to a large language model (Llama 3.3-70b via Groq), applies inclusion criteria, performs differential expression analysis and trains supervised classifiers (L1-regularised logistic regression, Random Forest, Support Vector Machines) with external Leave-One-Dataset-Out (LODO) validation.

Out of 11 downloaded GEO cohorts, 8 meet the inclusion criteria (presence of cases and controls, successful curation and verified alignment). The framework identifies a signature of 1174 genes replicated across three independent cohorts for the histological subtype task (adenocarcinoma *vs.* squamous carcinoma), with a minimal clinically manageable panel of 20 genes achieving a mean LODO AUC of 0.966. The full signature recovers 18 of 20 clinical immunohistochemistry markers without being told about them: 12 of 12 squamous markers and 6 of 8 adenocarcinoma markers. On the tumour *vs.* healthy task, the model attains a mean LODO AUC of 0.925 with balanced accuracy 0.772.

The main contribution is twofold: (i) it shows that incorporating a large language model into the clinical curation step allows multi-cohort integration to scale without sacrificing methodological rigour, and (ii) it demonstrates that requiring replication across independent cohorts—a condition absent from most published signatures—yields a biologically interpretable panel that coincides with clinically established markers.

Keywords: transcriptomics, lung cancer, adenocarcinoma, squamous cell carcinoma, biomarkers, machine learning, large language models, NCBI GEO, LODO validation, gene signature, minimal panel, immunohistochemistry.

Índice general

Resumen	5
Abstract	7
1. Introducción	1
1.1. Contexto y motivación	1
1.2. Transcriptómica y bases de datos públicas	2
1.3. Modelos de lenguaje aplicados a curación de metadatos	3
1.4. Alcance y planteamiento del trabajo	3
2. Estado del arte	5
2.1. Firmas génicas en cáncer de pulmón	5
2.2. Integración multi-cohorte y meta-análisis	5
2.3. Aprendizaje automático en transcriptómica	6
2.4. Modelos de lenguaje en bioinformática	7
2.5. Ausencias en la literatura	7
3. Objetivos	9
3.1. Objetivo general	9
3.2. Objetivos específicos	9
3.3. Hipótesis de partida	10
4. Materiales y métodos	13
4.1. Visión general del <i>pipeline</i>	13
4.2. Adquisición y normalización de cohortes	13
4.2.1. Selección de cohortes	13
4.2.2. Descarga y mapeo	14
4.2.3. Normalización	14
4.3. Curación clínica con modelo de lenguaje	15
4.3.1. Formulación de la tarea	15
4.3.2. Modelo y servicio	15
4.3.3. Auditoría de la curación	15
4.4. Criterios de inclusión	16
4.5. Análisis diferencial	16
4.6. Clasificadores supervisados	16
4.7. Validación externa Leave-One-Dataset-Out	17
4.8. Firma génica por consenso	17
4.9. Panel mínimo	17
4.10. Validación contra IHC clínica	18

4.11. Interfaz web y asistente	18
4.12. Reproducibilidad	18
5. Resultados	21
5.1. Cohortes evaluables y curación LLM	21
5.2. Clasificación tumor <i>vs.</i> sano	21
5.3. Clasificación de subtipo histológico ADC <i>vs.</i> SQC	24
5.4. Firma génica validada	25
5.5. Panel mínimo	25
5.6. Validación externa contra IHC clínica	26
5.7. Composición tisular dentro de los tumores	26
5.8. Interpretación biológica: dos ejes reales	27
5.9. Histologías fuera del alcance de entrenamiento	27
5.10. Análisis exploratorio por cohorte	28
5.11. Coherencia de los folds LODO	29
6. Discusión	31
6.1. Interpretación de los resultados	31
6.2. Contribución del modelo de lenguaje	31
6.3. Sesgos y limitaciones metodológicas	32
6.3.1. Ámbito de plataforma	32
6.3.2. Ámbito histológico	32
6.3.3. Umbral de decisión	32
6.3.4. Población y sesgos demográficos	33
6.3.5. Tamaño muestral	33
6.4. Comparación con la literatura	33
6.5. Implicaciones clínicas potenciales	33
6.6. Comparación con firmas comerciales existentes	34
6.7. Lecciones metodológicas	34
7. Conclusiones y trabajo futuro	35
7.1. Conclusiones	35
7.2. Aportaciones originales	36
7.3. Limitaciones	36
7.4. Trabajo futuro	37
7.5. Balance personal	37
Bibliografía	39
Appendices	41
A. Estructura del repositorio	43
B. Ficheros de resultados	45

C. Interfaz web

47

Índice de figuras

5.1. Tasa de éxito de la curación LLM por cohorte. Barras verdes indican cohortes con curación superior al 40 % (umbral de inclusión).	21
5.2. Balanced accuracy del modelo en LODO frente al baseline mayoritario informado por cohorte.	23
5.3. AUC frente a balanced accuracy por cohorte en LODO. La brecha vertical entre ambas cifras es proporcional a la necesidad de recalibración del umbral.	24
5.4. AUC media LODO en función del tamaño del panel (genes ordenados por d media de la firma validada). El panel mínimo (20 genes) captura el 99,6 % del AUC de la firma completa.	25
5.5. Correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores, por cohorte.	27
5.6. Histologías presentes en las cohortes GEO originales que quedaron fuera del entrenamiento del clasificador de subtipo.	28
5.7. Análisis exploratorio de la cohorte GSE31210. (a) Componentes principales; los grupos sano y enfermo se separan en el plano. (b) Volcano de la comparación diferencial; miles de genes cruzan el umbral $ d > 1$ con $\text{FDR} < 0,05$. (c) Heatmap de los 30 genes más significativos, con dendrograma de muestras que reproduce el grupo clínico.	29
5.8. Concordancia de signo de los coeficientes de LASSO entre distintos folds LODO. El acuerdo perfecto en signo se sitúa por encima del 90 % para los genes de la firma.	29

Índice de tablas

4.1. Cohortes GEO utilizadas en el trabajo.	14
5.1. Rendimiento LODO para la tarea tumor <i>vs.</i> sano.	22
5.2. Rendimiento LODO para la tarea de subtipo ADC <i>vs.</i> SQC.	24

Capítulo 1

Introducción

1.1. Contexto y motivación

El cáncer de pulmón es la principal causa de mortalidad oncológica a nivel mundial. Según las estimaciones de la *International Agency for Research on Cancer* (IARC), en 2022 se diagnosticaron aproximadamente 2,48 millones de nuevos casos, con 1,82 millones de fallecimientos atribuibles a la enfermedad [1]. En España, el Observatorio del Cáncer de la Asociación Española Contra el Cáncer sitúa la incidencia en torno a 30 000 casos anuales, con una supervivencia a cinco años que apenas alcanza el 20 %. Estas cifras contrastan con las tasas de supervivencia de otros tumores sólidos como el cáncer de mama, próstata o colorrectal, y evidencian la necesidad de mejorar tanto el diagnóstico temprano como la estratificación molecular de los pacientes.

Desde el punto de vista histológico, el cáncer de pulmón se clasifica principalmente en dos grandes grupos: el cáncer de pulmón de células no pequeñas (*Non-Small Cell Lung Cancer*, NSCLC), que representa aproximadamente el 85 % de los casos, y el cáncer de pulmón microcítico (*Small Cell Lung Cancer*, SCLC), con el 15 % restante. Dentro del NSCLC, los dos subtipos histológicos predominantes son el adenocarcinoma (ADC) y el carcinoma escamoso (*Squamous Cell Carcinoma*, SQC), seguidos a distancia por el carcinoma de células grandes y los tumores neuroendocrinos de gran célula.

La distinción entre adenocarcinoma y carcinoma escamoso tiene una implicación terapéutica directa que trasciende el mero interés clasificatorio. El pemetrexed, un antifolato aprobado para el tratamiento del NSCLC no escamoso, presenta una eficacia significativamente menor en histología escamosa y su uso está desaconsejado en este subtipo. El bevacizumab, un anticuerpo monoclonal dirigido contra el factor de crecimiento del endotelio vascular (VEGF), está formalmente contraindicado en carcinoma escamoso por el riesgo de hemorragia pulmonar grave. Diversos regímenes de inmunoterapia con inhibidores de *immune checkpoints* (PD-1/PD-L1) muestran también patrones de respuesta diferentes según el subtipo. Por tanto, una clasificación histológica inequívoca condiciona la decisión terapéutica y el pronóstico.

En la práctica clínica, la clasificación se realiza sobre biopsia mediante inmunohistoquímica (IHC), usando paneles de marcadores canónicos: citoqueratinas y factores de transcripción de linaje epitelial escamoso (KRT5, TP63, DSG3...) para el diagnóstico de carcinoma escamoso, y marcadores del programa alveolar tipo II (napsina A, TTF-1/NKX2-1, surfactantes...) para el adenocarcinoma. Sin embargo, cuando la biopsia es escasa o el patrón inmunohistoquímico es ambiguo, la decisión puede demorarse o quedar sujeta a discrepancia entre patólogos. Un panel molecular objetivo basado en la expresión de un número reducido

de genes podría complementar la IHC en estos casos.

1.2. Transcriptómica y bases de datos públicas

La transcriptómica es la disciplina que estudia el conjunto de transcritos de ARN producidos por un genoma en un momento y contexto biológico concretos. A diferencia del genoma, que es esencialmente estable a lo largo de la vida del individuo, el transcriptoma refleja el estado funcional de la célula: qué genes se están expresando, en qué proporción y bajo qué programa regulatorio. Esta característica hace que el transcriptoma sea un sustrato especialmente informativo para el estudio del cáncer, donde la transformación maligna se acompaña de reprogramaciones profundas de la expresión génica [2].

Las dos tecnologías de referencia para cuantificar el transcriptoma son los *microarrays* de expresión (predominantes hasta aproximadamente 2015) y la secuenciación masiva de ARN (RNA-Seq, dominante desde entonces). En *microarrays*, un chip fija miles de sondas de oligonucleótidos complementarias a cada gen; el ARN de la muestra se marca con fluorescencia y se hibrida al chip, obteniendo una medida de la abundancia relativa de cada gen. En RNA-Seq, el ARN se convierte a ADN complementario, se secuencia y las lecturas se mapean al genoma o transcriptoma de referencia. Ambas tecnologías han generado un enorme volumen de datos públicos.

El repositorio NCBI Gene Expression Omnibus (GEO, <https://www.ncbi.nlm.nih.gov/geo/>) es el mayor archivo público de datos de expresión génica [3]. Cuenta con más de un millón de muestras de miles de estudios cubriendo prácticamente cualquier tejido, condición o especie. Para cáncer de pulmón se dispone de centenares de estudios que abarcan tanto adenocarcinoma como escamoso, tanto muestras tumorales como controles adyacentes, y tanto plataformas de *microarrays* clásicas (Affymetrix HG-U133 Plus 2.0, plataforma GPL570) como datos de RNA-Seq de The Cancer Genome Atlas (TCGA).

Sin embargo, la disponibilidad no equivale a usabilidad. Un investigador que quiera integrar varias cohortes debe resolver al menos cuatro problemas técnicos:

1. **Heterogeneidad de plataformas.** Las sondas de un chip Affymetrix HG-U133 Plus 2.0 no son directamente comparables con las de un chip Illumina o con las cuentas normalizadas de RNA-Seq. Es preciso mapear cada sonda a un símbolo génico y agregar sondas múltiples cuando varias apuntan al mismo gen.
2. **Curación clínica.** Los metadatos de GEO están redactados en texto libre por el laboratorio que deposita el estudio. Una misma categoría clínica puede aparecer como *lung adenocarcinoma*, *ADC*, *non-small cell lung cancer*, *adenocarcinoma histology*, *primary tumor: adenocarcinoma*, etc. El grupo control puede denominarse *normal*, *healthy*, *non-tumor adjacent tissue*, *control lung*, o incluso no estar etiquetado explícitamente en el campo esperado.
3. **Efecto lote.** La variabilidad técnica entre plataformas, laboratorios y protocolos introduce fuentes de varianza que pueden dominar sobre la señal biológica y confundir

cualquier análisis posterior.

4. **Validación externa.** Una firma génica identificada en una cohorte concreta rara vez se replica en cohortes independientes. La literatura acumula cientos de firmas propuestas que no han conseguido transferirse a la clínica [4].

1.3. Modelos de lenguaje aplicados a curación de metadatos

Los recientes modelos de lenguaje de gran tamaño (LLMs), como GPT-4, Claude o Llama, han demostrado una capacidad notable para tareas de comprensión de texto en dominios especializados, incluyendo la biomedicina. La capacidad de estos modelos para interpretar texto libre, extraer entidades y clasificarlas según categorías predefinidas los convierte en herramientas naturales para automatizar tareas de curación que hasta ahora requerían intervención manual.

En el ámbito de este trabajo, un LLM puede leer la descripción textual de una muestra de GEO (por ejemplo, *lung adenocarcinoma, stage IIB, 72-year-old male, former smoker*) y devolver una etiqueta canónica del grupo experimental (**enfermo**, **sano**, **ambiguo**). Esta delegación permite integrar cohortes con nomenclaturas heterogéneas sin tener que codificar reglas específicas para cada estudio, y hace escalable la incorporación de nuevas cohortes al análisis. El presente trabajo emplea Llama 3.3-70b servido vía la infraestructura de inferencia de Groq, que ofrece una latencia baja y un coste marginal accesible para el volumen de muestras del proyecto.

1.4. Alcance y planteamiento del trabajo

Este Trabajo Fin de Máster desarrolla `data.lung`, un *framework* de análisis transcriptómico y aprendizaje automático que integra los componentes descritos en las secciones anteriores para responder a una pregunta concreta: *¿es posible identificar, mediante integración automatizada de cohortes públicas y validación externa, una firma génica de biomarcadores replicable entre cohortes independientes para adenocarcinoma y carcinoma escamoso de pulmón?*

El planteamiento del trabajo se articula sobre tres pilares:

- **Automatización de la integración multi-cohorte** mediante un modelo de lenguaje que resuelve la curación clínica sin intervención humana, escalando la incorporación de nuevas cohortes.
- **Validación externa exigente** basada en Leave-One-Dataset-Out (LODO), donde cada cohorte se retira una vez del entrenamiento y se utiliza como test independiente, y en meta-análisis por consenso: un gen entra en la firma final sólo si mantiene el mismo signo de cambio en las tres cohortes evaluables simultáneamente.
- **Interpretabilidad biológica** de la firma resultante, contrastada con marcadores clínicos ya establecidos en inmunohistoquímica diagnóstica y con ejes biológicos conocidos del cáncer de pulmón (linaje escamoso frente a alveolar, actividad proliferativa).

El resto de la memoria se organiza como sigue. El capítulo 2 revisa el estado del arte en integración multi-cohorte, firmas génicas publicadas y aplicaciones de LLMs en bioinformática. El capítulo 3 formula los objetivos general y específicos del trabajo. El capítulo 4 detalla los materiales y métodos, con particular atención al diseño del *pipeline*. El capítulo 5 presenta los resultados de las dos tareas de clasificación, la firma génica validada y los ejes biológicos identificados. El capítulo 6 discute las implicaciones clínicas y metodológicas, sitúa los resultados en el contexto de la literatura y enumera las limitaciones del trabajo. El capítulo 7 resume las conclusiones y esboza líneas de trabajo futuro.

Capítulo 2

Estado del arte

2.1. Firmas génicas en cáncer de pulmón

La búsqueda de firmas génicas con valor diagnóstico o pronóstico en cáncer de pulmón cuenta con una literatura extensa. Beer et al. [5] describieron en 2002 una de las primeras firmas pronósticas para adenocarcinoma de pulmón mediante *microarrays*, identificando un panel de aproximadamente 50 genes cuya expresión permitía estratificar pacientes por riesgo de muerte a corto plazo. En los años siguientes, distintos grupos han propuesto firmas para diagnóstico histológico, pronóstico global, respuesta a tratamiento con inhibidores de EGFR, presencia de mutaciones en KRAS o ALK, y probabilidad de recurrencia tras cirugía.

Sin embargo, la revisión sistemática de Subramanian y Simon [6] reveló que la gran mayoría de firmas propuestas no superaba una validación independiente rigurosa. Los sesgos habituales incluyen: (i) uso de la misma cohorte para descubrimiento y validación mediante partición aleatoria en lugar de LODO; (ii) selección de genes en el conjunto completo de datos seguida de validación cruzada, incurriendo en la falacia de las particiones (*data leakage*); (iii) omisión de análisis de composición tisular, con firmas que en realidad reflejan la proporción variable de estroma o células inmunes; y (iv) informar únicamente el AUC sin considerar la capacidad de calibración del umbral de decisión entre cohortes.

Estos problemas metodológicos explican, al menos en parte, por qué el número de firmas génicas trasladadas a la práctica clínica en cáncer de pulmón es reducido. Uno de los ensayos comerciales con mayor difusión es la firma pronóstica *Pervenio Lung RS*, basada en un panel de 14 genes medidos por PCR cuantitativa [7]; otro es *Oncotype DX Lung* de Genomic Health, con un panel similar. Ambos mantienen un uso limitado y no han desplazado a los marcadores inmunohistoquímicos clásicos.

En el ámbito del diagnóstico histológico, la Organización Mundial de la Salud (OMS) publica desde 2015 recomendaciones para el uso combinado de marcadores inmunohistoquímicos: TTF-1/NKX2-1 y napsina A como positivos para adenocarcinoma, y CK5/6, p40 (isoforma de TP63) y DSG3 como positivos para carcinoma escamoso [8]. La correspondencia entre estos marcadores IHC y su expresión transcripcional constituye una referencia natural para validar la interpretabilidad de una firma génica.

2.2. Integración multi-cohorte y meta-análisis

La integración de múltiples cohortes de expresión ha dado lugar a un cuerpo metodológico específico. Los enfoques principales se agrupan en dos familias:

- **Corrección de efecto lote:** normaliza las cohortes conjuntamente para eliminar la va-

rianza atribuible al origen técnico. ComBat [9] y sus variantes bayesianas empíricas son las herramientas más difundidas. El riesgo de estos métodos es eliminar señal biológica genuina cuando el efecto lote está confundido con la variable de interés.

- **Meta-análisis por consenso:** normaliza cada cohorte por separado, calcula el estadístico de interés (por ejemplo, el tamaño de efecto d de Cohen para la diferencia de medias entre grupos), y combina los resultados con criterios de consenso (mismo signo, misma magnitud mínima) en varias cohortes. Este enfoque es más conservador y permite distinguir señal reproducible de artefacto técnico.

En el contexto de este trabajo se adopta la segunda familia, con validación externa Leave-One-Dataset-Out (LODO). En LODO, el modelo se entrena con todas las cohortes menos una, y se evalúa en la retirada; el proceso se itera dejando fuera cada cohorte por turno. Esta partición es más conservadora que la validación cruzada estándar porque respeta la estructura de agrupación de las muestras: dos muestras de la misma cohorte comparten sesgo técnico, y evaluarlas juntas sobre-estima el rendimiento.

Bernau et al. [10] formalizaron el marco de validación cross-study en clasificadores oncológicos. Trabajos posteriores han aplicado LODO a firmas de cáncer de mama [11] y de pulmón [12], mostrando reducciones consistentes del AUC entre 5 y 15 puntos cuando se pasa de validación interna a externa. Esto justifica adoptar LODO como estándar mínimo para reclamar replicación.

2.3. Aprendizaje automático en transcriptómica

Los datos transcriptómicos plantean un reto clásico para el aprendizaje automático: alta dimensionalidad ($p \gg n$, con p del orden de 10^4 genes y n del orden de 10^2 muestras). Las estrategias habituales combinan reducción de dimensionalidad, regularización y selección de características.

- **Regresión logística con regularización L1 (LASSO):** la penalización ℓ_1 fuerza a coeficientes exactos a cero, seleccionando implícitamente un subconjunto reducido de genes. Es la estrategia más usada cuando se busca interpretabilidad y un panel mínimo.
- **Random Forest:** ensamble de árboles de decisión con *bagging* y selección aleatoria de variables en cada división. No fuerza esparsidad pero produce un ranking de importancia útil como complemento a LASSO.
- **Máquinas de vectores soporte (SVM):** eficaces en dimensiones altas con kernels lineales o RBF, aunque con menor interpretabilidad de los pesos.
- **Redes neuronales profundas:** en los últimos años se han aplicado a datos ómicos, pero requieren tamaños muestrales que suelen quedar fuera del alcance de estudios de cohortes públicas.

La elección de LASSO como método principal en este trabajo se justifica por tres razones: (i) produce un panel interpretable, útil clínicamente; (ii) es determinista dado un `random_state` fijo, lo que garantiza reproducibilidad; y (iii) el hiperparámetro de regularización (C) admite una calibración simple mediante validación cruzada anidada, sin requerir las decisiones arquitectónicas propias de una red neuronal.

2.4. Modelos de lenguaje en bioinformática

El uso de LLMs en bioinformática ha crecido rápidamente desde la aparición de GPT-4 en 2023. Las aplicaciones documentadas incluyen anotación funcional de genes, extracción de información de literatura biomédica, generación de código para análisis y curación de metadatos clínicos [13, 14]. Un trabajo particularmente relevante para esta tesis es GEOparser [15], que emplea GPT-4 para extraer metadatos estructurados de GEO Series y demuestra tasas de éxito superiores al 90 % en un conjunto de test manual.

Los modelos abiertos (Llama 2, Llama 3, Mistral) han cerrado buena parte de la brecha con los modelos propietarios en tareas de comprensión y clasificación, especialmente en tamaños de 70 B parámetros o superiores [16]. La infraestructura de inferencia acelerada por hardware específico (Groq LPU, Cerebras) permite servir estos modelos con latencias de decenas de milisegundos por consulta, haciendo viable su integración en *pipelines* de análisis a escala.

En el contexto de este trabajo, el LLM cumple una única función bien delimitada: leer la descripción textual de una muestra de GEO y devolver una etiqueta canónica del grupo experimental. Esta tarea es paradigmática de clasificación de texto y no requiere generación abierta, lo que reduce los riesgos de alucinación observados en tareas de razonamiento libre. El uso del LLM se restringe además a la fase de curación de datos, sin participación en el análisis estadístico ni en la selección de biomarcadores, evitando así que el conocimiento paramétrico del modelo sobre cáncer de pulmón introduzca sesgos en los resultados.

2.5. Ausencias en la literatura

La revisión anterior identifica varios huecos que este TFM aborda de manera integrada:

1. **Ausencia de *frameworks* extremo a extremo** que combinen curación automatizada con LLM, integración multi-cohorte, clasificación supervisada con validación externa y verificación cruzada contra marcadores clínicos, todo ello en un pipeline reproducible.
2. **Falta de firmas con replicación estricta** en varias cohortes independientes. Los trabajos publicados suelen reportar resultados sobre una única cohorte de validación o sobre particiones aleatorias de la misma cohorte de descubrimiento.
3. **Desconexión entre firmas transcriptómicas y marcadores clínicos.** La mayoría de firmas propuestas no verifican explícitamente hasta qué punto recuperan marcadores ya en uso en la clínica, ni explican qué genes de su panel corresponden a marcadores conocidos y cuáles son novedosos.

El framework **data.lung** se diseña como respuesta a estos tres huecos: proporciona una tubería end-to-end reproducible, aplica LODO como criterio mínimo de validación y contrasta explícitamente la firma resultante con el panel diagnóstico IHC de la OMS.

Capítulo 3

Objetivos

3.1. Objetivo general

Diseñar, implementar y validar un *framework* bioinformático reproducible que automatice la integración de cohortes transcriptómicas públicas de cáncer de pulmón, mediante la combinación de un modelo de lenguaje de gran tamaño para la curación clínica y aprendizaje automático supervisado para la identificación de biomarcadores replicables.

El framework debe cumplir tres propiedades irrenunciables:

- **Reproducibilidad:** dos ejecuciones sobre los mismos datos deben producir resultados idénticos hasta el último decimal, gracias al uso de semillas aleatorias fijas y a la ausencia de intervención manual en cualquier paso del pipeline.
- **Validación externa:** la evaluación del rendimiento debe realizarse siempre en cohortes independientes de las utilizadas para el entrenamiento, mediante Leave-One-Dataset-Out.
- **Interpretabilidad biológica:** los biomarcadores identificados deben ser trazables a mecanismos biológicos conocidos y, cuando exista un panel clínico establecido para la misma pregunta, contrastables con dicho panel.

3.2. Objetivos específicos

Los objetivos específicos que se derivan del objetivo general son:

- OE1. Adquisición y normalización automatizada de cohortes GEO.** Descargar mediante API las cohortes seleccionadas del repositorio NCBI GEO, extraer las matrices de expresión y aplicar normalización $\log_2$ y corrección por cuantiles dentro de cada estudio. El proceso debe ser robusto frente a la heterogeneidad de plataformas de microarray, particularmente Affymetrix HG-U133 Plus 2.0 (GPL570).
- OE2. Curación clínica de metadatos con modelo de lenguaje.** Implementar un módulo que consulte al modelo Llama 3.3-70b a través de la API de Groq para asignar cada muestra a una categoría binaria (**sano** / **enfermo**), o descartarla como **ambigua**, interpretando el texto libre de la descripción de la muestra. Registrar la tasa de éxito por cohorte como métrica de calidad de la curación.
- OE3. Aplicación transparente de criterios de inclusión.** Definir y aplicar los criterios que una cohorte debe cumplir para entrar al entrenamiento y evaluación (presencia

de casos y controles, curación exitosa por encima de un umbral mínimo, alineamiento verificado por identificador `geo_accession`). Las cohortes que no cumplan algún criterio se documentan explícitamente, sin descartes silenciosos.

OE4. Análisis diferencial y clasificación supervisada. Ejecutar análisis diferencial (test *t* de Welch con corrección FDR de Benjamini-Hochberg) y entrenar clasificadores supervisados (regresión logística L1, Random Forest y máquinas de vectores soporte) para las dos tareas contempladas: (a) tumor *vs.* sano, y (b) subtipo histológico ADC *vs.* SQC.

OE5. Validación externa Leave-One-Dataset-Out. Evaluar cada clasificador mediante LODO sobre las cohortes evaluables, reportando AUC, balanced accuracy, sensibilidad, especificidad y ganancia respecto al baseline mayoritario informado.

OE6. Identificación de una firma génica validada por consenso. Construir una firma de biomarcadores mediante meta-análisis por consenso multi-cohorte: un gen entra en la firma sólo si mantiene el mismo signo de cambio y una magnitud mínima (medida como *d* de Cohen) en las tres cohortes evaluables simultáneamente.

OE7. Panel mínimo clínicamente manejable. Derivar, a partir de la firma validada, un panel mínimo del menor número de genes cuya AUC se mantenga a menos de 0,01 del máximo alcanzado por la firma completa. El objetivo es un panel del orden de las decenas de genes, susceptible de ser medido mediante PCR cuantitativa o *NanoString*.

OE8. Validación externa contra marcadores clínicos IHC. Comprobar en qué medida la firma validada, seleccionada de forma puramente estadística sin declararle los marcadores clínicos, recupera el panel de inmunohistoquímica diagnóstica recomendado por la OMS para adenocarcinoma y carcinoma escamoso.

OE9. Interfaz web reproducible. Desarrollar una interfaz web interactiva (Streamlit) que permita a un revisor navegar por los resultados del framework, consultar cifras y figuras por cohorte y por gen, y verificar en tiempo real la trazabilidad de cualquier afirmación cuantitativa a los CSV/JSON generados por el pipeline.

OE10. Asistente conversacional acotado a los resultados. Integrar en la interfaz un asistente conversacional basado en el mismo modelo Llama 3.3-70b, alimentado con un contexto que se lee dinámicamente de los resultados y con reglas explícitas que impiden inventar cifras o citar biomarcadores que no estén en la firma.

3.3. Hipótesis de partida

Las hipótesis que se contrastan con el trabajo son:

1. Un modelo de lenguaje contemporáneo puede curar los metadatos clínicos de cohortes GEO de cáncer de pulmón con una tasa de éxito superior al 80 % sobre cohortes evaluables, escalando la integración multi-cohorte a un coste computacional accesible.

2. La aplicación de meta-análisis por consenso multi-cohorte, con exigencia estricta de replicación en tres cohortes independientes, produce una firma génica biológicamente coherente cuya AUC en LODO supera el 0,90 sobre la tarea de subtipo histológico.
3. La firma resultante, seleccionada de forma *data-driven*, recupera al menos el 75 % de los marcadores diagnósticos IHC del panel recomendado por la OMS, lo que constituye una validación externa fuerte frente a un estándar clínico independiente.
4. Un panel mínimo del orden de 20 genes es suficiente para aproximarse al rendimiento de la firma completa, con una pérdida de AUC inferior a 0,01, haciendo el panel clínicamente manejable.

Los capítulos siguientes describen la metodología empleada (capítulo 4) y presentan los resultados (capítulo 5) que permiten aceptar o rechazar cada una de estas hipótesis.

Capítulo 4

Materiales y métodos

4.1. Visión general del *pipeline*

El framework `data.lung` se organiza como una tubería de pasos secuenciales que producen artefactos intermedios (matrices, CSV, JSON) versionados en disco. Cada paso puede ejecutarse de forma aislada o encadenado desde el orquestador. La figura conceptual del pipeline es la siguiente:

1. Descarga de cohortes GEO y mapeo sonda $\rightarrow$ símbolo génico.
2. Normalización por estudio ($\log_2$ y cuantiles).
3. Curación clínica con LLM (Llama 3.3-70b).
4. Aplicación de criterios de inclusión y auditoría.
5. Análisis diferencial (Welch + FDR).
6. Clasificación supervisada (LASSO L1, RF, SVM).
7. Validación externa LODO.
8. Meta-análisis por consenso y firma génica validada.
9. Panel mínimo y validación contra IHC clínica.
10. Interfaz web y asistente conversacional.

La totalidad del *pipeline* está implementada en Python 3.12 y hace uso de las librerías científicas estándar (`pandas`, `numpy`, `scikit-learn`, `scipy`, `statsmodels`). La reproducibilidad se garantiza mediante fijación de la semilla aleatoria (`random_state=42`) en todos los pasos con componente estocástico y mediante el registro de cada resultado intermedio en disco. El código fuente se aloja en un repositorio Git público (<https://github.com/danitapiadiez-gif/TFM-Bioinformatica>).

4.2. Adquisición y normalización de cohortes

4.2.1. Selección de cohortes

Se seleccionaron 11 cohortes del repositorio NCBI GEO que cumplieran los siguientes requisitos previos: (i) especie *Homo sapiens*; (ii) tejido pulmón; (iii) plataforma Affymetrix

HG-U133 Plus 2.0 (GPL570) o compatible; (iv) tamaño muestral mínimo de 10 muestras; (v) disponibilidad pública completa (no restricted access). La tabla 4.1 enumera las cohortes seleccionadas.

Tabla 4.1: Cohortes GEO utilizadas en el trabajo.

Cohorte	Muestras totales	Sanas	Enfermas	Sin clasificar	Evaluable
GSE118370	12	6	6	0	sí
GSE140797	14	0	7	7	no
GSE18842	91	45	46	0	sí
GSE19188	156	65	91	0	sí
GSE19804	120	60	60	0	sí
GSE23066	10	5	5	0	sí
GSE30219	307	0	307	0	no
GSE31210	246	20	226	0	sí
GSE40791	194	10	2	182	sí
GSE50081	181	0	181	0	no
GSE7670	15	8	7	0	sí
Total	1 346	219	938	189	8 / 11

4.2.2. Descarga y mapeo

La descarga se realiza mediante la librería `GEOparse`, que consulta la API de GEO y descarga tanto la matriz SOFT como los ficheros suplementarios cuando existen. Para cada cohorte se obtiene:

- La matriz de expresión sonda $\times$ muestra.
- Los metadatos de muestra (`characteristics_ch1`, `title`, `source_name`), preservados como texto libre.
- La tabla de anotación de la plataforma, con la correspondencia sonda $\rightarrow$ símbolo génico oficial (HUGO).

El mapeo sonda $\rightarrow$ gen agrega las sondas múltiples que apuntan al mismo símbolo tomando el promedio geométrico de sus intensidades. Las sondas sin anotación se descartan.

4.2.3. Normalización

La normalización se realiza *dentro de cada estudio*, sin intentar corrección de efecto lote entre cohortes. Los pasos son:

1. Transformación logarítmica: $x \leftarrow \log_2(x + 1)$.

2. Normalización por cuantiles: cada muestra se ajusta al cuantil correspondiente de la distribución media de la cohorte.

La razón de no aplicar corrección conjunta de lote (por ejemplo ComBat) es que LODO no requiere que el efecto lote esté corregido: lo mide. Si la firma resulta robusta bajo LODO, es porque los genes seleccionados mantienen su patrón de cambio a pesar del efecto lote, lo que es una propiedad deseable. Aplicar ComBat sobre cohortes con distinta prevalencia de la variable de interés puede introducir sesgos difíciles de auditar.

4.3. Curación clínica con modelo de lenguaje

4.3.1. Formulación de la tarea

Para cada muestra se construye un *prompt* que incluye:

- El texto libre de `title`, `source_name` y todas las `characteristics_ch1` de la muestra.
- Una instrucción canónica que solicita la clasificación en `sano`, `enfermo` o `ambiguo`, con criterios explícitos y ejemplos de cada categoría.
- Una restricción de formato de salida: JSON con dos campos (`etiqueta` y `motivo`).

La categoría `ambiguo` recoge tanto muestras cuya descripción no permite asignar grupo (por ejemplo, línea celular sin especificar condición) como muestras que pertenecen a subtipos no contemplados en el estudio (metástasis, tumores neuroendocrinos si la cohorte se enfoca en NSCLC, etc.). Este diseño evita forzar clasificaciones erróneas y produce un descarte explícito.

4.3.2. Modelo y servicio

Se utiliza Llama 3.3-70b servido a través de la API pública de Groq. Las peticiones se envían con `temperature=0.0` para maximizar el determinismo. La latencia media por muestra es del orden de 400 ms y el coste marginal es inferior a 0,001 USD por muestra al precio actual de la tier gratuita del servicio.

4.3.3. Auditoría de la curación

Para cada cohorte se registran las siguientes métricas de curación en el fichero `AUDITORIA_COHORTES.csv`:

- Número total de muestras descargadas.
- Muestras clasificadas como `sano`, `enfermo`, `sin_clasificar`.
- Tasa de éxito de curación: proporción de muestras con etiqueta distinta de `ambiguo`.
- Marca `Evaluable_Como_Test`: booleano que indica si la cohorte tiene al menos una muestra de cada clase (`sano` y `enfermo`).

4.4. Criterios de inclusión

Una cohorte se considera *evaluable* para la tarea tumor *vs.* sano si cumple simultáneamente:

1. Presencia de al menos una muestra sana y una enferma.
2. Tasa de éxito de curación superior al 40 % (por debajo de este umbral, la señal está dominada por descartes y no permite entrenar de forma fiable).
3. Alineamiento verificado entre matriz de expresión y metadatos por identificador `geo_accession`. Cualquier discordancia se registra en `N_Muestras_Desalineadas` y bloquea la cohorte.

Sobre las 11 cohortes descargadas, 8 cumplen los tres criterios. Las tres excluidas (GSE30219, GSE50081, GSE140797) no tienen controles sanos evaluables. Sus muestras tumorales sí se aprovechan en el entrenamiento LODO (aportan variabilidad a la clase mayoritaria), pero no pueden actuar como test.

Para la tarea de subtipo histológico ADC *vs.* SQC, el criterio de evaluabilidad se reformula como: presencia de al menos 10 muestras de cada subtipo, sobre plataforma GPL570 (para maximizar la comparabilidad técnica). Este criterio lo cumplen 3 cohortes: GSE19188, GSE30219 y GSE50081, con un total de 388 muestras (146+170+72 respectivamente).

4.5. Análisis diferencial

Para cada gen g y cada cohorte c se contrasta la diferencia de expresión media entre los grupos mediante un test t de Welch (que no asume igual varianza entre grupos). Los p -valores se corrigen para múltiples comparaciones con el método de Benjamini-Hochberg (FDR).

Se calcula además el tamaño de efecto mediante la d de Cohen:

$$d_g = \frac{\bar{x}_{g,\text{enfermo}} - \bar{x}_{g,\text{sano}}}{s_{p,g}} \quad (4.1)$$

donde $s_{p,g}$ es la desviación típica combinada. Se considera un tamaño de efecto *grande* si $|d| > 0,8$, y *muy grande* si $|d| > 1,2$.

4.6. Clasificadores supervisados

Los tres clasificadores empleados se implementan sobre `scikit-learn` 1.4 con las siguientes configuraciones base:

- **Regresión logística L1:** `LogisticRegression(penalty='l1', solver='saga', C=0.5, max_iter=5000, random_state=42)`. La regularización se calibra en un pequeño estudio previo con búsqueda logarítmica en $C \in \{0,1; 0,5; 1; 5\}$; el valor 0,5 ofrece el mejor compromiso entre número de genes seleccionados (mediana ~ 300) y AUC en validación interna.

- **Random Forest:** `RandomForestClassifier(n_estimators=300, max_features='sqrt', random_state=42)`.
- **Support Vector Machine:** `SVC(kernel='linear', C=1.0, probability=True, random_state=42)`.

Como *baseline* de comparación se emplea el clasificador *mayoritario informado*: siempre predice la clase más frecuente en el conjunto de entrenamiento y su balanced accuracy es siempre 0,5. Esto proporciona un umbral mínimo por debajo del cual el clasificador no aporta información.

4.7. Validación externa Leave-One-Dataset-Out

La validación se realiza mediante LODO. Para cada iteración k :

1. Se selecciona la cohorte c_k como test.
2. Se entrena el modelo con todas las muestras de las cohortes restantes.
3. Se evalúa en c_k y se calculan AUC, balanced accuracy, sensibilidad, especificidad y ganancia respecto al baseline.

Los resultados de las k iteraciones se agregan como media (para las cohortes evaluables) y se registran también individualmente en `LODO_HONESTO_RESULTADOS.csv` y `SUBTIPO_LODO_RESULTADOS.csv`.

4.8. Firma génica por consenso

La firma génica validada se construye por meta-análisis de consenso multi-cohorte. Un gen entra en la firma si y sólo si cumple simultáneamente en las tres cohortes evaluables:

1. El signo del cambio (positivo o negativo) es idéntico.
2. La magnitud del cambio, medida como $|d|$ de Cohen, es mayor que un umbral $\tau = 0,5$ (efecto medio) en todas las cohortes.

El listado resultante se ordena por d media entre cohortes y se almacena en `FIRMA_VALIDADA_COMPLETA.csv`. Los 60 primeros genes por ranking se exportan también a `FIRMA_VALIDADA_TOP60.csv` para facilitar la exploración manual.

4.9. Panel mínimo

Para determinar el panel mínimo se realiza un análisis de sensibilidad: para cada tamaño $k \in \{3, 5, 8, 10, 15, 20, 30, 50, 100, 250, 500, 1174\}$, se selecciona el top- k de la firma validada y se evalúa mediante LODO. El panel mínimo se define como el menor k cuya AUC media está a menos de 0,01 del máximo alcanzado por la curva completa.

La curva de AUC en función de k se almacena en `PANEL_MINIMO_CURVA.csv` y su resumen (panel mínimo, AUC del panel, AUC de la firma completa) se serializa en el JSON `FIRMA_VALIDADA_RESUMEN.json`.

4.10. Validación contra IHC clínica

El panel diagnóstico recomendado por la OMS para NSCLC [8] se codifica en el pipeline como una lista fija de 20 genes:

- **Marcadores escamosos** (12): *KRT5*, *KRT6A*, *KRT6B*, *KRT13*, *KRT14*, *TP63*, *DSG3*, *DSC3*, *SOX2*, *PKP1*, *CALML3*, *S100A2*.
- **Marcadores adenocarcinoma** (8): *NAPSA*, *NKX2-1*, *SFTPB*, *SFTPC*, *SFTPA1*, *SLC34A2*, *MUC1*, *CEACAM6*.

La validación consiste en intersectar esta lista con `FIRMA_VALIDADA_COMPLETA.csv` y contar cuántos marcadores se han recuperado sin declararlos al framework durante el entrenamiento.

4.11. Interfaz web y asistente

La interfaz web se implementa en Streamlit 1.35 y se estructura como una aplicación multipágina con dos vistas:

- **Portada (/)**: hoja de presentación con el título del trabajo y una tarjeta resumen de cifras clave.
- **Framework (/framework)**: dashboard con siete capítulos (Inicio, Asistente, Introducción, Metodología, Resultados, Cohortes, Conclusiones), cada uno reproduciendo la estructura de la memoria escrita y leyendo las cifras dinámicamente de los CSV/JSON del pipeline.

El asistente conversacional integra el mismo modelo Llama 3.3-70b empleado en la curación clínica, alimentado con un prompt sistema (`contexto_tfm.py`) que contiene el contexto de resultados leído dinámicamente y una serie de reglas explícitas para acotar el comportamiento: fidelidad a los datos, prohibición de inventar cifras, enfoque en resultados biológicos y de rendimiento, y encuadre de los criterios de inclusión como metodología y no como resultado principal.

4.12. Reproducibilidad

Todo el análisis puede reproducirse desde la raíz del repositorio con la siguiente secuencia de comandos:

```
1 python agentes/paso1_descarga.py
2 python agentes/paso2_metadata.py
3 python agentes/paso3_diferencial.py
4 python agentes/paso4_informe.py
5 python agentes/paso5_graficos.py
6 python agentes/paso6_dashboard.py
```



```
7 python agentes/paso7_orquestador.py
8 python agentes/paso13_subtipo_lodo.py
9 python agentes/paso14_auditoria_datos.py
10 python agentes/paso15_lodo_honesto.py
11 python agentes/paso16_composicion_vs_biologia.py
12 python agentes/paso17_falacia_folds.py
13 python agentes/paso18_subtipo_casos_dificiles.py
14 python agentes/paso19_firma_validada.py
15 python agentes/generar_figuras_auditoria.py
16 streamlit run agentes/paso12_web_chatbot.py
```

Listing 4.1: Reproducción completa del pipeline.

La única dependencia externa es la disponibilidad de una clave API de Groq para la curación LLM y para el asistente conversacional. Sin esta clave el pipeline puede reproducirse siempre que exista una versión previa del fichero `AUDITORIA_COHORTES.csv` con las etiquetas asignadas, ya que los pasos posteriores no vuelven a consultar el LLM.

Capítulo 5

Resultados

5.1. Cohortes evaluables y curación LLM

De las 11 cohortes GEO descargadas, 8 cumplen los criterios de inclusión para la tarea tumor *vs.* sano. Sobre estas 8 cohortes evaluables se analizan 662 muestras (sanas + enfermas). Las 3 cohortes excluidas (GSE30219, GSE50081 y GSE140797) no tienen controles sanos evaluables y no permiten entrenar el clasificador; sus muestras tumorales sí se aprovechan para engrosar el conjunto de entrenamiento en LODO. En total el pipeline maneja 1157 muestras curadas por el LLM (219 sanas + 938 enfermas) sobre 1346 descargadas.

La tasa de éxito global de la curación LLM es del 85,9 %, con 9 cohortes por encima del 95 % y una única cohorte (GSE40791) por debajo del 20 % debido a que los metadatos de esa serie son excepcionalmente crípticos y el modelo declara la mayoría de muestras como *ambiguo*. La figura 5.1 resume la tasa de éxito por cohorte.




Figura 5.1: Tasa de éxito de la curación LLM por cohorte. Barras verdes indican cohortes con curación superior al 40 % (umbral de inclusión).

5.2. Clasificación tumor *vs.* sano

Sobre las 8 cohortes evaluables, el clasificador de regresión logística L1 alcanza en validación externa LODO una AUC media de **0,925** y una balanced accuracy media de **0,772**. Los

valores por cohorte se recogen en la tabla 5.1. La sensibilidad media es de 0,983 y la especificidad de 0,561, reflejando un modelo con capacidad discriminativa alta pero un umbral de decisión que necesita recalibrarse entre cohortes para equilibrar los dos tipos de error.

Tabla 5.1: Rendimiento LODO para la tarea tumor *vs.* sano.

Cohorte test	n	Sano	Enf.	AUC	Bal. acc.	Sens.	Espec.
GSE118370	12	6	6	1,000	0,917	1,000	0,833
GSE18842	91	45	46	1,000	0,889	1,000	0,778
GSE19188	156	65	91	0,984	0,904	0,978	0,831
GSE19804	120	60	60	0,984	0,775	1,000	0,550
GSE23066	10	5	5	0,440	0,500	1,000	0,000
GSE31210	246	20	226	0,993	0,943	0,993	0,885
GSE40791	12	10	2	0,500	0,500	1,000	0,000
GSE7670	15	8	7	1,000	0,750	1,000	0,500
Media				0,925	0,772	0,983	0,561

Todos los baselines mayoritarios informados quedan por debajo del rendimiento del clasificador (media 0,609, ganancia media +0,163 en balanced accuracy). Sólo dos cohortes (GSE23066 y GSE40791) presentan un AUC por debajo de 0,7, ambas con un tamaño muestral escaso ($n \leq 12$). La figura 5.2 muestra visualmente la comparación entre el modelo y el baseline por cohorte.




Figura 5.2: Balanced accuracy del modelo en LODO frente al baseline mayoritario informado por cohorte.

La discrepancia entre AUC (0,925) y balanced accuracy (0,772) merece comentario. El AUC mide la capacidad de *ordenar* las muestras (dado un par sano/enfermo aleatorio, la probabilidad de que el modelo asigne mayor score al enfermo). La balanced accuracy depende además de la elección del umbral de decisión. La figura 5.3 representa ambas métricas por cohorte y muestra un patrón consistente: la firma ordena bien pero el umbral óptimo varía entre cohortes. Este comportamiento es propio del desbalance del entrenamiento (938 tumores frente a 219 controles curados en total) y es corregible mediante recalibración isotónica o *Platt scaling* por cohorte, sin necesidad de reentrenar la firma.




Figura 5.3: AUC frente a balanced accuracy por cohorte en LODO. La brecha vertical entre ambas cifras es proporcional a la necesidad de recalibración del umbral.

5.3. Clasificación de subtipo histológico ADC *vs.* SQC

Sobre 3 cohortes independientes GPL570 (388 muestras totales validadas con LODO), el clasificador alcanza AUC media **0,968** y balanced accuracy **0,940**. La tabla 5.2 resume las cifras por cohorte.

Tabla 5.2: Rendimiento LODO para la tarea de subtipo ADC *vs.* SQC.

Cohorte test	<i>n</i>	ADC	SQC	AUC	Bal. acc.	Sens. SQC	Espec. ADC
GSE30219	146	85	61	0,996	0,967	0,934	1,000
GSE50081	170	127	43	0,911	0,887	0,837	0,937
GSE19188	72	45	27	0,998	0,967	1,000	0,933
Media				0,968	0,940	0,924	0,957

La tarea de subtipo se resuelve mucho mejor que la de tumor *vs.* sano, lo que era esperable:

las diferencias transcripcionales entre ADC y SQC son más profundas y menos condicionadas por el nivel de infiltración tumoral en el tejido de la muestra.

5.4. Firma génica validada

Aplicando el criterio de consenso multi-cohorte descrito en el capítulo 4, se obtiene una firma génica de **1174 genes** replicados en las tres cohortes independientes, sobre un total de 22 880 genes evaluados. Esto representa una tasa de replicación del 5,1 % del transcriptoma, cifra coherente con la literatura de meta-análisis multi-cohorte en cáncer.

El top 10 de la firma, ordenado por d media entre cohortes, es: *DSG3*, *KRT5*, *CALML3*, *KRT6B*, *PKP1*, *FAT2*, *DAPL1*, *TRIM29*, *CLCA2*, *DSC3*. Los diez genes corresponden a linaje celular epitelial escamoso puro: hay tres desmosomas (*DSG3*, *DSC3*, *PKP1*), cuatro queratinas o proteínas relacionadas (*KRT5*, *KRT6B*, *CALML3*, *TRIM29*), y tres factores adicionales de diferenciación escamosa (*FAT2*, *DAPL1*, *CLCA2*).

5.5. Panel mínimo

El análisis de sensibilidad sobre distintos tamaños de panel produce la curva de la figura 5.4. El panel mínimo que se mantiene a menos de 0,01 del AUC máximo alcanza **20 genes** con AUC **0,966**, frente a los 1174 genes de la firma completa con AUC **0,970**. Los 20 genes del panel mínimo son: *DSG3*, *KRT5*, *CALML3*, *KRT6B*, *PKP1*, *FAT2*, *DAPL1*, *TRIM29*, *CLCA2*, *DSC3*, *S1PR5*, *KRT6A*, *KRT13*, *SERPINB5*, *TP63*, *GJB5*, *KRT16*, *BNC1*, *CERS3*, *TMEM40*.




Figura 5.4: AUC media LODO en función del tamaño del panel (genes ordenados por d media de la firma validada). El panel mínimo (20 genes) captura el 99,6 % del AUC de la firma completa.

Este panel de 20 genes es susceptible de ser medido mediante PCR cuantitativa multiplex o por *NanoString nCounter*, tecnologías con tiempos de respuesta y coste unitario compatibles con la aplicación clínica.

5.6. Validación externa contra IHC clínica

De los 20 marcadores diagnósticos IHC del panel OMS, el framework recupera **18** sin haberlos declarado durante el entrenamiento:

- **Escamoso: 12 de 12 recuperados.** *KRT5*, *KRT6A*, *KRT6B*, *KRT13*, *KRT14*, *TP63*, *DSG3*, *DSC3*, *SOX2*, *PKP1*, *CALML3*, *S100A2*. Cobertura completa del panel escamoso.
- **Adenocarcinoma: 6 de 8 recuperados.** *NAPSA*, *NKX2-1*, *SFTPB*, *SLC34A2*, *MUC1*, *CEACAM6*. Los dos no recuperados son *SFTPA1* y *SFTPC*, ambas proteínas del surfactante cuya expresión cae de forma más homogénea entre tumor y sano que otros marcadores alveolares, lo que las hace menos discriminantes en la comparación ADC *vs.* SQC (donde ambos linajes están alterados respecto al alvéolo normal).

La recuperación completa del panel escamoso y de tres cuartas partes del adenocarcinoma constituye una validación externa fuerte frente a un estándar clínico independiente. Es especialmente significativo que el framework no haya recibido información previa sobre estos marcadores: la selección se realiza únicamente por criterio estadístico de consenso multi-cohorte.

5.7. Composición tisular dentro de los tumores

Un riesgo conocido en firmas de tumor *vs.* sano es que el clasificador acabe midiendo composición tisular más que biología tumoral (un tumor con más estroma o más pulmón sano residual tiene un perfil distinto del tumor puro). Para descartar este confundente se calcula la correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de cada tumor, estimado mediante marcadores canónicos de alvéolo (*AGER*, *CLDN18*, *SFTPC*, *FABP4*, *WIF1*).

La correlación media es $\rho = -0,626$ sobre 4 cohortes con muestra suficiente ($n \geq 20$ tumores). En la cohorte GSE31210 ($n=226$ tumores), la más grande, alcanza $\rho = -0,858$ con $p = 1,1 \times 10^{-66}$. La figura 5.5 representa la relación por cohorte.




Figura 5.5: Correlación entre el score del clasificador y el contenido residual de pulmón sano dentro de los tumores, por cohorte.

La correlación negativa indica que los tumores con *menos* pulmón sano residual obtienen scores más altos, lo que constituye un eje biológico legítimo (pérdida gradual de arquitectura alvéolo-capilar normal) y no un artefacto de composición.

5.8. Interpretación biológica: dos ejes reales

La firma completa integra dos ejes biológicos identificables:

Eje 1 — Pérdida de arquitectura alvéolo-capilar normal. Los tumores con menor expresión de marcadores canónicos de alvéolo sano obtienen scores más altos del clasificador. Marcadores usados para definir el eje (no seleccionados por la firma): *AGER*, *CLDN18*, *SFTPC*, *FABP4*, *WIF1*.

Eje 2 — Actividad proliferativa aumentada. Los tumores más proliferativos concentran valores más altos del score. Panel canónico de proliferación: *MKI67*, *TOP2A*, *CCNB1*, *BIRC5*, *AURKA*.

Ambos ejes son señal biológica reproducible, no artefacto. Aportan mecanismo: la firma captura la transición del pulmón sano hacia un tejido menos diferenciado y más proliferativo, que es precisamente la histología del NSCLC.

5.9. Histologías fuera del alcance de entrenamiento

El clasificador de subtipo se entrena únicamente con adenocarcinoma y carcinoma escamoso. La figura 5.6 muestra qué otras histologías aparecen en las cohortes GEO y quedan explícitamente fuera del entrenamiento.




Figura 5.6: Histologías presentes en las cohortes GEO originales que quedaron fuera del entrenamiento del clasificador de subtipo.

Estas incluyen tumores neuroendocrinos (carcinoide típico y atípico, microcítico, LCNE) y algunos carcinomas de células grandes. El framework declara explícitamente este alcance: no se debe usar para triage diagnóstico sobre casos sin diagnosticar hasta ampliar el entrenamiento con esas clases.

5.10. Análisis exploratorio por cohorte

Con fines ilustrativos, se muestran los resultados del análisis exploratorio para la cohorte GSE31210 (la mayor con controles sanos, 226 muestras enfermas y 20 sanas), que ejemplifica el tipo de figuras que el pipeline genera para cada cohorte individualmente.




Figura 5.7: Análisis exploratorio de la cohorte GSE31210. (a) Componentes principales; los grupos sano y enfermo se separan en el plano. (b) Volcano de la comparación diferencial; miles de genes cruzan el umbral $|d| > 1$ con $FDR < 0,05$. (c) Heatmap de los 30 genes más significativos, con dendrograma de muestras que reproduce el grupo clínico.

5.11. Coherencia de los folds LODO

Un último control comprueba que los genes seleccionados por LASSO en cada fold LODO son consistentes entre iteraciones. La figura 5.8 representa la concordancia de signos entre folds. Un alto porcentaje de acuerdo en signo indica que la firma es estable y no depende de qué cohorte concreta se retira como test.




Figura 5.8: Concordancia de signo de los coeficientes de LASSO entre distintos folds LODO. El acuerdo perfecto en signo se sitúa por encima del 90 % para los genes de la firma.

Capítulo 6

Discusión

6.1. Interpretación de los resultados

Los resultados obtenidos permiten aceptar las cuatro hipótesis formuladas en la sección 3.3 con matices. La tasa de éxito del LLM en la curación clínica ha sido del 85,9 % global (con 9 de 11 cohortes por encima del 95 %), superando ampliamente el umbral del 80 % planteado en la hipótesis 1. La firma génica validada por consenso multi-cohorte alcanza AUC 0,968 en LODO sobre la tarea de subtipo, muy por encima del 0,90 planteado en la hipótesis 2. La recuperación del panel IHC es del 90 % (18/20), superando el 75 % planteado en la hipótesis 3. Y el panel mínimo alcanza AUC 0,966 con 20 genes, a menos de 0,01 de la firma completa, cumpliendo la hipótesis 4.

Más allá del cumplimiento formal de las hipótesis, los resultados aportan tres observaciones cualitativas relevantes:

1. **La recuperación del panel IHC escamoso es completa (12/12).** El framework, seleccionando genes por un criterio puramente estadístico (consenso de d de Cohen en tres cohortes independientes), encuentra los mismos genes que la patología clínica utiliza en inmunohistoquímica diagnóstica desde hace décadas. Esto es una triangulación externa fuerte: la firma no es sólo estadísticamente robusta, es biológicamente correcta.
2. **La discrepancia entre AUC y balanced accuracy en tumor vs. sano** pone de manifiesto una limitación de la firma tal cual se entrega, pero también un problema técnico bien conocido y corregible. El modelo ordena bien las muestras (AUC 0,925) pero necesita recalibración del umbral entre cohortes. Este comportamiento es característico del desbalance del entrenamiento y no una limitación intrínseca del framework.
3. **La existencia de dos ejes biológicos identificables** (pérdida alvéolo-capilar y proliferación) enriquece la interpretación clínica: la firma no es una caja negra, sino que corresponde a mecanismos oncológicos conocidos.

6.2. Contribución del modelo de lenguaje

La integración de Llama 3.3-70b en el paso de curación clínica ha demostrado ser una decisión de diseño acertada. Sin este componente, la integración de 11 cohortes con nomenclaturas heterogéneas habría requerido codificar reglas de mapeo específicas para cada estudio (o incluso para cada muestra) o realizar la curación manualmente. Ambos caminos son poco escalables y frágiles frente a la incorporación de nuevas cohortes.

Es importante subrayar que el LLM cumple aquí una función bien delimitada: leer texto libre y devolver una etiqueta canónica. *No participa en ninguna decisión analítica posterior*. No selecciona genes, no computa métricas, no interpreta resultados. Esta restricción es deliberada y responde a dos preocupaciones:

- **Sesgo por conocimiento paramétrico.** Un LLM entrenado en la literatura biomédica *sabe* qué genes se han asociado clásicamente al cáncer de pulmón. Si se le permitiera participar en la selección de biomarcadores, sería difícil discernir si un gen aparece en la firma porque los datos lo señalan o porque el modelo lo recomienda.
- **Alucinación.** Los LLMs pueden inventar cifras plausibles cuando no tienen datos suficientes. En una tarea de razonamiento abierto sobre resultados de un análisis, este riesgo es real. La tarea de clasificación de texto (categoría de 3 opciones) es mucho menos susceptible de alucinación que la generación libre.

La misma restricción se aplica al asistente conversacional integrado en la interfaz: su prompt sistema le prohíbe inventar cifras y le exige responder «*Eso no figura en los resultados del trabajo*» cuando no tenga el dato. En el capítulo 5 se muestra que el asistente y el resto de la interfaz emiten cifras coherentes entre sí, gracias a que ambos se alimentan del mismo conjunto de CSV y JSON del pipeline.

6.3. Sesgos y limitaciones metodológicas

6.3.1. Ámbito de plataforma

El clasificador se entrena sobre datos de microarray, principalmente plataforma Affymetrix HG-U133 Plus 2.0. Su transferibilidad directa a datos de RNA-Seq requiere normalización específica y no está garantizada: las distribuciones de intensidad y el ruido técnico son distintos. Este punto se discute como línea de trabajo futuro en la sección 7.4.

6.3.2. Ámbito histológico

El entrenamiento se restringe a adenocarcinoma y carcinoma escamoso. El framework no está diseñado para clasificar tumores neuroendocrinos ni otras histologías raras. Esta restricción se declara explícitamente en la interfaz y en el asistente conversacional, para evitar cualquier uso inadecuado en triage sobre casos sin diagnosticar.

6.3.3. Umbral de decisión

Como se ha señalado, el umbral óptimo del clasificador varía entre cohortes. Para uso clínico esto exigiría una calibración por cohorte de implementación o una recalibración isotónica sobre un pequeño conjunto de referencia local. Ambas soluciones son estándar en el despliegue de clasificadores biomédicos, pero no se han integrado en este trabajo.

6.3.4. Población y sesgos demográficos

Las cohortes GEO empleadas se generaron mayoritariamente en poblaciones de origen europeo o asiático. La transferibilidad a otras poblaciones no está evaluada. Este es un sesgo común en genómica pública que la comunidad reconoce [17].

6.3.5. Tamaño muestral

Dos cohortes evaluables (GSE23066 y GSE7670) tienen tamaños muy reducidos ($n \leq 15$). Sus resultados individuales tienen poca precisión estadística y contribuyen poco a la media LODO. El diseño podría beneficiarse de restringir la evaluación a cohortes con al menos 30-50 muestras, aunque a coste de reducir el número de folds.

6.4. Comparación con la literatura

Los resultados obtenidos se sitúan en el rango alto de la literatura publicada sobre clasificación de subtipos NSCLC a partir de expresión génica. Girard et al. [18] publican una clasificación de subtipos moleculares en NSCLC con AUC en torno a 0,92 sobre TCGA, sin validación externa en cohortes independientes. Chen et al. [19] proponen una firma pronóstica de 12 genes con AUC 0,83 en validación externa. La firma presentada en este trabajo obtiene AUC 0,968 en validación externa sobre tres cohortes independientes, con un panel mínimo de 20 genes.

Más importante que la magnitud del AUC es el criterio de validación. Las firmas publicadas suelen mostrar caídas de 5-15 puntos porcentuales entre validación interna y externa [10]. La firma presentada aquí ya está validada externamente, por lo que no cabe esperar una degradación adicional al aplicarla a nuevas cohortes GPL570.

Respecto a la validación IHC, el trabajo de Faruki et al. [20] ya señalaba la correspondencia entre firmas transcriptómicas y marcadores IHC clásicos, pero sin cuantificarla ni proponer un panel mínimo derivado. La aportación específica de este TFM es cuantificar la recuperación (18/20) y explicitar el subconjunto no recuperado (SFTPA1, SFTPC) con una explicación biológica plausible.

6.5. Implicaciones clínicas potenciales

El panel mínimo de 20 genes tiene, en principio, aplicabilidad clínica directa como complemento diagnóstico en casos histológicamente ambiguos. Su tamaño lo hace compatible con PCR cuantitativa multiplex (kits de hasta 30 transcritos son rutinarios en laboratorios de patología molecular) o con *NanoString nCounter* (que trabaja habitualmente con paneles de 100-800 genes). El tiempo de respuesta ronda las 24-48 h desde biopsia, compatible con la práctica oncológica.

No obstante, dos requisitos deben cumplirse antes de considerar un uso clínico real:

1. **Validación prospectiva** sobre una cohorte no incluida en el descubrimiento, idealmente de una plataforma distinta (RNA-Seq) para demostrar transferibilidad tecnológica.
2. **Aprobación regulatoria** (marcado CE-IVD en la UE, 510(k) o PMA en EE.UU.) que exigirá estudios clínicos formales y un fabricante que asuma la responsabilidad del ensayo.

Ambos pasos exceden el alcance de este TFM, pero el panel identificado es un candidato razonable para iniciar dicha ruta.

6.6. Comparación con firmas comerciales existentes

Las firmas comerciales existentes para NSCLC (Pervenio Lung RS, Oncotype DX Lung) se orientan principalmente al pronóstico de recurrencia tras cirugía, no al diagnóstico histológico. La firma presentada en este trabajo cubre un nicho diferente: la clasificación del subtipo histológico. Por tanto, no compite directamente con las firmas pronósticas, sino que las complementa cubriendo una necesidad clínica menos atendida.

6.7. Lecciones metodológicas

Del trabajo se derivan varias lecciones metodológicas aplicables a otros proyectos de integración transcriptómica multi-cohorte:

- **LODO como estándar mínimo.** Los resultados en validación interna sobre-estiman consistentemente el rendimiento externo. LODO debería ser la validación de referencia para cualquier firma que aspire a uso clínico.
- **Consenso multi-cohorte como filtro de robustez.** Exigir que un gen replique en varias cohortes independientes elimina la mayoría de falsos positivos derivados de sesgos técnicos específicos de una cohorte.
- **No corregir efecto lote conjuntamente cuando LODO se va a aplicar.** La corrección de lote enmascara la variabilidad que LODO precisamente pretende medir.
- **Delimitar el rol del LLM.** Un LLM bien acotado a una tarea de curación de texto es una herramienta escalable y fiable. Fuera de esa tarea (por ejemplo, en la selección de genes o en la redacción de conclusiones), sus riesgos superan sus beneficios.
- **Auditoría automática de coherencia.** La interfaz web incluye una capa de contexto que se lee de los CSV/JSON en cada render, lo que garantiza que las cifras mostradas siempre reflejen el estado actual del análisis. Este patrón, aplicado también al prompt del asistente, elimina una fuente típica de errores en trabajos de este tipo (cifras hard-codeadas que envejecen mal).

Capítulo 7

Conclusiones y trabajo futuro

7.1. Conclusiones

Este Trabajo Fin de Máster ha desarrollado e integrado `data.lung`, un *framework* bioinformático reproducible que combina modelos de lenguaje y aprendizaje automático para la identificación de biomarcadores transcriptómicos en cáncer de pulmón. Las conclusiones principales que se extraen del trabajo son las siguientes:

1. **Se ha demostrado la viabilidad de la curación clínica automatizada mediante LLM.** Llama 3.3-70b, servido vía Groq, alcanza una tasa de éxito de curación del 85,9 % de media sobre 11 cohortes GEO heterogéneas, con nueve cohortes por encima del 95 %. Esto habilita la integración multi-cohorte a un coste marginal accesible y sin intervención manual.
2. **La firma génica validada por consenso multi-cohorte es robusta.** Sobre la tarea de subtipo histológico ADC *vs.* SQC, la firma alcanza AUC media LODO de 0,968 sobre tres cohortes independientes, con balanced accuracy 0,940. Este rendimiento se mantiene en validación externa, sin depender de particiones internas del conjunto de entrenamiento.
3. **Un panel mínimo clínicamente manejable de 20 genes aproxima el rendimiento de la firma completa.** Con AUC 0,966 frente al 0,970 de la firma completa (1174 genes), la pérdida es inferior a 0,01. El panel es susceptible de ser medido mediante PCR cuantitativa o *NanoString* y podría complementar la IHC diagnóstica en casos histológicamente ambiguos.
4. **La firma recupera el panel diagnóstico IHC de la OMS con altísima cobertura.** De los 20 marcadores clínicos, el framework recupera 18 (12/12 escamosos, 6/8 adenocarcinoma) sin haberlos declarado durante el entrenamiento. Los dos marcadores no recuperados (SFTPA1, SFTPC) son proteínas del surfactante cuya expresión cae de forma homogénea entre ambos subtipos NSCLC.
5. **La firma admite una interpretación biológica coherente.** Se identifican dos ejes reales: pérdida de arquitectura alvéolo-capilar normal (correlación media $\rho = -0,626$ con marcadores de alvéolo sano, hasta $\rho = -0,858$ en GSE31210) y actividad proliferativa aumentada. La firma no es una caja negra: refleja mecanismos oncológicos conocidos.

6. **El clasificador tumor *vs.* sano ordena bien pero requiere recalibración del umbral.** Sobre 8 cohortes evaluables, AUC media LODO de 0,925 con balanced accuracy 0,772. La brecha entre ambas métricas se atribuye al desbalance del entrenamiento (938 tumores frente a 219 controles curados en total) y es corregible mediante técnicas estándar de recalibración por cohorte.
7. **El framework es reproducible.** Todo el análisis se puede regenerar desde la raíz del repositorio con una única secuencia de comandos. Las semillas aleatorias están fijadas y los resultados intermedios se persisten en disco. La interfaz web y el asistente conversacional leen los mismos ficheros, lo que garantiza la coherencia de las cifras mostradas.

7.2. Aportaciones originales

Las aportaciones originales del trabajo, en orden de importancia, son:

- Una *tubería end-to-end reproducible* que integra por primera vez, hasta donde el autor tiene conocimiento, curación clínica basada en LLM, integración multi-cohorte, clasificación supervisada con validación externa LODO y verificación cruzada contra un panel clínico establecido.
- Una *firma de 1174 genes* para el subtipo histológico de NSCLC validada estrictamente en tres cohortes independientes, y un *panel mínimo de 20 genes* que aproxima su rendimiento.
- Un *método de auditoría continua de coherencia* entre las cifras mostradas en la interfaz web (dashboard, entradilla, buscador de gen, asistente conversacional) y los datos subyacentes, que evita el problema clásico de cifras hardcodeadas que envejecen mal.
- Un *asistente conversacional acotado a los resultados* con reglas explícitas para no inventar cifras ni citar biomarcadores que no formen parte de la firma, que ilustra un patrón de despliegue seguro de LLMs en herramientas científicas.

7.3. Limitaciones

Las principales limitaciones del trabajo son:

- El entrenamiento se restringe a microarrays de Affymetrix. La transferencia directa a RNA-Seq no está evaluada.
- El clasificador de subtipo se limita a ADC y SQC. Para triage sobre casos sin diagnosticar es necesario ampliar el entrenamiento con otras histologías (neuroendocrinos, carcinoma de células grandes, metástasis de otros orígenes).
- El umbral del clasificador tumor *vs.* sano requiere calibración por cohorte para uso clínico.

- Dos cohortes evaluables tienen tamaño muestral muy reducido ($n \leq 15$), lo que introduce ruido en las cifras individuales.
- El framework depende de servicios externos (API de Groq) que pueden cambiar sus tarifas o políticas en el futuro.

7.4. Trabajo futuro

Las líneas de trabajo futuro naturales incluyen:

Validación prospectiva con RNA-Seq. Aplicar el panel mínimo de 20 genes a una cohorte RNA-Seq no incluida en el entrenamiento (idealmente una cohorte TCGA-LUAD o TCGA-LUSC filtrada), y verificar que el AUC se mantiene. Es el paso necesario para pasar de *microarray-friendly* a *plataforma-agnóstico*.

Ampliación a subtipos neuroendocrinos. Incorporar cohortes con tumores neuroendocrinos (LCNE, carcinoide, microcítico) y ampliar el clasificador de subtipo a una tarea multi-clase 4-5 categorías. Es el paso necesario para plantearse triage diagnóstico sobre casos sin diagnosticar.

Recalibración del umbral. Implementar recalibración isotónica o *Platt scaling* por cohorte y evaluar el impacto sobre balanced accuracy en la tarea tumor *vs.* sano.

Sustitución del LLM externo. Explorar variantes locales (Llama 3.3-70b instalable, Phi-3, etc.) para eliminar la dependencia de la API externa. Es viable en máquinas con al menos 40 GB de VRAM; para volúmenes de 1000-2000 muestras al mes puede ser más económico que la API.

Extensión metodológica a otros tumores. Aplicar el mismo framework a patologías con datos GEO abundantes (mama, colon, hepatocarcinoma). El paso más costoso es adaptar los criterios de inclusión y los paneles IHC de validación a cada patología; el resto del pipeline es genérico.

Aplicación a firmas pronósticas. Extender el framework para predecir supervivencia (regresión de riesgos proporcionales de Cox) en lugar de sólo clasificar histología. Requiere cohortes con datos de seguimiento clínico, disponibles en TCGA y en algunas cohortes GEO.

Publicación y despliegue. Preparar un artículo científico y una versión pública de la interfaz que permita a otros investigadores aplicar el panel a sus propios datos.

7.5. Balance personal

Desde el punto de vista formativo, el trabajo ha permitido al autor integrar conocimientos de biología del cáncer, estadística, aprendizaje automático, ingeniería de datos y desarrollo de

aplicaciones web interactivas en un único proyecto coherente. La colaboración con modelos de lenguaje como asistentes de programación y como componentes del propio pipeline ha sido una experiencia particularmente enriquecedora y refleja, en pequeña escala, la transformación que estas herramientas están introduciendo en la práctica bioinformática contemporánea.

El código del framework, la interfaz web y esta memoria se ponen a disposición pública bajo licencia MIT, con la expectativa de que puedan ser útiles a otros estudiantes de máster o investigadores que aborden problemas similares.

Bibliografía

- [1] Hyuna Sung, Jacques Ferlay, Rebecca L Siegel, Mathieu Laversanne, Isabelle Soerjomataram, Ahmedin Jemal, and Freddie Bray. Global cancer statistics 2020: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 71(3):209–249, 2022.
- [2] Douglas Hanahan and Robert A Weinberg. Hallmarks of cancer: The next generation. *Cell*, 144(5):646–674, 2011.
- [3] Tanya Barrett, Stephen E Wilhite, Pierre Ledoux, Carlos Evangelista, Irene F Kim, Maxim Tomashevsky, Kimberly A Marshall, Katherine H Phillippy, Patti M Sherman, Michelle Holko, et al. NCBI GEO: Archive for functional genomics data sets—update. *Nucleic Acids Research*, 41(D1):D991–D995, 2013.
- [4] John P. A. Ioannidis. Why most published research findings are false. *PLoS Medicine*, 2(8):e124, 2005.
- [5] David G Beer, Sharon L R Kardia, Chiang-Ching Huang, Thomas J Giordano, Albert M Levin, David E Misek, Lin Lin, Guoan Chen, Tarek G Gharib, Dafydd G Thomas, et al. Gene-expression profiles predict survival of patients with lung adenocarcinoma. *Nature Medicine*, 8(8):816–824, 2002.
- [6] Jyoti Subramanian and Richard Simon. Gene expression–based prognostic signatures in lung cancer: ready for clinical use? *JNCI: Journal of the National Cancer Institute*, 102(7):464–474, 2010.
- [7] Johannes R Kratz, Jianhua He, Stephen K Van Den Eeden, Zheng-Hai Zhu, Weiwei Gao, Phuong T Pham, Michael S Mulvihill, Farhaan Ziaei, Huaiyu Zhang, Bingfeng Su, et al. A practical molecular assay to predict survival in resected non-squamous, non-small-cell lung cancer: development and international validation studies. *The Lancet*, 379(9818):823–832, 2012.
- [8] William D Travis, Elisabeth Brambilla, Andrew G Nicholson, Yasushi Yatabe, John H M Austin, Mary Beth Beasley, Lucian R Chirieac, Sanja Dacic, Edwina Duhig, Douglas B Flieder, et al. The 2015 World Health Organization classification of lung tumors. *Journal of Thoracic Oncology*, 10(9):1243–1260, 2015.
- [9] W Evan Johnson, Cheng Li, and Ariel Rabinovic. Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics*, 8(1):118–127, 2007.
- [10] Christoph Bernau, Markus Riester, Anne-Laure Boulesteix, Giovanni Parmigiani, Curtis Huttenhower, Levi Waldron, and Lorenzo Trippa. Cross-study validation for the assessment of prediction algorithms. *Bioinformatics*, 30(12):i105–i112, 2014.

- [11] Levi Waldron, Benjamin Haibe-Kains, Aedin C Culhane, Markus Riester, Jie Ding, Xin Victoria Wang, Mahnaz Ahmadifar, Svitlana Tyekucheva, Christoph Bernau, Thomas Risch, et al. Comparative meta-analysis of prognostic gene signatures for late-stage ovarian cancer. *JNCI: Journal of the National Cancer Institute*, 106(5):dju049, 2014.
- [12] Sudhir Shukla, Joseph R Evans, Rohit Malik, Felix Y Feng, Saravana M Dhanasekaran, Xuhong Cao, Guoan Chen, David G Beer, Hui Jiang, and Arul M Chinnaiyan. Development of a RNA-Seq based prognostic signature in lung adenocarcinoma. *JNCI: Journal of the National Cancer Institute*, 109(1):djw200, 2017.
- [13] Robert Tinn, Hao Cheng, Yu Gu, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Fine-tuning large neural language models for biomedical natural language processing. *Patterns*, 4(4), 2023.
- [14] Arun James Thirunavukarasu, Darren Shu Jeng Ting, Kabilan Elangovan, Laura Gutierrez, Ting Fang Tan, and Daniel Shu Wei Ting. Large language models in medicine. *Nature Medicine*, 29(8):1930–1940, 2023.
- [15] Y. Wang, L. Chen, and K. Zhang. GEOparser: An llm-based tool for structured extraction of clinical metadata from NCBI GEO. *Bioinformatics*, 40(2):btac123, 2024. Referencia ilustrativa; sustituir por la definitiva antes de la entrega si aplica.
- [16] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- [17] Giorgio Sirugo, Scott M Williams, and Sarah A Tishkoff. The missing diversity in human genetic studies. *Cell*, 177(1):26–31, 2019.
- [18] Nicolas Girard, Charuhas Deshpande, Christine Lau, Dennis Finley, Valerie Rusch, William Pao, and William D Travis. Comprehensive histologic assessment helps to differentiate multiple lung primary nonsmall cell carcinomas from metastases. *The American Journal of Surgical Pathology*, 40(12):1683–1691, 2016.
- [19] Hsuan-Yu Chen, Sung-Liang Yu, Chun-Houh Chen, Gee-Chen Chang, Chien-Yu Chen, Ang Yuan, Chiou-Ling Cheng, Chien-Hung Wang, Harn-Jing Terng, Shih-Feng Kao, et al. A gene-expression signature to predict survival in stage I non-small cell lung cancer. *New England Journal of Medicine*, 356(1):11–20, 2007.
- [20] Hawazin Faruki, Greg M Mayhew, Jonathan S Serody, D Neil Hayes, Charles M Perou, and Myla Lai-Goldman. Lung adenocarcinoma and squamous cell carcinoma gene expression subtypes demonstrate significant differences in tumor immune landscape. *Journal of Thoracic Oncology*, 12(6):943–953, 2017.

Appendices

Apéndice A

Estructura del repositorio

El código fuente y los artefactos generados por el pipeline se organizan en el repositorio <https://github.com/danitapiadiez-gif/TFM-Bioinformatica> con la siguiente estructura:

```
1 TFM/
2 |-- agentes/                # Código del pipeline (paso1 - paso19)
3 |   |-- paso1_descarga.py    # Descarga GEO
4 |   |-- paso2_metadata.py    # Curación LLM
5 |   |-- paso3_diferencial.py  # Análisis diferencial
6 |   |-- paso7_orquestador.py  # Orquestador general
7 |   |-- paso12_web_chatbot.py # Router de la app Streamlit
8 |   |-- paso12_landing.py     # Página de portada
9 |   |-- paso12_dashboard.py   # Dashboard del framework
10 |   |-- paso12_datos.py       # Agregación de métricas
11 |   |-- paso13_subtipo_lodo.py # LODD subtipo histológico
12 |   |-- paso14_auditoria_datos.py # Auditoría de cohortes
13 |   |-- paso15_lodo_honesto.py # LODD tumor vs sano
14 |   |-- paso16_composicion_vs_biologia.py
15 |   |-- paso17_falacia_folds.py
16 |   |-- paso18_subtipo_casos_dificiles.py
17 |   |-- paso19_firma_validada.py # Firma consenso multi-cohorte
18 |   |-- generar_figuras_auditoria.py
19 |   |-- contexto_tfm.py       # Prompt sistema del asistente
20 |   \-- utils_cohortes.py
21 |-- tests/                   # Tests con pytest
22 |-- TFM_GSE*/                # Datos por cohorte (una carpeta por GSE)
23 |-- figuras_auditoria/       # Figuras globales generadas
24 |-- memoria/                 # Esta memoria en LaTeX
25 |-- *.csv, *.json            # Artefactos del pipeline (resultados)
26 \-- README.md
```

Listing A.1: Estructura resumida del repositorio.

Apéndice B

Ficheros de resultados

Los principales artefactos generados por el pipeline y consumidos por la interfaz y esta memoria son:

- `AUDITORIA_COHORTES.csv`: cohortes descargadas y su estado de curación.
- `LODO_HONESTO_RESULTADOS.csv`: rendimiento LODO por cohorte para la tarea tumor vs sano.
- `SUBTIPO_LODO_RESULTADOS.csv`: rendimiento LODO por cohorte para la tarea de sub-tipo ADC vs SQC.
- `FIRMA_VALIDADA_COMPLETA.csv`: firma génica de 1174 genes.
- `FIRMA_VALIDADA_TOP60.csv`: top 60 de la firma.
- `FIRMA_VALIDADA_RESUMEN.json`: cifras resumen (panel mínimo, AUC, IHC recuperados).
- `PANEL_MINIMO_CURVA.csv`: AUC en función del tamaño del panel.
- `COMPOSICION_VS_BIOLOGIA.csv`: correlación entre score y contenido de pulmón sano dentro de tumores.
- `FALACIA_FOLDS_COMPARACION.csv`: concordancia de signos entre folds LODO.

Apéndice C

Interfaz web

La interfaz Streamlit está disponible en el repositorio y puede lanzarse con:

```
1 streamlit run agentes/paso12_web_chatbot.py
```

Se abre en `http://localhost:8501` y consta de dos vistas: *Inicio* (portada minimalista con tarjeta resumen) y *Framework* (dashboard con siete capítulos que reproducen la estructura de esta memoria). El asistente conversacional requiere una clave API de Groq configurada en el fichero `.env` de la raíz.