

Capítulos 5 y 6 (versión revisada)

Framework transcriptómico para la auditoría de reproducibilidad
de firmas de expresión en cáncer de pulmón

Daniel Tapia Díez

Versión de trabajo generada automáticamente desde los resultados

Resumen

Documento de trabajo con los capítulos de Resultados y Discusión reescritos a partir de los análisis de los pasos 14 a 18. Todas las tablas se generan mediante `agentes/generar_tablas_latex.py` y todas las figuras mediante `agentes/generar_figuras_auditoria.py`, en ambos casos directamente desde los ficheros CSV de resultados, de modo que ningún valor numérico está transcrito a mano y una reejecución de los análisis actualiza el documento de forma consistente.

De las cinco hipótesis contrastadas, tres se confirmaron y dos no. Las dos que no se confirmaron se mantienen con el umbral fijado antes de ejecutar el análisis y se reportan como resultaron.

Índice

1. Resultados	2
1.1. Auditoría de integridad de las cohortes	2
1.2. Reevaluación de la validación LODO	3
1.2.1. Un hallazgo no previsto: discriminación sin decisión	4
1.3. Naturaleza de la señal: composición tisular frente a biología tumoral	6
1.4. Validez de la consistencia de signo como medida de reproducibilidad	8
1.5. Control positivo: clasificación de subtipo histológico	8
1.5.1. Límites del clasificador ante histologías no observadas	10
1.6. Síntesis de resultados	10
2. Discusión	13
2.1. Reorientación del objeto de estudio	13
2.2. Los cuatro modos de fallo silencioso	13
2.3. Discriminación y decisión como propiedades independientes	14
2.4. Qué mide la firma: composición, proliferación y biología	14
2.5. Implicaciones sobre el diseño de la validación externa	15
2.6. Alcance y limitaciones del control positivo	15
2.7. Recomendaciones metodológicas	16
2.8. Líneas futuras	16

1. Resultados

Este capítulo se organiza en torno a una distinción que resultó determinante: la diferencia entre *lo que un modelo consigue* y *lo que una métrica parece indicar*. Los cinco análisis que se presentan fueron especificados con su hipótesis y su umbral de decisión fijados antes de ejecutarse. Dos de las cinco hipótesis no se confirmaron, y se reportan como resultaron; mantener el criterio original en esos dos casos es parte del resultado, no una concesión.

1.1. Auditoría de integridad de las cohortes

Antes de reevaluar cualquier modelo se auditó el estado real de los datos sobre los que se construyeron los análisis. La tabla 1 resume las once cohortes con datos procesados.

Tabla 1: Auditoría de integridad de las once cohortes con datos procesados. La columna *Desalin.* indica muestras cuya etiqueta clínica corresponde a otro paciente por asignación posicional; *Eval.* indica si la cohorte contiene ambas clases y por tanto es evaluable como conjunto de test.

Cohorte	Plataforma	n	Sanas	Enfermas	Sin clas.	Curacion	Desalin.	Eval.
GSE118370	GPL570	12	6	6	0	100,0 %	OK	si
GSE140797	GPL13497	14	0	7	7	50,0 %	OK	no
GSE18842	GPL570	91	45	46	0	100,0 %	OK	si
GSE19188	GPL570	156	65	91	0	100,0 %	OK	si
GSE19804	GPL570	120	60	60	0	100,0 %	OK	si
GSE23066	GPL570	10	5	5	0	100,0 %	OK	si
GSE30219	GPL570	307	0	307	0	100,0 %	307/307	no
GSE31210	GPL570	246	20	226	0	100,0 %	OK	si
GSE40791	GPL570	194	10	2	182	6,2 %	OK	si
GSE50081	GPL570	181	0	181	0	100,0 %	OK	no
GSE7670	GPL96	66	8	7	51	22,7 %	OK	si
Total		1397	219	938	240	82,8 %	307	8/11

La auditoría reveló cuatro problemas de naturaleza distinta.

Cobertura incompleta y silenciosa. De las doce cohortes declaradas en `datasets.txt`, tres nunca llegaron a procesarse: GSE40419, GSE81089 y GSE140343, precisamente las tres basadas en RNA-seq. El fallo no generó ningún error: el pipeline continuó y produjo resultados aparentemente completos. En sentido inverso, dos cohortes presentes en los resultados (GSE118370 y GSE140797) no figuran en el fichero de declaración. La cohorte efectivamente analizada no coincide, por tanto, con la cohorte declarada.

Desalineamiento entre muestras y etiquetas clínicas. En GSE30219, las 307 columnas de la matriz de expresión están ordenadas de forma distinta a las filas del fichero de metadatos, aunque ambos contengan el mismo conjunto de muestras. Asignar las etiquetas por posición — operación habitual cuando las longitudes coinciden — adjudica a cada muestra la información clínica de otro paciente. El error afecta a la totalidad de la cohorte y no produce ninguna señal de aviso.

Su efecto práctico se cuantificó de forma directa. Al entrenar el clasificador de subtipo histológico (sección 1.5) sobre los datos desalineados, el AUC obtenido sobre esta cohorte fue de 0,56, indistinguible del azar. Con el alineamiento corregido mediante identificador de muestra, el mismo modelo y los mismos datos alcanzaron un AUC de 0,99. El desalineamiento

no degrada el resultado: lo destruye por completo, y lo hace de forma indistinguible de una ausencia genuina de señal biológica.

Fallo parcial de la curación clínica automatizada. La asignación de etiquetas mediante modelo de lenguaje funcionó de forma completa en ocho de las once cohortes, pero falló de manera severa en dos: en GSE40791 dejó sin clasificar 182 de 194 muestras (93,8 %) y en GSE7670, 51 de 66 (77,3 %). En conjunto, 240 de las 1397 muestras disponibles (17,2 %) quedaron fuera del análisis por esta vía. La figura 1 muestra la distribución por cohorte. El patrón es relevante: el fallo no es gradual sino bimodal — la curación funciona casi perfectamente o se colapsa — lo que sugiere sensibilidad al formato concreto de los metadatos más que una limitación uniforme de la capacidad del modelo.




Figura 1: Proporción de muestras a las que la curación mediante modelo de lenguaje asignó una etiqueta utilizable. El comportamiento es bimodal: éxito casi completo o colapso.

Cohortes no evaluables empleadas como conjunto de test. Tres cohortes contienen únicamente muestras tumorales y ningún control: GSE30219 (307 muestras), GSE50081 (181) y GSE140797 (7). Una cohorte de una sola clase puede formar parte legítimamente del conjunto de entrenamiento, pero no puede funcionar como conjunto de test: en ella, la estrategia trivial de predecir siempre la clase presente alcanza por definición una *accuracy* de 1,000. Cualquier valor elevado obtenido sobre estas cohortes es una consecuencia aritmética de su composición, no una medida de capacidad predictiva.

1.2. Reevaluación de la validación LODO

Se repitió la validación *Leave-One-Dataset-Out* sobre la tarea tumor frente a sano conservando deliberadamente el modelo original (regresión logística con penalización L_1 , $C = 0,5$, sin ponderación de clases). Solo se modificaron dos elementos: el alineamiento muestra-etiqueta y

el conjunto de métricas reportadas. Aislar así las variables permite atribuir cualquier diferencia observada al modo de medir, y no a un cambio de método.

La hipótesis registrada fue que el rendimiento medio descendería respecto al valor previamente reportado y que GSE31210 y GSE40791 quedarían por debajo de su propio *baseline*. La tabla 2 recoge el resultado.

Tabla 2: Validación LODO de la tarea tumor frente a sano, con el mismo modelo del análisis original (LASSO, $C = 0,5$) y el alineamiento muestra-etiqueta corregido. Se añaden el *baseline* de clase mayoritaria y la *balanced accuracy*; las tres cohortes con una sola clase se marcan como no evaluables. En negrita, las cohortes que no superan su propio *baseline*.

Cohorte test	n	Sano/Enf.	<i>Baseline</i>	Acc.	Bal. acc.	AUC	Sens.	Espec.
GSE118370	12	6/6	0,500	0,917	0,917	1,000	1,000	0,833
GSE18842	91	45/46	0,505	0,890	0,889	1,000	1,000	0,778
GSE19188	156	65/91	0,583	0,917	0,904	0,984	0,978	0,831
GSE19804	120	60/60	0,500	0,775	0,775	0,984	1,000	0,550
GSE7670	15	8/7	0,533	0,733	0,750	1,000	1,000	0,500
GSE23066	10	5/5	0,500	0,500	0,500	0,440	1,000	0,000
GSE31210	246	20/226	0,919	0,894	0,943	0,993	0,885	1,000
GSE40791	12	10/2	0,833	0,167	0,500	1,000	1,000	0,000
GSE50081	181	0/181	1,000	0,967	<i>no evaluable: una sola clase</i>			
GSE30219	307	0/307	1,000	0,941	<i>no evaluable: una sola clase</i>			
GSE140797	7	0/7	1,000	0,857	<i>no evaluable: una sola clase</i>			
<i>Media sobre las 8 cohortes evaluables</i>					0,772	0,925	0,983	0,561
<i>Media de accuracy sobre las 11 (como en el análisis original)</i>						0,778		

La hipótesis se confirmó. Sobre las ocho cohortes evaluables, la *balanced accuracy* media fue de 0,772 y la ganancia media respecto al azar informado, de +0,115. 3 de las 8 cohortes evaluables no superan su propio *baseline*: GSE23066 lo iguala (0,500 frente a 0,500), GSE31210 queda ligeramente por debajo (0,894 frente a 0,919) y GSE40791 lo hace de forma drástica (0,167 frente a 0,833). La figura 2 representa cada cohorte frente a su umbral trivial.

1.2.1. Un hallazgo no previsto: discriminación sin decisión

El análisis produjo un resultado que no formaba parte de la hipótesis registrada y que resultó ser el más informativo del capítulo. Sobre las mismas ocho cohortes evaluables, el AUC medio fue de 0,925 mientras que la *balanced accuracy* media se quedó en 0,772. La divergencia entre ambas métricas es sistemática, no anecdótica, y alcanza su expresión más extrema en GSE40791: *accuracy* de 0,167 con un AUC de 1,000.

Un AUC de 1,000 indica que el modelo ordena perfectamente las muestras: existe un umbral que las separa sin error. Una *accuracy* de 0,167 indica que el umbral empleado — el valor por defecto de 0,5 — no es ese. Las columnas de sensibilidad y especificidad de la tabla 2 identifican la causa: la sensibilidad media es de 0,983 y la especificidad media, de 0,561. El modelo clasifica como tumoral casi todo lo que recibe. Ese sesgo es coherente con la composición del conjunto de entrenamiento, que reúne 938 muestras tumorales frente a 219 controles.

La conclusión es que la firma transcriptómica sí transfiere entre cohortes independientes en cuanto a su *capacidad de ordenación*, pero el *punto de corte* no transfiere. La figura 3 representa ambas dimensiones. Esta distinción tiene una consecuencia metodológica inmediata: los valores de *accuracy* próximos a 0,5 acompañados de un AUC próximo a 1,0 que aparecían en el análisis original no eran ruido ni indicios de dificultad intrínseca del problema, sino la manifestación de un problema de calibración enteramente corregible.




Figura 2: *Accuracy* obtenida en cada cohorte externa (barras) frente al *baseline* de clase mayoritaria (marcas horizontales). En rojo, las cohortes evaluables que no superan su umbral trivial; en gris, las tres cohortes de una sola clase, donde la métrica carece de contenido.




Figura 3: Cada punto es una cohorte externa; el tamaño es proporcional al número de muestras. La distancia a la diagonal mide cuánto se pierde por un umbral de decisión mal calibrado. Las cohortes situadas arriba a la izquierda ordenan bien y deciden mal.

1.3. Naturaleza de la señal: composición tisular frente a biología tumoral

Los genes que encabezaban la firma de consenso previa sugerían una interpretación alternativa a la de biomarcadores tumorales. Entre los cincuenta primeros aparecen cinco marcadores canónicos de tejido pulmonar sano — AGER y CLDN18 (epitelio alveolar tipo I), SFTPC (tipo II), FABP4 y WIF1 — todos con un logFC medio próximo a -4 , junto con COL10A1, característico de estroma desmoplásico, al alza. Ese perfil describe la sustitución de parénquima pulmonar normal por tejido tumoral y estroma reactivo, es decir, una diferencia de *composición* de la muestra.

Para contrastarlo se construyó un *score* de contenido de pulmón normal a partir de un panel de 18 marcadores de compartimentos alveolar, endotelial y estromal normal, y se correlacionó con el *score* del clasificador. La prueba decisiva se restringió a las muestras tumorales: sobre el conjunto completo la correlación es alta por construcción, dado que los controles son pulmón sano, y no distingue entre ambas hipótesis. El umbral fijado de antemano fue $|\rho| > 0,7$.

La hipótesis no se confirmó al umbral establecido. La correlación media entre muestras tumorales fue de $\rho = -0,626$, por debajo del criterio fijado, y solo 2 de las 4 cohortes con tumores suficientes lo superan individualmente. El umbral no se ha modificado a posteriori.

La lectura que sostienen los datos es intermedia y más matizada que la hipótesis de partida. La composición tisular explica una fracción sustancial de la señal — en GSE31210, la cohorte con más tumores evaluables ($n = 226$), la correlación alcanza $\rho = -0,870$ con $p = 7 \times 10^{-71}$ — pero no la totalidad. Además, el análisis reveló un segundo eje no previsto: entre muestras tumorales, el *score* del clasificador correlaciona positivamente con un panel de proliferación (ρ entre $+0,314$ y $+0,667$). El clasificador no lee un único fenómeno, sino al menos dos: cuánto parénquima normal conserva la muestra y con qué intensidad proliferan sus células.

Tabla 3: Correlacion de Spearman entre el *score* del clasificador y el contenido de pulmon normal (panel de 18 marcadores alveolares, endoteliales y de estroma normal). La columna decisiva es la tercera: restringida a muestras tumorales, donde la correlacion ya no puede explicarse por la presencia de controles sanos. Se requieren al menos 8 tumores para calcularla.

Cohorte	Tumores	Sanas	ρ frente al <i>score</i> del clasificador		
			Todas (pulmon n.)	Solo tumores	Prolif.
GSE31210	226	20	-0,889	-0,858	0,667
GSE19188	91	65	-0,822	-0,332	0,420
GSE19804	60	60	-0,799	-0,776	0,500
GSE18842	46	45	-0,872	-0,537	0,314
GSE7670	7	8	-0,725	<i>n insuficiente</i>	
GSE118370	6	6	-0,755	<i>n insuficiente</i>	
GSE23066	5	5	-0,054	<i>n insuficiente</i>	
GSE40791	2	10	-0,489	<i>n insuficiente</i>	
<i>Media sobre las 4 cohortes evaluables</i>				-0,626	0,475

Solo muestras tumorales: el score sigue al tejido normal residual




Figura 4: Relación entre el *score* del clasificador y el contenido estimado de pulmón normal, restringida a muestras tumorales. La pendiente negativa persiste al eliminar los controles sanos, lo que indica que parte de la señal procede de tejido normal residual y no de biología tumoral.

1.4. Validez de la consistencia de signo como medida de reproducibilidad

El análisis original cuantificaba la estabilidad de cada gen sumando el signo de su coeficiente a lo largo de los *folds* LODO, y presentaba valores como 11/11 como evidencia de robustez. Esta métrica presenta un problema estructural: cada *fold* entrena con todas las cohortes menos una, de modo que dos *folds* cualesquiera comparten la mayor parte de sus muestras de entrenamiento. En la configuración analizada, la fracción compartida entre pares de *folds* oscila entre el 62,5 % y el 98,5 %, con una mediana del 97,6 %. No se trata de réplicas independientes, sino del mismo modelo ajustado varias veces sobre datos casi idénticos.

Se midió el acuerdo direccional de dos formas sobre los mismos genes y las mismas ocho cohortes: entre *folds* LODO y entre modelos ajustados de forma independiente en cada cohorte. Los resultados iniciales estaban confundidos por el tamaño de muestra, dado que los modelos por cohorte disponen de entre 10 y 246 muestras frente a las 416–652 de los *folds*, y con penalización L_1 un menor tamaño produce menos genes seleccionados. Se añadió por ello un control que compara parejas de modelos con entrenamientos de magnitud comparable, variando únicamente el solapamiento entre ellos.

Tabla 4: Acuerdo direccional de los coeficientes LASSO medido de dos formas sobre los mismos genes y las mismas ocho cohortes. La ultima fila es el control que descarta el tamaño de muestra como explicación: compara parejas de modelos con entrenamientos de magnitud comparable, y únicamente cambia si comparten muestras.

	<i>Folds</i> LODO (solapados)	Cohortes (disjuntas)
Muestras de entrenamiento compartidas	~98 %	0 %
Genes seleccionados alguna vez	739	304
Genes seleccionados en las 8	12	0
Genes con acuerdo de signo perfecto	12	0
<i>Control:</i> concordancia entre parejas	100,0 %	77,3 %

La hipótesis se confirmó, y el control descarta la explicación alternativa. Las 28 parejas de *folds* LODO presentan una concordancia de signo del 100,0 % — perfecta, en todos los pares sin excepción —, mientras que parejas de mitades disjuntas de tamaño comparable ($n \approx 328$ cada una) concuerdan al 77,33 %. La caída de 23 puntos es atribuible al solapamiento y no a la esparsidad del modelo. Una métrica que no puede tomar valores bajos no aporta información: la consistencia de signo entre *folds* LODO mide la reproducibilidad del procedimiento de ajuste, no la del fenómeno biológico.

La consecuencia sobre la firma previa es directa. De los siete genes destacados por esta métrica — SLC6A4, S100A10, KANK3, SH3GL3, HIST1H2BM, ZNF702P y TOX3 —, **ninguno** mantiene coeficiente no nulo y signo constante al ajustar modelos independientes en las ocho cohortes disjuntas. HIST1H2BM ilustra el caso con claridad: alcanza un acuerdo de 8/8 entre *folds* solapados y no resulta seleccionado en ninguna cohorte individual.

1.5. Control positivo: clasificación de subtipo histológico

Los resultados anteriores plantean una pregunta necesaria: si el marco metodológico no detecta señal reproducible en la tarea tumor frente a sano, ¿está midiendo mal, o simplemente no hay señal que medir? Para distinguir ambas posibilidades se aplicó el mismo pipeline a una tarea con respuesta conocida y consecuencia terapéutica real: la distinción entre adenocarcinoma y carcinoma escamoso, que condiciona la elección de tratamiento — pemetrexed y bevacizumab están contraindicados en histología escamosa.




Figura 5: Concordancia direccional entre parejas de modelos con entrenamientos de tamaño comparable. La única variable que cambia entre ambas columnas es la fracción de muestras compartidas.

Se emplearon las tres cohortes con histología anotada y ambas clases presentes (GSE30219, GSE50081 y GSE19188), todas en plataforma GPL570, con 388 muestras y 22 880 genes comunes. La armonización de códigos requirió atención explícita: la abreviatura SCC designa carcinoma escamoso en GSE19188 y carcinoma microcítico en GSE30219, entidades clínicamente opuestas.

Tabla 5: Validación LODO de la tarea adenocarcinoma frente a escamoso sobre las tres cohortes con histología anotada y ambas clases presentes (todas en plataforma GPL570).

Cohorte test	n	ADC/Esc.	<i>Baseline</i>	Bal. acc.	AUC	Ganancia
GSE30219	146	85/61	0,582	0,967	0,996	+0,390
GSE50081	170	127/43	0,747	0,887	0,911	+0,165
GSE19188	72	45/27	0,625	0,967	0,998	+0,333
<i>Media</i>				0,940	0,968	+0,296

El rendimiento es sustancialmente superior al de la tarea tumor frente a sano: *balanced accuracy* media de 0,940 y AUC media de 0,968, con una ganancia media de +0,296 sobre el azar informado. Se derivó además una firma de 1174 genes con $|d| > 0,8$ y signo concordante en las tres cohortes calculadas de forma independiente.

La validación más relevante de este resultado no es su magnitud, sino su contenido. La firma recupera los doce marcadores empleados en inmunohistoquímica diagnóstica en la práctica clínica, todos en la dirección correcta: siete de siete para histología escamosa (KRT5, KRT6A, TP63, DSG3, SOX2, PKP1, KRT14) y cinco de cinco para adenocarcinoma (NAPSA, NKX2-1, SFTPB, SLC34A2, MUC1). Los primeros puestos del *ranking* — DSG3, KRT5, CALML3, KRT6B, PKP1, DSC3, TP63 — corresponden a desmosomas, queratinas y el programa transcripcional de TP63, es decir, a linaje celular escamoso y no a composición del tejido.

Este resultado establece que el marco metodológico es capaz de recuperar biología reproducible cuando existe. Conviene delimitar su alcance: la distinción entre adenocarcinoma y escamoso está bien caracterizada en la literatura transcriptómica y su recuperación no constituye un hallazgo nuevo. Su valor aquí es el de un control positivo, y fue además el análisis que

permitió detectar el desalineamiento descrito en la sección 1.1.

1.5.1. Límites del clasificador ante histologías no observadas

El resultado anterior se obtuvo excluyendo 177 muestras — el 31,3 % de los tumores disponibles — correspondientes a histologías que no son adenocarcinoma ni escamoso: neuroendocrino de célula grande, basaloide, carcinoide, microcítico, célula grande y adenoescamoso. Se excluyeron, por tanto, precisamente los casos que en la práctica clínica resultan ambiguos. Someter el modelo a esas muestras es necesario para no sobreestimar su aplicabilidad.

No existe etiqueta correcta que predecir en ellas, de modo que lo evaluado es la calibración: un modelo prudente debería asignarles probabilidades intermedias. La métrica fijada de antemano fue el porcentaje de muestras con $P > 0,9$ o $P < 0,1$, y la hipótesis registrada, que superaría el 50 %.

Tabla 6: Comportamiento del clasificador de subtipo ante las histologías que no vio en el entrenamiento (grupos con $n \geq 3$). *Alta conf.* recoge el porcentaje de muestras con $P > 0,9$ o $P < 0,1$, es decir, asignadas con confianza a una categoría a la que no pertenecen.

Histología	Cohorte	n	$P(\text{esc.})$ mediana	Alta conf.	A escamoso
neuroendocrino celula grande	GSE30219	56	0,174	32,1 %	10,7 %
basaloide	GSE30219	39	0,922	56,4 %	89,7 %
carcinoide	GSE30219	24	0,177	8,3 %	4,2 %
microcitico (small cell)	GSE30219	21	0,260	4,8 %	4,8 %
celula grande	GSE19188	19	0,408	5,3 %	42,1 %
celula grande	GSE50081	7	0,214	42,9 %	42,9 %
otro	GSE30219	4	0,373	50,0 %	50,0 %
celula grande	GSE30219	3	0,101	33,3 %	0,0 %

La hipótesis no se confirmó. Solo el 29,4 % de las muestras ambiguas recibe una asignación de alta confianza, frente al 63,1 % de las muestras que sí pertenecen a alguna de las dos clases. El modelo es, por tanto, más prudente ante lo que no ha visto de lo que se había previsto.

El valor agregado oculta, sin embargo, dos comportamientos opuestos que la figura 6 separa. El carcinoma basaloide recibe una mediana de $P(\text{escamoso}) = 0,937$ y se asigna a escamoso en el 89,7 % de los casos; esto no constituye necesariamente un error, dado que varias clasificaciones lo consideran una variante de carcinoma escamoso, de modo que el modelo puede estar recuperando la biología correcta. En cambio, de los 101 tumores neuroendocrinos (neuroendocrino de célula grande, microcítico y carcinoide), el 92 % se asigna a adenocarcinoma. Este sí es un fallo con consecuencia clínica directa: el carcinoma microcítico recibe un tratamiento completamente distinto al del cáncer de pulmón no microcítico, y el modelo lo etiqueta como adenocarcinoma sin señalar incertidumbre.

El AUC de 0,968 de la sección 1.5 es válido únicamente sobre tumores previamente confirmados como adenocarcinoma o escamoso. El modelo no puede emplearse como primer filtro sobre un caso sin diagnosticar.

1.6. Síntesis de resultados

Los cinco análisis permiten establecer lo siguiente:

1. Los datos presentan cuatro modos de fallo silencioso y cuantificables: tres cohortes declaradas nunca procesadas, 307 muestras con etiqueta cruzada, 240 muestras (17,2 %)




Figura 6: Distribución de la probabilidad asignada a las histologías ausentes del entrenamiento. En rojo, los tumores neuroendocrinos, desplazados hacia adenocarcinoma. Las bandas grises delimitan las regiones de alta confianza.

perdidas en la curación automatizada y 3 cohortes de una sola clase empleadas como conjunto de test. Ninguno generó un error en tiempo de ejecución.

2. En la tarea tumor frente a sano, la *balanced accuracy* media sobre cohortes evaluables es de 0,772, con 3 de 8 por debajo de su propio *baseline*.
3. La firma transfiere su capacidad de ordenación entre cohortes (AUC medio 0,925) pero no su umbral de decisión (especificidad media 0,561), un problema de calibración inducido por el desbalance del entrenamiento.
4. La composición tisular explica una parte sustancial de la señal ($\rho = -0,626$ entre tumores) sin agotarla, y coexiste con un eje de proliferación no previsto.
5. La consistencia de signo entre *folds* LODO no mide reproducibilidad biológica: alcanza el 100,0 % frente al 77,33 % de modelos disjuntos comparables, y ninguno de los siete genes destacados por esa métrica replica de forma independiente.
6. El marco metodológico sí recupera biología reproducible cuando existe (subtipo histológico, AUC 0,968, con los doce marcadores de inmunohistoquímica recuperados), con la limitación de no reconocer las histologías ausentes del entrenamiento.

2. Discusión

2.1. Reorientación del objeto de estudio

El planteamiento inicial de este trabajo perseguía identificar biomarcadores transcriptómicos universales de cáncer de pulmón mediante la integración de múltiples cohortes públicas. Los resultados del capítulo anterior no sostienen ese objetivo, y conviene ser explícito sobre por qué.

La firma derivada del contraste entre tejido tumoral y tejido sano adyacente reúne tres características que impiden interpretarla como un conjunto de biomarcadores: su señal procede en parte sustancial de la composición del tejido más que de biología tumoral específica (sección 1.3); su estabilidad aparente era un artefacto del diseño de validación (sección 1.4); y la tarea que resuelve no constituye un problema clínico, dado que la distinción entre tumor y parénquima normal la resuelve el examen histopatológico convencional con fiabilidad superior, coste incomparablemente menor y sobre la misma muestra ya disponible.

Esto no invalida el framework desarrollado. Lo que invalida es la lectura que se había hecho de sus resultados. El pipeline descarga, normaliza, curó metadatos mediante modelos de lenguaje, ejecuta análisis diferencial, entrena modelos y valida de forma externa; todos esos componentes funcionan, y el control positivo de la sección 1.5 demuestra que recuperan biología reproducible cuando está presente. La contribución defendible de este trabajo no es, por tanto, una firma molecular, sino la caracterización sistemática de los modos en que estos pipelines fallan sin avisar, y un conjunto de controles concretos para detectarlos.

2.2. Los cuatro modos de fallo silencioso

Los problemas documentados en la sección 1.1 comparten un rasgo que los hace especialmente peligrosos: ninguno interrumpe la ejecución. El pipeline termina, escribe sus ficheros y produce tablas de aspecto correcto.

El desalineamiento como fallo indistinguible. El caso de GSE30219 es instructivo porque su efecto imita exactamente el de una hipótesis nula verdadera. Un AUC de 0,56 sobre una cohorte de 146 tumores es perfectamente compatible con la conclusión «esta señal no generaliza a esta cohorte», y ese es el tipo de resultado que un trabajo honesto acepta y reporta. Solo la comparación con marcadores de referencia externos — la observación de que KRT5 mostraba una diferencia de +0,90 en esta cohorte frente a +5,32 y +5,66 en las otras dos — reveló que la señal estaba presente pero desacoplada de las etiquetas. La lección metodológica es que la validación frente a conocimiento biológico previo no es un adorno interpretativo, sino un control de integridad de los datos.

Resulta pertinente señalar que el análisis original no se vio afectado por este error, y la razón es instructiva: GSE30219 contiene una sola clase, de modo que intercambiar etiquetas idénticas entre sí no altera nada. El fallo permaneció latente y solo se manifestó al plantear una pregunta que utilizara la información clínica. Un pipeline puede arrastrar errores de este tipo durante todo su ciclo de vida sin que se manifiesten, hasta que alguien formula la pregunta adecuada.

La curación automatizada como fuente de sesgo de selección. El empleo de modelos de lenguaje para homogeneizar metadatos clínicos heterogéneos es una de las aportaciones metodológicamente más interesantes del framework, y su comportamiento bimodal — éxito prácticamente completo en ocho cohortes, colapso en dos — merece una lectura cuidadosa. El

problema no es la tasa global del 82,8 %, sino que las pérdidas no son aleatorias: se concentran en cohortes concretas y, dentro de ellas, afectan a la práctica totalidad de las muestras. GSE40791 pasó de 194 muestras a 12, y las 12 supervivientes presentan una composición de clases (10 controles y 2 tumores) que no representa al estudio original. El resultado es un sesgo de selección introducido por una capa de procesamiento automático, no declarado como tal en ningún punto del pipeline. La recomendación que se deriva es que cualquier etapa de curación automatizada debe reportar su tasa de éxito por cohorte como parte de los resultados, y que las cohortes con tasas bajas deben excluirse explícitamente en lugar de participar con su fracción superviviente.

Cohortes de una sola clase. Que GSE30219 y GSE50081 no contengan controles no es un defecto de esas cohortes: son estudios de supervivencia, diseñados para correlacionar expresión con evolución clínica, y su composición es la correcta para su propósito. El error consiste en emplearlas como conjunto de test de un clasificador binario. Este fallo es además el más fácil de detectar automáticamente — basta comprobar el número de clases presentes antes de evaluar — y el más fácil de pasar por alto cuando la métrica reportada es únicamente la *accuracy*, porque produce precisamente los valores más altos de la tabla.

2.3. Discriminación y decisión como propiedades independientes

El hallazgo de la sección 1.2.1 no estaba previsto y es, a nuestro juicio, el resultado de mayor utilidad práctica del trabajo. La coexistencia de un AUC medio de 0,925 con una *balanced accuracy* media de 0,772, y su expresión extrema en GSE40791 (*accuracy* 0,167 con AUC 1,000), descompone lo que habitualmente se trata como un único atributo — «el modelo generaliza» o «no generaliza» — en dos propiedades que transfieren de forma independiente entre cohortes.

La capacidad de ordenación transfiere bien: la firma sitúa consistentemente las muestras tumorales por encima de los controles en cohortes que nunca ha visto. El umbral de decisión no transfiere: el punto de corte aprendido sobre una distribución de clases determinada (938 tumores frente a 219 controles) deja de ser adecuado cuando la cohorte de destino presenta otra composición. La sensibilidad media de 0,983 frente a una especificidad media de 0,561 describe un modelo que ha aprendido, razonablemente dada su dieta de entrenamiento, que predecir «tumor» casi siempre acierta.

Esta lectura reinterpreta un patrón que el análisis original registraba sin explicar. Los casos de *accuracy* próxima a 0,5 acompañada de AUC próximo a 1,0 se habían atribuido a la dificultad intrínseca del problema, al tamaño muestral reducido o a particularidades técnicas de los estudios. No era ninguna de esas cosas: era un problema de calibración, y los problemas de calibración son corregibles. La vía inmediata es la ponderación de clases en el entrenamiento; la más robusta, reportar métricas independientes del umbral (AUC, precisión media) junto con métricas de decisión, y ajustar el punto de corte sobre la cohorte de destino cuando el escenario de aplicación lo permita.

2.4. Qué mide la firma: composición, proliferación y biología

La hipótesis de que la firma tumor frente a sano capturase esencialmente composición tisular no se confirmó al umbral fijado de antemano ($|\rho| > 0,7$; obtenido $\rho = -0,626$). Mantener ese criterio obliga a una conclusión más matizada, y probablemente más correcta, que la hipótesis de partida.

La composición tisular explica una fracción sustancial de la señal. La evidencia es convergente: la correlación entre el *score* del clasificador y el contenido de pulmón normal persiste

al restringir el análisis a muestras tumorales, alcanzando $\rho = -0,870$ ($p = 7 \times 10^{-71}$) en la cohorte con mayor número de tumores evaluables; y cinco de los cincuenta genes principales de la firma son marcadores canónicos de epitelio alveolar y estroma pulmonar normal, con logFC en torno a -4 . Interpretados como biomarcadores tumorales, genes como AGER, CLDN18 o SFTPC informan principalmente de cuánto parénquima sano conserva la muestra.

Pero no la agotan. El segundo eje detectado — correlación positiva con proliferación, entre $+0,314$ y $+0,667$ — indica que el clasificador integra al menos dos fenómenos distintos, y el segundo sí es biología tumoral en sentido estricto. La descripción más ajustada de lo que mide la firma es «pérdida de arquitectura alvéolo-capilar normal más ganancia de actividad proliferativa», una combinación real, reproducible y de escaso valor discriminativo por ser común a la práctica totalidad de los tumores sólidos.

Debe señalarse una limitación de este análisis: solo 4 cohortes reunían tumores suficientes ($n \geq 8$) para el contraste restringido, y los estimadores presentan heterogeneidad notable entre ellas (ρ de $-0,343$ a $-0,870$). Un abordaje más riguroso emplearía métodos de deconvolución celular para estimar la proporción de cada tipo celular, en lugar de un panel de marcadores promediado.

2.5. Implicaciones sobre el diseño de la validación externa

La estrategia LODO es metodológicamente superior a la validación cruzada convencional dentro de un mismo estudio, y su adopción sigue siendo escasa en la literatura de biomarcadores transcriptómicos. Este trabajo no cuestiona esa elección, sino dos usos concretos que se hicieron de ella.

El primero es de terminología con consecuencias conceptuales: LODO no corrige el efecto lote, lo *mide*. Presentarla como mecanismo de superación del *batch effect* confunde la naturaleza del procedimiento. En el pipeline analizado no existe corrección de lote alguna — solo normalización por cuantiles dentro de cada estudio y estandarización por estudio —, y la degradación de rendimiento entre cohortes que LODO revela *es* la magnitud del problema, no su solución.

El segundo es el uso de los *folds* LODO como réplicas para medir estabilidad. La demostración de la sección 1.4 es cuantitativa y, en nuestra opinión, generalizable más allá de este trabajo: cuando el número de cohortes es moderado, los conjuntos de entrenamiento de los distintos *folds* comparten una mediana del 97,6 % de sus muestras, y la concordancia direccional resultante es del 100,0 % en la totalidad de los pares. Una métrica cuyo valor está determinado por el diseño no puede aportar evidencia sobre el fenómeno estudiado. El control con mitades disjuntas de tamaño comparable (77,33 %) delimita cuánto de ese 100,0 % procede del solapamiento.

La consecuencia sobre los siete genes previamente destacados es contundente: ninguno replica al ajustar modelos independientes. Esto no significa que carezcan de interés biológico — SLC6A4 y KANK3 son marcadores endoteliales pulmonares bien caracterizados, coherentes con la interpretación composicional de la sección anterior —, sino que la evidencia aportada para priorizarlos no era evidencia. La alternativa empleada en la sección 1.5, exigir concordancia de tamaño de efecto en cohortes ajustadas por separado, es más exigente y produjo una firma que recupera marcadores de uso clínico establecido.

2.6. Alcance y limitaciones del control positivo

La clasificación de subtipo histológico cumple su función como control positivo: demuestra que el marco metodológico detecta biología reproducible cuando existe, con AUC medio de 0,968 y recuperación completa de los doce marcadores de inmunohistoquímica diagnóstica. Conviene,

no obstante, precisar tres límites.

Primero, la distinción entre adenocarcinoma y carcinoma escamoso está extensamente caracterizada en transcriptómica y su recuperación no constituye una aportación original. Su valor es de verificación, no de descubrimiento.

Segundo, el resultado se obtuvo excluyendo el 31,3 % de los tumores disponibles, precisamente los de histología ambigua. El análisis de la sección 1.5.1 muestra que el modelo es más prudente ante esas muestras de lo previsto (29,4 % de asignaciones de alta confianza frente al 63,1 % en muestras de clase conocida; la hipótesis registrada no se confirmó), pero también que el 92 % de los 101 tumores neuroendocrinos se etiqueta como adenocarcinoma. Dado que el carcinoma microcítico requiere un abordaje terapéutico completamente distinto, esta es una limitación con consecuencia clínica y no meramente estadística.

Tercero, las tres cohortes comparten plataforma (GPL570), de modo que el resultado no informa sobre transferencia entre tecnologías de medición. Las tres cohortes de RNA-seq que habrían permitido evaluarlo son precisamente las que el pipeline no llegó a procesar.

2.7. Recomendaciones metodológicas

De los resultados obtenidos se derivan seis controles concretos, aplicables a cualquier pipeline de descubrimiento de biomarcadores sobre repositorios públicos:

1. **Alinear muestras y metadatos por identificador explícito**, nunca por posición, y verificar la correspondencia como paso previo a cualquier análisis. La coincidencia de longitudes no implica coincidencia de orden.
2. **Validar contra marcadores biológicos conocidos** antes de interpretar cualquier resultado. Un panel de referencia de la patología estudiada funciona como control de integridad de los datos y detecta fallos que ninguna comprobación de formato revela.
3. **Reportar el *baseline* de clase mayoritaria** junto a toda métrica de rendimiento, y excluir explícitamente las cohortes de una sola clase de la evaluación, indicándolo en las tablas.
4. **Separar métricas de discriminación y de decisión**. Informar AUC y *balanced accuracy* conjuntamente, con sensibilidad y especificidad desglosadas; su divergencia identifica problemas de calibración que la *accuracy* agregada oculta.
5. **Medir la estabilidad sobre particiones disjuntas**, no sobre *folds* solapados, y declarar la fracción de muestras compartidas cuando se empleen estas últimas.
6. **Cuantificar y reportar la tasa de éxito de toda etapa de curación automatizada** por cohorte, tratando las pérdidas elevadas como criterio de exclusión y no como merma silenciosa del tamaño muestral.

2.8. Líneas futuras

Los datos ya descargados permiten abordar preguntas que este trabajo no ha explorado y que resultan más informativas que la comparación entre tumor y tejido sano. GSE30219 y GSE50081 disponen de seguimiento clínico completo (307 y 181 tumores, con 200 y 75 eventos de mortalidad respectivamente), lo que habilita análisis de supervivencia con validación cruzada entre cohortes. GSE31210 incluye el estado de los principales genes conductores — 127 tumores con mutación de EGFR, 20 de KRAS, 11 con fusión de ALK y 68 sin ninguna de las tres

alteraciones —, lo que permite plantear la predicción de alteración conductora a partir del perfil de expresión. Ambas son preguntas cuya respuesta no se conoce de antemano por inspección de la muestra, condición que la tarea tumor frente a sano no cumplía.

En el plano metodológico, tres extensiones mejorarían el rigor de los análisis presentados: el empleo de deconvolución celular en lugar de paneles de marcadores promediados para cuantificar composición tisular; la incorporación de corrección de lote explícita, con evaluación de su efecto sobre la transferencia entre cohortes; y la recuperación de las tres cohortes de RNA-seq no procesadas, que permitirían por primera vez evaluar la generalización entre plataformas de medición distintas.