

data.lung

Del dataset a una firma génica replicable

Framework transcriptómico basado en la integración de modelos de lenguaje y aprendizaje automático para la identificación de biomarcadores en cáncer de pulmón

Daniel Tapia Díez · Tutor: Leonardo Dulcetti · TFM Bioinformática · UAX 2026

Contexto y motivación

El cáncer de pulmón es la **primera causa de mortalidad oncológica** en el mundo (2,48 millones de nuevos casos en 2022; supervivencia a 5 años $< 20\%$). La distinción entre **adenocarcinoma** (ADC) y **carcinoma escamoso** (SQC) tiene consecuencia terapéutica directa: pemetrexed y bevacizumab están contraindicados en escamoso.

Las bases de datos públicas (NCBI GEO) reúnen *cientos* de estudios, pero su integración se ve frenada por:


- Heterogeneidad de plataformas.
- Metadatos clínicos en **texto libre**.
- Firmas génicas propuestas que **no replican** en cohortes independientes.

Objetivo

Un framework reproducible que *automatica* la integración multi-cohorte usando un modelo de lenguaje para curar metadatos, y que *valide externamente* las firmas génicas identificadas.

Método

Pipeline extremo a extremo en 9 fases:



Consenso multi-cohorte: un gen entra en la firma sólo si mantiene el mismo signo y $|d| > 0,5$ (Cohen) en las **3 cohortes** evaluables simultáneamente.

Cifras principales


11 cohortes GEO descargadas
8/11 cumplen criterios de inclusión
1157 muestras curadas con LLM
1174 genes replicados en 3 cohortes
20 genes del panel mínimo
18/20 marcadores IHC recuperados
0,968 AUC media LODO (subtipo)
0,925 AUC media LODO (tumor vs sano)

Rendimiento LODO

Tarea	AUC	Bal. acc.	Sens.	Espec.	k cohortes
Tumor vs sano	0,925	0,772	0,983	0,561	8
Subtipo ADC vs SQC	0,968	0,940	0,924	0,957	3

Sobre 8 cohortes evaluables tumor-vs-sano el modelo **ordena** correctamente las muestras (AUC 0.925), aunque el umbral de decisión necesita recalibración por cohorte. Es un problema técnico corregible, no una limitación de la firma.

Panel mínimo (20 genes) $\approx$ firma completa



Validación externa contra IHC clínica

De los 20 marcadores diagnósticos del panel IHC de la OMS (2015), el framework recupera **18 sin declararlos**:

Linaje	Marcadores recuperados	Cobertura
Escamoso	KRT5, KRT6A, KRT6B, KRT13, KRT14, TP63, DSG3, DSC3, SOX2, PKP1, CALML3, S100A2	12/12
Adenocarcinoma	NAPSA, NKX2-1, SFTPB, MUC1, SLC34A2, CEACAM6 (no: SFT-PA1, SFTPC)	6/8

Es especialmente significativo que la firma, seleccionada por *criterio estadístico puro* (consenso multi-cohorte), coincida con el panel diagnóstico que ya usa la clínica.

Interpretación biológica: 2 ejes reales

Eje 1 — Pérdida de arquitectura alvéolo-capilar. Correlación media $\rho = -0,626$ entre score del clasificador y contenido residual de pulmón sano dentro de los tumores; en GSE31210 ($n = 226$) alcanza $\rho = -0,858$ con $p = 1,1 \cdot 10^{-66}$.

Eje 2 — Actividad proliferativa aumentada. Marcadores canónicos: MKI67, TOP2A, CCNB1, BIRC5, AURKA.

Ambos ejes son *señal biológica reproducible*, no artefacto de composición tisular. La firma captura la transición del pulmón sano a un tejido menos diferenciado y más proliferativo — la histología del NSCLC.

Conclusiones

- Un LLM contemporáneo puede **curar los metadatos** de cohortes GEO con tasa de éxito media del **85,9 %**.
- El consenso multi-cohorte produce una firma **robusta** (AUC 0,968 LODO en 3 cohortes independientes).