

data.lung

Del dataset a una firma génica replicable

Framework transcriptómico basado en la integración de modelos de lenguaje y aprendizaje automático
para la identificación de biomarcadores en cáncer de pulmón

Daniel Tapia Díez · Tutor: Leonardo Dulcetti · 14 ago 2026

CONSTRUIDO CON



DATOS DE



El problema · el objetivo

> Cáncer de pulmón

2,48 M casos/año

<20 % superv. 5 años

Distinguir **adenocarcinoma** (ADC) de **carcinoma escamoso** (SQC) es crítico: pemetrexed y bevacizumab **contraindicados** en escamoso.

> El reto


Cientos de estudios GEO públicos, pero:

- ▶ Plataformas heterogéneas
- ▶ Metadatos en **texto libre**
- ▶ Firmas publicadas que **no replican**

> Objetivo

*Framework reproducible que integra cohortes GEO con **curación LLM**, validación **LODO** y firma **consenso interpretable**.*

Método · pipeline de 9 pasos



> Piezas clave

► Paso 3 · LLM

Llama 3.3-70b cura los metadatos clínicos de texto libre. Tasa de éxito **85,9 %**.

► Paso 7 · LODO externa

Cada cohorte se retira una vez del entrenamiento y se usa como test independiente.

► Paso 8 · Consenso multi-cohorte

Un gen entra en la firma sólo si mantiene signo y $|d| > 0,5$ en las 3 cohortes.

Sin corrección de batch: LODO no lo corrige, lo mide.

Resultados · firma génica y panel mínimo

11

COHORTES GEO

8/11

CUMPLEN CRITERIOS

1157

MUESTRAS CURADAS LLM

1174

GENES VALIDADOS

EN 3 COHORTES INDEP.

20

GENES PANEL MÍNIMO

0,966 vs 0,970

AUC PANEL · AUC FIRMA COMPLETA

> Top 5 firma

<i>DSG3</i>	desmosoma
<i>KRT5</i>	queratina basal
<i>CALML3</i>	diferenciación
<i>KRT6B</i>	queratina basal
<i>PKP1</i>	desmosoma

Los 20 del panel se pueden medir por PCR cuantitativa o NanoString. Aplicable en clínica.

Resultados · validación externa contra IHC y biología

> Panel diagnóstico OMS recuperado sin declararlo

Linaje	Recuperación
Escamoso	12 / 12
Adenocarcinoma	6 / 8
Total	18 / 20 · 90 %

Selección puramente estadística → coincide con el panel que ya usa la clínica.

*La firma no es sólo robusta: es **biológicamente correcta**.*

> Interpretación · 2 ejes reales

Eje 1 · Pérdida alvéolo-capilar

$\rho = -0,626$ media

$\rho = -0,858$ en GSE31210 ($p = 1,1 \cdot 10^{-66}$)

Eje 2 · Actividad proliferativa

MKI67, TOP2A, CCNB1, BIRC5, AURKA

La firma captura la transición del pulmón sano al tejido tumoral.

Resultados · rendimiento, recalibración y RNA-Seq

> LODO tumor vs sano · con recalibración

	Sin recal.	Con isotónica
AUC	0,925	0,953
BalAcc	0,772	0,810
Sensibilidad	0,983	0,988
Especificidad	0,561	0,632

> Comparativa LODO

LASSO 0,925 · RF 0,933 · SVM 0,957 (AUC)

LASSO elegido por interpretabilidad (coefs. por gen)

> Transferibilidad a RNA-Seq · TCGA

Panel entrenado en microarray → aplicado a
TCGA-LUAD ($n = 230$) + **TCGA-LUSC**
($n = 178$)

0,857

AUC CON SCORE LASSO TRANSFERIDO

[0,812; 0,899]

IC 95 % BOOTSTRAP

*Ninguna muestra TCGA participó en la selección
ni en la calibración. Plataforma cambiada,
firma se transfiere.*

data.lung · demo en vivo


> Interfaz Streamlit multipágina

- Portada + dashboard con 7 capítulos
- **Buscador de gen** sobre la firma
- Vista por cohorte (PCA, volcano, heatmap)
- Cifras leídas de los CSV — nada hardcoded

> Asistente Llama 3.3-70b acotado

- Responde *sólo* con los resultados del trabajo
- Reglas explícitas contra alucinación
- Distingue lo que está en la firma de lo que no

> streamlit run paso12_web_chatbot.py



(captura real · demo en vivo)

Conclusiones

- ▶ Un LLM cura los metadatos de GEO con **85,9 %** de éxito.
- ▶ Consenso multi-cohorte + LODO produce firma robusta: **1174 genes** con AUC **0,968** en subtipo.
- ▶ Panel mínimo de **20 genes** $\approx$ firma completa (0,966 vs 0,970), clínicamente manejable.
- ▶ La firma **recupera 18/20 marcadores IHC clínicos** sin declararlos.
- ▶ Recalibración isotónica: **BalAcc 0,772 $\rightarrow$ 0,810** en tumor vs sano.
- ▶ El panel se transfiere a RNA-Seq: **AUC 0,857** en TCGA (408 muestras).
- ▶ Framework **reproducible** extremo a extremo con interfaz web y asistente acotado.

Trabajo futuro · stack tecnológico

> Líneas futuras

- ▶ Validación clínica prospectiva sobre biopsias frescas (NanoString / RT-qPCR)
- ▶ Ampliación a subtipos neuroendocrinos
- ▶ Sustitución del LLM externo por modelo local
- ▶ Extensión metodológica a otros tumores (mama, colon, hepatocarcinoma)
- ▶ Firmas pronósticas (regresión de Cox sobre TCGA)

> Reproducible sobre software libre



github.com/danitapiadiez-gif/TFM-Bioinformatica

data.lung

Gracias por vuestra atención

Daniel Tapia Díez

Tutor: Leonardo Dulcetti · Universidad Alfonso X el Sabio

github.com/danitapiadiez-gif/TFM-Bioinformatica