

# data.lung

*Del dataset a una firma génica replicable*

---

## Guía de estudio para la defensa

Framework transcriptómico para biomarcadores  
en cáncer de pulmón

|                    |                                |
|--------------------|--------------------------------|
| <b>Autor</b>       | Daniel Tapia Díez              |
| <b>Tutor</b>       | Leonardo Dulcetti              |
| <b>Universidad</b> | UAX · Máster en Bioinformática |
| <b>Defensa</b>     | 14 de agosto de 2026           |

*Este documento tiene dos partes: (A) conceptos clave explicados en lenguaje llano para llegar a la defensa con seguridad; (B) guión diapositiva por diapositiva con timing y transiciones. Añádense preguntas probables del tribunal y un checklist de última hora.*

Léelo dos veces enteras antes del día D. La víspera, sólo la Parte B.

# Índice

---

|                                                                    |           |
|--------------------------------------------------------------------|-----------|
| <b>Parte A · Conceptos clave</b>                                   | <b>3</b>  |
| 0.1. Transcriptómica y expresión génica . . . . .                  | 3         |
| 0.2. Cómo se mide la expresión: microarrays y RNA-Seq . . . . .    | 3         |
| 0.3. GEO (Gene Expression Omnibus) y cohortes . . . . .            | 3         |
| 0.4. Adenocarcinoma vs Carcinoma escamoso . . . . .                | 3         |
| 0.5. Inmunohistoquímica (IHC) y panel OMS . . . . .                | 4         |
| 0.6. Modelos de lenguaje (LLM), Llama y Groq . . . . .             | 4         |
| 0.7. Batch effect y por qué integrar cohortes es difícil . . . . . | 4         |
| 0.8. Meta-análisis por consenso . . . . .                          | 5         |
| 0.9. LODO · Leave-One-Dataset-Out . . . . .                        | 5         |
| 0.10. Aprendizaje automático usado . . . . .                       | 5         |
| 0.11. Métricas de rendimiento . . . . .                            | 6         |
| 0.12. Calibración (isotónica y Platt) . . . . .                    | 6         |
| 0.13. Bootstrap e intervalos de confianza . . . . .                | 6         |
| 0.14. TCGA y cBioPortal . . . . .                                  | 7         |
| 0.15. Correlación de Spearman ( $\rho$ ) . . . . .                 | 7         |
| 0.16. Streamlit y la interfaz data.lung . . . . .                  | 7         |
| 0.17. Ejes biológicos reales (interpretación) . . . . .            | 7         |
| 0.18. NanoString y RT-qPCR (transferibilidad clínica) . . . . .    | 7         |
| 0.19. Reproducibilidad . . . . .                                   | 8         |
| 0.20. Objetivo del TFM en una frase . . . . .                      | 8         |
| <b>Parte B · Guión por diapositiva</b>                             | <b>9</b>  |
| Slide 1 · Portada . . . . .                                        | 9         |
| Slide 2 · Problema y objetivo . . . . .                            | 9         |
| Slide 3 · Pipeline . . . . .                                       | 9         |
| Slide 4 · Firma y panel . . . . .                                  | 10        |
| Slide 5 · IHC y biología . . . . .                                 | 10        |
| Slide 6 · Rendimiento y TCGA . . . . .                             | 11        |
| Slide 7 · Demo . . . . .                                           | 11        |
| Slide 8 · Conclusiones . . . . .                                   | 12        |
| Slide 9 · Trabajo futuro . . . . .                                 | 12        |
| Slide 10 · Cierre . . . . .                                        | 12        |
| <b>Parte C · Preguntas del tribunal</b>                            | <b>13</b> |
| <b>Parte D · Checklist</b>                                         | <b>15</b> |

## Parte A · Conceptos clave

---

---

### 0.1 Transcriptómica y expresión génica

- **ADN:** es el libro de instrucciones de la célula. Todas las células de tu cuerpo tienen el mismo ADN.
- **Genes:** son "frases concretas dentro del libro. Un gen codifica una proteína o una función reguladora.
- **Expresión génica:** no todos los genes se "leen" al mismo tiempo. Una célula del pulmón lee genes distintos que una del hígado. La expresión es *cuánto* se está leyendo cada gen.
- **Transcriptoma:** el conjunto completo de genes activos en una muestra en un momento dado. "Medir la expresión." <sup>es</sup> medir el transcriptoma.
- **Por qué importa en cáncer:** un tumor tiene un patrón distinto del tejido sano, y dentro de los tumores adenocarcinoma y escamoso tienen patrones distintos. Esa **firma de expresión** sirve para diagnóstico y pronóstico.

### 0.2 Cómo se mide la expresión: microarrays y RNA-Seq

- **Microarray:** chip de vidrio con miles de sondas de ADN pegadas. Vuelcas ARN de tu muestra, se une a las sondas complementarias y se mide la fluorescencia. Tecnología clásica (2000-2015), barata, dominante en estudios GEO antiguos.
- **RNA-Seq:** secuencia directamente todo el ARN. Tecnología moderna (2015 en adelante), más precisa, estándar en TCGA.
- **Por qué importa aquí:** el framework se entrenó en **microarrays** (11 cohortes GEO) y se validó en **RNA-Seq** (TCGA). Que un panel entrenado en microarray funcione en RNA-Seq demuestra que la señal es real, no un artefacto tecnológico.

### 0.3 GEO (Gene Expression Omnibus) y cohortes

- **GEO:** repositorio público del NCBI (EE. UU.) con más de 200.000 estudios de expresión génica.
- **Cohorte / estudio / dataset:** sinónimos. Cada uno con identificador tipo GSE10245, GSE31210.
- **Metadatos:** descripciones de cada muestra (edad, tumor/sano, subtipo, estadio...) en **texto libre**, sin estructura. Por eso el paso 3 del pipeline necesita un LLM: convertir texto no estructurado en etiquetas canónicas.

### 0.4 Adenocarcinoma vs Carcinoma escamoso

- Son los dos subtipos más frecuentes del cáncer de pulmón *no microcítico* (a su vez, el 85 % de todos los cánceres de pulmón).

- **ADC (adenocarcinoma)**: origen glandular, periferia pulmonar. Marcadores clásicos: TTF-1, napsina A.
- **SQC (escamoso)**: origen en el epitelio bronquial, más central. Marcadores clásicos: p40, CK5/6, DSG3.
- **Por qué es crítico distinguirlos**: el tratamiento cambia. **Pemetrexed** (quimio) y **bevacizumab** (antiangiogénico) están **contraindicados en escamoso** por riesgo de hemorragia mortal. Un diagnóstico erróneo puede matar al paciente.

## 0.5 Inmunohistoquímica (IHC) y panel OMS

- **IHC**: técnica del laboratorio de anatomía patológica. Anticuerpos marcados que se unen a proteínas específicas. Es lo que hace el patólogo al teñir y mirar al microscopio.
- **Panel OMS 2015** (Travis et al.): conjunto pequeño de marcadores recomendado por la OMS para diagnóstico rutinario. En el TFM se toma como **verdad clínica**.
  - **Escamoso**: KRT5, KRT6A, KRT6B, KRT13, KRT14, KRT15, KRT16, KRT17, CDH3, DSG3, PKP1, TP63.
  - **Adenocarcinoma**: NKX2-1 (TTF-1), NAPS A (napsina A), SFTPB, SFTPC, SFTPA1, SFTPA2, MUC1, CEACAM5, CEACAM6, KRT7.
- **Validación del TFM**: la firma de 20 genes seleccionada por LASSO **recupera 18 de los 20 marcadores del panel OMS** sin que se le dijera nada del panel. Es un aval biológico fortísimo.

## 0.6 Modelos de lenguaje (LLM), Llama y Groq

- **LLM**: modelo estadístico entrenado con enormes cantidades de texto que aprende a generar y clasificar lenguaje natural.
- **Llama 3.3-70b**: LLM de código abierto publicado por Meta. 70.000 millones de parámetros. Es el modelo usado para curar los metadatos de GEO.
- **Groq**: infraestructura de inferencia ultrarrápida (hardware LPU en vez de GPU). Sirve modelos abiertos como Llama con latencias de decenas de milisegundos, lo que hace viable procesar miles de muestras.
- **Por qué un LLM en bioinformática**: los metadatos GEO están en texto libre, con abreviaturas, faltas y sinónimos. Codificar reglas regex para todos los casos es imposible. Un LLM entiende contexto: le pasas “*primary lung tumor, LUSC, stage III*” y devuelve la etiqueta canónica LUSC.

## 0.7 Batch effect y por qué integrar cohortes es difícil

- **Efecto lote (batch effect)**: al integrar muestras de laboratorios distintos, gran parte de la varianza es técnica (chip, reactivo, operador, año), no biológica.
- **ComBat**: algoritmo clásico (Johnson et al., 2007) que “corrige” el efecto lote normalizando cohortes. Riesgo: si el efecto lote está confundido con la variable de interés, ComBat borra también señal biológica real.
- **En este TFM**: no se aplica ComBat. Se usa **meta-análisis por consenso**.

## 0.8 Meta-análisis por consenso

- Cada cohorte se analiza por separado.
- Para cada gen y cohorte se calcula el **tamaño de efecto d de Cohen**:

$$d = \frac{\bar{x}_{tumor} - \bar{x}_{sano}}{s_{combinado}}$$

- $|d| > 0,5$  es efecto moderado;  $|d| > 0,8$  grande.
- Un gen entra en la firma sólo si mantiene **el mismo signo** y  $|d| > 0,5$  en al menos las cohortes exigidas (aquí: 3 independientes).
- Ventaja frente a ComBat: más conservador, no fuerza normalizaciones. Sólo sobreviven señales robustas.

## 0.9 LODO · Leave-One-Dataset-Out

- Variante estricta de validación cruzada.
- Con N cohortes: entrenas con N-1 y evalúas en la retirada. Repites N veces.
- **Contraste con CV k-fold clásica**: la CV normal mezcla muestras de todas las cohortes. Dos muestras de la misma cohorte comparten sesgos técnicos; evaluarlas juntas infla el rendimiento. LODO lo evita.
- **En este TFM**: LODO es el criterio principal. Un AUC = 0,925 en LODO es **más creíble** que un AUC = 0,95 en k-fold.

## 0.10 Aprendizaje automático usado

### LASSO (regresión logística con regularización L1)

- Modelo lineal con penalización que fuerza coeficientes a cero. Selecciona sólo los genes útiles.
- Ventajas: (i) panel pequeño e interpretable (coeficientes por gen), (ii) determinista con **random\_state** fijo, (iii) un único hiperparámetro (C).
- **Es el método principal del TFM.**

### Random Forest (RF)

- “Bosque” de árboles de decisión. Cada árbol se entrena con submuestra aleatoria y selección aleatoria de variables; se vota entre árboles.
- No hace selección tan agresiva como LASSO, pero da un **ranking de importancia** útil como complemento.
- En el TFM: AUC 0,933 (ligeramente mejor que LASSO), pero se descarta porque no da un panel interpretable.

## SVM (Support Vector Machine)

- Encuentra el hiperplano óptimo que separa dos clases en un espacio de alta dimensión. Kernels (RBF) para separaciones no lineales.
- En el TFM: AUC 0,957 (el mejor absoluto), pero pesos difíciles de interpretar como “importancia de gen”.

**Por qué LASSO si SVM da más AUC?** Interpretabilidad clínica. Diferencia de 3 puntos de AUC no compensa perder un panel que un clínico puede leer.

### 0.11 Métricas de rendimiento

- **AUC** (Area Under ROC Curve): probabilidad de que el modelo ordene una muestra positiva por encima de una negativa. Rango 0,5 (azar) a 1,0 (perfecto). Independiente del umbral.
- **Sensibilidad** (recall / TPR): de todos los positivos reales, cuántos detecto. Con 100 tumores y 95 detectados, sensibilidad = 0,95.
- **Especificidad**: de todos los negativos reales, cuántos descarto correctamente.
- **Balanced Accuracy**: media de sensibilidad y especificidad. Útil con clases desbalanceadas.
- **PPV / VPP**: valor predictivo positivo. De los que predije positivos, cuántos lo son de verdad. Depende de la prevalencia.

#### Regla mnemotécnica.

Sensibilidad: “no se me escape ningún enfermo”.

Especificidad: “no marque como enfermo a alguien sano”.

### 0.12 Calibración (isotónica y Platt)

- Un modelo puede tener buen AUC pero puntuaciones **descalibradas** entre cohortes: predice 0,8 y la probabilidad real es 0,5.
- **Platt scaling**: regresión logística sobre las puntuaciones. **Isotónica**: función monótona no paramétrica, más flexible.
- **En el TFM**: la calibración isotónica sube BalAcc de 0,772  $\rightarrow$  0,810 y AUC de 0,925  $\rightarrow$  0,953. Especialmente importante en tumor-vs-sano porque el umbral óptimo cambia entre cohortes.

### 0.13 Bootstrap e intervalos de confianza

- **Bootstrap**: técnica de remuestreo. Del conjunto de muestras tomas N con reemplazo, recalculas la métrica, repites (p. ej. 1000 veces). La distribución de esas 1000 métricas te da la incertidumbre.
- **IC 95 % bootstrap**: percentiles 2,5 y 97,5 de esa distribución.
- **TFM**: AUC TCGA = 0,857, IC 95 % = [0,812; 0,899]. Si repitiéramos el experimento, en el 95 % de las repeticiones el AUC caería entre esos dos valores.

## 0.14 TCGA y cBioPortal

- **TCGA** (The Cancer Genome Atlas): consorcio del NIH que caracterizó miles de tumores humanos. Pulmón: **TCGA-LUAD** (adenocarcinoma) y **TCGA-LUSC** (escamoso).
- **cBioPortal**: portal y API pública que permite descargar los datos de TCGA limpios. En el TFM se usó su REST API.
- **Papel en el TFM**: validación externa RNA-Seq. Panel LASSO entrenado en microarray aplicado a TCGA ( $n=408$ )  $\rightarrow$  AUC = 0,857. Prueba de que la firma es transferible entre plataformas.

## 0.15 Correlación de Spearman ( $\rho$ )

- Medida de asociación entre dos variables ordinales.
- $\rho = 1$ : monótona positiva perfecta;  $\rho = -1$ : monótona negativa perfecta;  $\rho \approx 0$ : sin asociación.
- **En el TFM**: la firma correlaciona negativamente con la composición alvéolo-capilar ( $\rho = -0,626$  media, hasta  $\rho = -0,858$  en GSE31210). Interpretación biológica: cuanto más tumor, menos alvéolos.

## 0.16 Streamlit y la interfaz data.lung

- **Streamlit**: framework Python para apps web interactivas sin escribir HTML/JS.
- **data.lung**: app multipágina del TFM. Portada, framework, resultados (con buscador de gen), cohortes individuales, asistente conversacional Llama acotado.
- **Reproducibilidad**: todas las cifras se leen de los CSV generados por el pipeline. Ningún número está hardcodeado.

## 0.17 Ejes biológicos reales (interpretación)

La firma no es una caja negra. Al analizarla emergen dos ejes claros:

- **Eje 1 · Pérdida alvéolo-capilar**: genes como SFTPC, SFTPB, AGER, CLDN18 (típicos de neumocitos y capilares). Cuanto más tumor, menos estos genes.
- **Eje 2 · Actividad proliferativa**: MKI67 (marcador clásico Ki-67), TOP2A, CCNB1, BIRC5, AURKA. Cuanto más agresivo, más proliferación.

Ambos se recuperan **sin haberlos declarado**: el pipeline los descubre por estadística.

## 0.18 NanoString y RT-qPCR (transferibilidad clínica)

- **NanoString nCounter**: mide expresión de un panel pequeño de genes sobre tejido fijado en formalina (FFPE). Perfecta para clínica.
- **RT-qPCR**: PCR cuantitativa. Estándar clínico para paneles muy pequeños.
- **Relevancia**: los 20 genes del panel son medibles por estas técnicas. El panel podría trasladarse a un test clínico. Diferencia clave respecto a firmas que requieren microarray/RNA-Seq.

## 0.19 Reproducibilidad

- **Definición fuerte:** cualquiera con acceso al código y datos puede regenerar todas las cifras y figuras.
- **En este TFM:** pipeline con `random_state=42` en todos los pasos aleatorizados. CSV intermedios almacenados. Código público en GitHub.

## 0.20 Objetivo del TFM en una frase

*Framework transcriptómico reproducible que integra cohortes GEO de cáncer de pulmón mediante curación con LLM, meta-análisis por consenso y clasificación LASSO validada en LODO, con una firma génica interpretable que recupera el panel diagnóstico OMS y se transfiere a RNA-Seq (TCGA).*

Si te preguntan “en una frase, qué has hecho”, esa es tu respuesta.



## Parte B · Guión diapositiva por diapositiva

**Formato de cada slide.** Timing objetivo, texto sugerido (aprender la intención, no memorizar palabra por palabra), puntos que enfatizar y transición.

### Slide 1 Portada · 30 s

#### Guión

Buenos días. Muchas gracias por estar aquí. Mi nombre es Daniel Tapia Díez y presento hoy mi Trabajo Fin de Máster, titulado *Framework transcriptómico basado en la integración de modelos de lenguaje y aprendizaje automático para la identificación de biomarcadores en cáncer de pulmón*, tutorizado por Leonardo Dulcetti. El trabajo se materializa en un framework al que hemos llamado **data.lung**, construido sobre software libre — Python, scikit-learn, Streamlit, Llama sobre Groq y GitHub — y datos públicos de NCBI GEO y del portal cBioPortal para TCGA.

**Enfatizar:** tu nombre y el nombre del framework (data.lung). “Software libre y datos públicos” = reproducibilidad.

**Transición:** “*Empecemos por el porqué del trabajo.*”

### Slide 2 Problema y objetivo · 45 s

#### Guión

El cáncer de pulmón sigue siendo la principal causa de muerte por cáncer en el mundo: **2,48 millones de casos anuales** y supervivencia a 5 años **inferior al 20 %**. Dentro del cáncer de pulmón no microcítico, distinguir adenocarcinoma de escamoso es crítico, porque tratamientos como pemetrexed o bevacizumab están **contraindicados en escamoso** por riesgo de hemorragia mortal.

Existen cientos de estudios de expresión génica públicos en GEO, pero integrarlos es difícil: plataformas heterogéneas, metadatos en texto libre y firmas génicas publicadas que muchas veces **no replican** en cohortes independientes. Nuestro objetivo ha sido construir un framework reproducible que combine tres piezas: curación de metadatos con LLM, validación externa Leave-One-Dataset-Out y una firma consenso interpretable.

**Enfatizar:** cifra clínica (2,48 M y <20 %) para dimensionar; palabra **contraindicados**; palabra **no replican** para situar el hueco.

**Transición:** “*Veamos cómo se ha construido el pipeline.*”

### Slide 3 Pipeline · 1 min 30 s

#### Guión

El pipeline tiene nueve pasos que van del **dataset crudo** hasta la **firma interpretable**. Los pasos 1 y 2 hacen la ingesta y limpieza técnica desde GEO. El paso 3 es el primero clave: usamos **Llama 3.3 de 70.000 millones de parámetros, servido con Groq**, para curar los metadatos clínicos. GEO tiene los metadatos en texto libre y las expresiones regulares se

quedan cortas; el LLM entiende contexto. Alcanzamos una tasa de éxito del **85,9 %**. Los pasos 4 a 6 son análisis diferencial cohorte a cohorte, calculando **d de Cohen**. El paso 7 es la **validación externa LODO**: cada cohorte se retira una vez y se usa como test independiente. Más conservador que la validación cruzada estándar porque respeta la agrupación por cohorte. El paso 8 es el **consenso multi-cohorte**: un gen entra en la firma sólo si mantiene el mismo signo y una magnitud mínima en las tres cohortes. El paso 9 entrega la firma final y el panel mínimo. Detalle metodológico importante: no aplicamos ComBat. LODO no corrige el efecto lote, **lo mide**.

**Enfatizar:** 85,9 % LLM. La frase “LODO no corrige el efecto lote, lo mide” es muy potente — memorízala.

**Transición:** “*Con este pipeline, estos son los resultados.*”

## Slide 4 Firma y panel mínimo · 1 min

### Guión

Partimos de **11 cohortes GEO**. Ocho cumplieron los criterios de tamaño y balance, sumando **1.157 muestras** curadas por el LLM. El análisis de consenso deja **1.174 genes validados** en las tres cohortes independientes.

A partir de ese panel amplio, aplicamos LASSO para obtener un **panel mínimo de 20 genes**. El panel de 20 genes obtiene un AUC de **0,966**, prácticamente indistinguible del 0,970 de la firma completa. Se pierde muy poca información y se gana muchísima aplicabilidad clínica.

En el top 5 aparecen **DSG3, KRT5, CALML3, KRT6B y PKP1** — todos genes de desmosomas y queratinización, biología del epitelio escamoso.

**Enfatizar:** los tres bignums (11, 8/11, 1.157) dichos despacio. “20 genes  $\approx$  firma completa” es la clave clínica.

**Transición:** “*Y estos genes son biológicamente creíbles? Miremos la validación externa.*”

## Slide 5 IHC y biología · 1 min 30 s

### Guión

La OMS publica desde 2015 un panel de marcadores IHC para el diagnóstico rutinario de cáncer de pulmón: 12 marcadores de escamoso y 8 de adenocarcinoma. La firma obtenida, seleccionada de forma **puramente estadística sin conocer ese panel**, recupera **12 de 12 marcadores escamosos y 6 de 8 adenocarcinomatosis: 18 de 20 en total, un 90 %**. Coincidencia entre selección estadística y práctica clínica: validación externa muy fuerte.

Analizando la estructura interna emergen dos ejes biológicos claros. El **primer eje** captura la pérdida alvéolo-capilar: correlación negativa con marcadores alveolares con  $\rho$  media de  $-0,626$ , llegando a  $\rho = -0,858$  en GSE31210, con p-valor del orden de  $10^{-66}$ . El **segundo eje** captura la actividad proliferativa: MKI67, TOP2A, CCNB1, BIRC5, AURKA — marcadores clásicos de proliferación tumoral.

Es decir, la firma no es una caja negra. Captura la transición biológica del pulmón sano al tejido tumoral en dos ejes que un patólogo reconoce.

**Enfatizar:** 18/20 sin haberlo declarado es tu argumento más fuerte.  $\rho = -0,858$ ,  $p \approx 10^{-66}$  son cifras impresionantes.

**Transición:** “*En cuanto a rendimiento, hemos ido más allá del AUC básico.*”

**Slide 6 Rendimiento, recalibración y TCGA · 1 min 30 s****Guión**

En la tarea **tumor vs sano**, el LODO base da un AUC de 0,925 y una BalAcc de 0,772. Al aplicar **recalibración isotónica**, el AUC sube a **0,953** y la BalAcc a **0,810**. La especificidad mejora especialmente, de 0,561 a 0,632, reduciendo falsos positivos.

Comparamos con Random Forest y SVM: LASSO 0,925, Random Forest 0,933, SVM 0,957. SVM gana ligeramente, pero elegimos LASSO por interpretabilidad — un panel de 20 genes con coeficientes explícitos es más útil clínicamente que un hiperplano SVM.

Validación en **RNA-Seq**: aplicamos el panel LASSO entrenado en microarray a **TCGA-LUAD y TCGA-LUSC**, 408 muestras. Ninguna muestra TCGA participó en la selección ni en la calibración. AUC = **0,857, con IC 95 % [0,812; 0,899] por bootstrap**. La firma se transfiere a una plataforma tecnológica distinta, lo que refuerza que la señal es biológica y no un artefacto de microarray.

**Enfatizar:** BalAcc 0,772 → 0,810 tras recalibración. AUC 0,857 en TCGA como sello de garantía externa. “Ninguna muestra TCGA participó” cierra dudas sobre *data leakage*.

**Transición:** “Y ahora, la parte más divertida. Voy a enseñaros la herramienta.”

**Slide 7 data.lung · DEMO EN VIVO · 2 min****Guión ANTES de cambiar al navegador**

Todo lo que os he contado se recoge en una herramienta interactiva multipágina que hemos llamado **data.lung**, hecha en Streamlit. Un buscador de gen en tiempo real, vistas por cohorte, y un asistente conversacional basado en Llama acotado a los resultados del trabajo — no responde nada que no esté en los datos.

Voy a enseñároslo un momento.

**Cambia a la app** (Cmd+Tab). **Secuencia recomendada:**

1. **Portada** (10 s): “Esta es la portada.”
2. **Framework** (15 s): “Aquí las cifras del framework. Todo se lee de CSV, ninguna cifra está en el código.”
3. **Resultados → Buscador de gen** (45 s):
  - Escribe DSG3: “DSG3 aparece: es uno de los cinco genes principales del panel escamoso.”
  - Escribe SFTPC: “SFTPC no aparece en el panel mínimo, aunque sí en la firma completa. Es un ejemplo de cómo LASSO reduce redundancia.”
4. **Asistente** (30 s):
  - Pregunta: “*qué biomarcadores identifica el framework?*”
  - Comentario: “Fijaos que responde con los datos concretos del trabajo, y si le pregunto algo que no está en los resultados, me lo dice explícitamente.”

**Cambia de vuelta al PDF** (Cmd+Tab): “Volvemos al PDF.”

**Antes de empezar la defensa**, tener corriendo:

```
streamlit run agentes/paso12_web_chatbot.py
```

Y la app abierta en el navegador, minimizada. Cmd+Tab probado.

**Transición:** “*Recapitulemos las conclusiones.*”

## Slide 8 Conclusiones · 45 s

### Guión

En resumen: un LLM cura los metadatos GEO con **85,9 % de éxito**, escalando la integración multi-cohorte sin intervención manual. El consenso multi-cohorte más LODO produce una firma robusta de **1.174 genes con AUC 0,968** en subtipo. El panel mínimo de **20 genes es prácticamente equivalente** a la firma completa. La firma **recupera 18 de 20 marcadores IHC clínicos sin declararlos**. La recalibración isotónica mejora significativamente el rendimiento tumor-vs-sano. Y la firma **se transfiere a RNA-Seq** con AUC 0,857 en TCGA. Todo el framework es reproducible extremo a extremo, con interfaz web pública y asistente conversacional acotado.

**Enfatizar:** es la última oportunidad de meter las cifras clave. Dilas.

**Transición:** “*Y de aquí, ¿por dónde continuaría el trabajo?*”

## Slide 9 Trabajo futuro y stack · 45 s

### Guión

El siguiente paso natural es una **validación clínica prospectiva** sobre biopsias frescas con NanoString o RT-qPCR — el panel de 20 genes está pensado para ser medible por esas técnicas. Otras líneas: ampliar a subtipos neuroendocrinos, sustituir el LLM externo por un modelo local por privacidad y coste, extender la metodología a otros tumores como mama, colon o hepatocarcinoma, y explorar firmas pronósticas con regresión de Cox sobre TCGA. Todo el trabajo está construido sobre software libre y datos públicos, y disponible en GitHub.

**Enfatizar:** **validación prospectiva** = camino hacia clínica. Software libre + datos públicos + GitHub = ética de investigación abierta.

**Transición:** “*Y con esto termino.*”

## Slide 10 Gracias · 15 s

### Guión

Muchas gracias por vuestra atención. Estoy a vuestra disposición para las preguntas que queráis plantearme.

Sonríe, respira, silencio corto. Espera el turno de preguntas.

## Parte C · Preguntas probables del tribunal

### Q1. 'Por qué no ha usado ComBat para corregir efecto lote?

R. Porque en varias cohortes GEO el efecto lote está confundido con la variable de interés — hay estudios que sólo contienen tumores, o sólo un subtipo. En ese escenario ComBat podría borrar señal biológica genuina. Prefiero un enfoque más conservador: normalizar cada cohorte por separado y exigir consenso en varias cohortes independientes. LODO complementa esto midiendo el rendimiento en la peor situación posible: una cohorte totalmente no vista.

### Q2. 'Cómo garantiza que no hay data leakage entre el descubrimiento de la firma y la validación TCGA?

R. Toda la selección de genes y la calibración se hizo exclusivamente sobre cohortes GEO en microarray. Las 408 muestras de TCGA se usaron sólo en la fase final, aplicando el modelo LASSO ya entrenado. Ninguna muestra TCGA participó en el ajuste ni en la selección de hiperparámetros.

### Q3. El LLM tiene sesgos. 'No los introduce en los datos?

R. Sí, es una preocupación real. Por eso el LLM se restringe a una tarea muy delimitada: leer una descripción de muestra y devolver una etiqueta canónica de grupo experimental. No participa en el análisis estadístico ni en la selección de genes. Además, la tasa de éxito del 85,9 % se auditó manualmente sobre un subconjunto para descartar sesgos sistemáticos.

### Q4. 'Por qué LASSO si SVM da un AUC mejor?

R. Porque un panel de 20 genes con coeficientes explícitos por gen es mucho más útil clínicamente que un hiperplano SVM. La diferencia de 3 puntos de AUC no compensa perder la interpretabilidad, sobre todo cuando el objetivo es un panel medible por NanoString o RT-qPCR.

### Q5. 'La firma es pronóstica o sólo diagnóstica?

R. En este trabajo, únicamente diagnóstica: distinguir ADC de SQC y tumor de sano. La firma pronóstica requeriría integrar tiempos de supervivencia y regresión de Cox, y está señalada como línea de trabajo futuro sobre TCGA.

### Q6. 'Qué pasa si un gen del panel no funciona por RT-qPCR en un laboratorio concreto?

R. El panel es redundante: dentro de los 20 genes hay grupos de marcadores del mismo linaje (varias queratinas y desmogleínas para escamoso; varios surfactantes para adenocarcinoma). Si uno falla técnicamente, otros del mismo grupo mantienen la señal.

### Q7. 'Por qué usar cohortes tan antiguas de microarray si RNA-Seq es el estándar hoy?

R. Porque hay más cohortes de microarray con metadatos ricos para adenocarcinoma vs escamoso, y eso permite el consenso multi-cohorte. RNA-Seq entra como validación externa para confirmar transferibilidad, no como base del descubrimiento.

**Q8. ‘No hay riesgo de que el LLM “invente” etiquetas?**

**R.** El prompt está muy acotado: se le dan las descripciones de las muestras y una lista cerrada de etiquetas posibles, con instrucción explícita de devolver **unknown** si no encaja. La tasa de éxito del 85,9 % se calcula sobre auditoría manual, y el 14,1 % restante se descarta, no se fuerza.

**Q9. ‘Qué le distingue de firmas comerciales como Pervenio Lung RS u Oncotype DX Lung?**

**R.** Tres cosas: (i) validación LODO estricta en 3 cohortes totalmente independientes, no partición aleatoria; (ii) verificación cruzada contra el panel diagnóstico OMS, que Pervenio no reporta; (iii) reproducibilidad completa con código y datos públicos. Los ensayos comerciales son cajas negras protegidas por patente.

**Q10. ‘Cómo escalaría data.lung a otros tumores?**

**R.** El framework es genérico: cambiar la fuente de datos (otras cohortes GEO y su equivalente TCGA), reentrenar la curación del LLM con las etiquetas del nuevo tumor y ejecutar el mismo pipeline. La lógica de consenso, LODO y selección LASSO no depende del tejido.

## Parte D · Checklist víspera de la defensa

---

---

- ☐ Portátil cargado + cargador.
- ☐ Adaptador HDMI/USB-C si el aula lo requiere.
- ☐ PDF de la presentación en local **y** en pen drive **y** en Drive/Dropbox.
- ☐ Streamlit corriendo antes de entrar al aula:  
`streamlit run agentes/paso12_web_chatbot.py`
- ☐ Navegador con data.lung abierto y minimizado (Cmd+Tab probado).
- ☐ Copia impresa opcional (por si falla todo).
- ☐ Botella de agua.
- ☐ Reloj visible (o el móvil en modo avión encima de la mesa).
- ☐ Respirar antes de empezar. Tres segundos de silencio son mucho menos largos de lo que crees.

*Suerte, Daniel. La memoria es rigurosa, la app funciona, los datos hablan por sí solos.  
Cuenta la historia con la tranquilidad de saber que todo está donde tiene que estar.*