

data.lung

Del dataset a una firma génica replicable

Manual teórico

Todo lo que necesitas saber
para defenderte de cualquier pregunta

Autor Daniel Tapia Díez
Universidad UAX · Máster en Bioinformática
Defensa 14 de agosto de 2026

Este documento cubre los fundamentos teóricos de biología, tecnología, estadística, aprendizaje automático y modelos de lenguaje que soportan el TFM. Se organiza en 12 partes temáticas, cada una autocontenida. Úsalo como referencia rápida ante cualquier pregunta del tribunal.

Índice

1. Cáncer de pulmón: contexto clínico	4
1.1. Epidemiología	4
1.2. Clasificación histológica	4
1.3. Diagnóstico clínico actual	4
1.4. Estadificación TNM	5
2. Biología molecular esencial	5
2.1. ADN, ARN, proteína	5
2.2. Expresión génica y transcriptoma	5
2.3. Símbolos génicos oficiales	6
3. Tecnologías de medición de expresión	6
3.1. Microarrays	6
3.2. RNA-Seq	6
4. GEO, TCGA y datos públicos	7
4.1. Gene Expression Omnibus (GEO)	7
4.2. The Cancer Genome Atlas (TCGA)	7
5. Preprocesado de expresión: normalización	7
5.1. Transformación logarítmica	8
5.2. Normalización por cuantiles	8
5.3. Por qué normalizar dentro de cada estudio y no entre estudios	8
6. Estadística para expresión génica	8
6.1. Pruebas de hipótesis: Welch, Mann-Whitney	8
6.2. Corrección de múltiples pruebas: FDR	9
6.3. Tamaño de efecto: d de Cohen	10
6.4. Correlación de Spearman (ρ)	11
6.5. Intervalos de confianza y bootstrap	11
7. Aprendizaje automático: fundamentos	11
7.1. Aprendizaje supervisado	11
7.2. Sobreajuste y sesgo-varianza	12
7.3. Regularización	12
7.4. Random Forest	13
7.5. SVM lineal	14
8. Validación cruzada, LODO y por qué importa	15
8.1. Validación cruzada estándar (k-fold)	15
8.2. Leave-One-Dataset-Out (LODO)	15
8.3. Batch effect (efecto lote)	16
9. Métricas y calibración	16
9.1. Matriz de confusión y métricas base	16
9.2. Curva ROC y AUC	16
9.3. Calibración de probabilidades	17
10. Decisiones de diseño del pipeline	18
10.1. Por qué microarrays y no sólo RNA-Seq	18

10.2. Por qué consenso multi-cohorte y no ComBat	19
10.3. Por qué $ d > 0,5$ y no otro umbral	19
10.4. Por qué 3 cohortes de consenso y no 5 o 8	19
10.5. Por qué panel mínimo de 20 genes y no 5 o 50	19
10.6. Por qué recalibración isotónica y no Platt	19
10.7. Por qué bootstrap y no otro método de IC	19
11. Modelos de lenguaje aplicados a bioinformática	20
11.1. Qué es un LLM	20
11.2. Llama 3.3-70b	20
11.3. Groq	20
11.4. Rol del LLM en el TFM	20
11.5. Alucinaciones y cómo se controlan	20
12. Consenso multi-cohorte y meta-análisis	21
12.1. Por qué integrar cohortes	21
12.2. Consenso en el TFM	21
13. Interpretabilidad: ejes biológicos	21
14. Transferibilidad clínica	22
14.1. NanoString nCounter	22
14.2. RT-qPCR	22
14.3. Por qué importa al TFM	22
15. Reproducibilidad	22
15.1. Principios	22
15.2. Data leakage	23
16. Glosario rápido	24

1 Cáncer de pulmón: contexto clínico

1.1 Epidemiología

El cáncer de pulmón es la primera causa de muerte por cáncer en el mundo. En 2022 se diagnosticaron $\approx 2,48$ millones de casos (GLOBOCAN, IARC) con $\approx 1,82$ millones de fallecimientos anuales atribuibles a la enfermedad. La supervivencia global a 5 años apenas supera el 20 %, muy por debajo de otros tumores sólidos (mama ≈ 90 %, próstata ≈ 98 %, colon ≈ 65 %).

Factores de riesgo principales: tabaco (85 % de los casos), exposición a radón, amianto, contaminación atmosférica, historia familiar y alteraciones genéticas hereditarias (aunque el componente hereditario es minoritario). En no fumadores, especialmente en mujeres asiáticas, predominan mutaciones activadoras en EGFR y ALK.

1.2 Clasificación histológica

El cáncer de pulmón se divide en dos grandes grupos:

- **Cáncer de pulmón de células pequeñas (SCLC, *Small Cell Lung Cancer*)**. Aproximadamente el 15 % de los casos. Muy agresivo, altamente asociado al tabaco, con tratamiento quimioterápico distinto y peor pronóstico.
- **Cáncer de pulmón no microcítico (NSCLC, *Non-Small Cell Lung Cancer*)**. El 85 % restante. Se subdivide en:
 - **Adenocarcinoma (ADC)**: 40–50 % de los NSCLC. Origen glandular. Aparece en la periferia del pulmón. Más común en no fumadores y en mujeres. Marcadores IHC: TTF-1/NKX2-1, napsina A.
 - **Carcinoma escamoso (SQC, LUSC)**: 25–30 %. Origen en el epitelio bronquial. Más central. Fuerte asociación con el tabaco. Marcadores IHC: p40 (isoforma TP63), CK5/6, DSG3.
 - **Carcinoma de células grandes**: poco frecuente, diagnóstico de exclusión.
 - **Tumores neuroendocrinos**: carcinoide típico y atípico. Perfil transcriptómico muy distinto.

Por qué distinguir ADC de SQC es crítico

El pemetrexed (antifolato) está contraindicado en escamoso porque no funciona con el mismo mecanismo bioquímico. El bevacizumab (antiangiogénico anti-VEGF) está contraindicado en escamoso por **riesgo de hemorragia pulmonar mortal**. Diagnosticar erróneamente un escamoso como adenocarcinoma puede matar al paciente en las primeras semanas de tratamiento. Por eso todo el pipeline se centra en esta separación binaria.

1.3 Diagnóstico clínico actual

El estándar clínico es la biopsia con estudio anatomopatológico e inmunohistoquímica (IHC). La OMS publica desde 2015 un panel de marcadores recomendados (Travis et al., 2015):

- **Escamoso**: KRT5, KRT6A, KRT6B, KRT13, KRT14, KRT15, KRT16, KRT17, CDH3, DSG3, PKP1, TP63 (12 marcadores).

- **Adenocarcinoma:** NKX2-1 (TTF-1), NAPS A (napsina A), SFTPB, SFTPC, SFTPA1, SFTPA2, MUC1, CEACAM5, CEACAM6, KRT7 (8-10 marcadores).

Estos marcadores se detectan mediante anticuerpos con revelado cromógeno. El patólogo mira al microscopio la muestra teñida y determina el subtipo basándose en el patrón de tinción.

1.4 Estadificación TNM

Sistema TNM (*Tumor, Nodes, Metastasis*) de la AJCC. T describe tamaño e invasión local, N el compromiso ganglionar, M la presencia de metástasis a distancia. Estadios I–IV. En este TFM las cohortes mezclan estadios variables y se trabaja sobre la clasificación histológica, no la TNM.

2 Biología molecular esencial

2.1 ADN, ARN, proteína

El **dogma central de la biología molecular** (Crick, 1958) establece el flujo de información:



- **ADN** (ácido desoxirribonucleico): molécula que contiene el genoma. Doble hélice de nucleótidos. En humanos, ~3 mil millones de pares de bases y ~20 000 genes codificantes de proteína.
- **Gen:** fragmento de ADN que codifica una proteína o una función reguladora (por ejemplo un ARN no codificante).
- **ARN mensajero (mRNA):** copia de un gen transcrito, que sale del núcleo hacia el citoplasma para ser traducido a proteína.
- **Proteína:** producto funcional. Ejecuta la mayor parte de las funciones celulares (estructural, catalítica, señalización).

2.2 Expresión génica y transcriptoma

Aunque todas las células de un individuo comparten el mismo ADN, no transcriben los mismos genes al mismo tiempo. La célula *expresa* un gen cuando lo transcribe activamente a mRNA. El conjunto de todos los mRNAs presentes en una muestra biológica en un momento dado se llama **transcriptoma**. Es un retrato dinámico del estado funcional de la célula.

Medir el transcriptoma equivale a medir cuántas copias de mRNA hay de cada gen. Los valores se expresan típicamente en escala logarítmica ($\log_2$) porque abarcan varios órdenes de magnitud y porque en escala log las diferencias biológicas se aproximan a una distribución gaussiana.

Qué “mide” realmente el transcriptoma

No mide directamente actividad celular. Mide **abundancia relativa de mRNA**. Hay una correlación razonable entre nivel de mRNA y nivel de proteína, pero no perfecta: los mRNAs pueden estar retenidos, no traducirse, o las proteínas pueden ser muy estables o degradarse rápidamente. En el TFM asumimos — como toda la literatura de firmas génicas — que las diferencias sostenidas de mRNA reflejan cambios funcionales relevantes.

2.3 Símbolos génicos oficiales

Cada gen humano tiene un símbolo oficial asignado por HGNC (*HUGO Gene Nomenclature Committee*). Ejemplos: *TP53*, *EGFR*, *KRT5*, *DSG3*. Los símbolos evolucionan con el tiempo (algunos se renombran); las bases de datos de expresión usan la versión vigente en el momento en que el fabricante del chip anotó las sondas.

3 Tecnologías de medición de expresión

3.1 Microarrays

Un microarray es un chip de vidrio del tamaño de una diapositiva con decenas de miles de **sondas** de ADN adheridas en posiciones conocidas. Cada sonda es una secuencia de ~ 25 nucleótidos complementaria a un fragmento de un mRNA específico. Al hibridar una muestra biológica marcada con fluorescencia:

1. Se extrae ARN total de la muestra.
2. Se retrotranscribe a cDNA con fluorefóros.
3. Se hibrida sobre el chip: los cDNAs se unen a sus sondas complementarias.
4. Se escanea la fluorescencia: cada punto brilla proporcionalmente a la cantidad de cDNA que se unió.

Plataforma más común en el TFM: **Affymetrix HG-U133 Plus 2.0** (identificador GEO GPL570), $\sim 54\,675$ sondas para $\sim 20\,000$ genes. Redundancia (varias sondas por gen) para robustez estadística.

Ventajas y limitaciones

Ventajas: barato, rápido, gran base histórica de datos. Limitaciones: rango dinámico comprimido, difícil detectar transcritos nuevos, sesgo por secuencia de sonda.

3.2 RNA-Seq

RNA-Seq secuencia directamente el mRNA:

1. Se extrae mRNA y se fragmenta.
2. Se retrotranscribe a cDNA.
3. Se secuencian los fragmentos generando *reads* de ~ 100 bases (Illumina).
4. Cada read se alinea al genoma o transcriptoma de referencia.
5. Se cuentan reads por gen (o por transcrito).

Ventajas: alto rango dinámico, detecta variantes nuevas, cuantitativo. Limitaciones: coste (aunque cayendo), requerimientos computacionales.

Unidades típicas:

- **Raw counts**: número de reads por gen.

- **TPM** (*Transcripts Per Million*): normaliza por longitud del gen y por profundidad de secuenciación.
- **FPKM** (*Fragments Per Kilobase per Million*): similar, para paired-end.
- **RSEM**: estimador estadístico que reparte reads que mapean ambiguamente. Usado por TCGA.

En el TFM: entrenamos en microarray, validamos en RNA-Seq (TCGA con RSEM). Que un panel funcione en ambas plataformas es evidencia de que la señal es **biológica y no artefactual**.

4 GEO, TCGA y datos públicos

4.1 Gene Expression Omnibus (GEO)

Repositorio del NCBI (EE. UU.) que aloja más de 200 000 estudios de expresión génica desde el año 2000. Terminología:

- **GSE** (*Gene Series*): un estudio completo, ejemplo GSE31210.
- **GSM** (*Gene Sample*): una muestra individual dentro de un estudio.
- **GPL** (*Gene Platform*): la plataforma tecnológica usada (chip Affymetrix, etc.). Cada GPL trae su tabla de anotación con la correspondencia sonda → gen.

Los metadatos clínicos en GEO están en **texto libre** sin estructura estándar. Cada laboratorio los redacta como quiere: en `characteristics_ch1` puede aparecer “*primary lung tumor, LUSC, stage III*” o “*sample from patient with squamous cell carcinoma*”. Automatizar la clasificación requiere leer y entender lenguaje natural: por eso el TFM usa un LLM.

4.2 The Cancer Genome Atlas (TCGA)

Gran consorcio del NIH americano que caracterizó molecularmente ~11 000 tumores humanos entre 2006 y 2018. Para pulmón hay dos proyectos:

- **TCGA-LUAD**: ~517 adenocarcinomas con expresión RNA-Seq, mutaciones, metilación, clínicos.
- **TCGA-LUSC**: ~504 escamosos, misma caracterización.

En el TFM se usan $230 \text{ LUAD} + 178 \text{ LUSC} = 408$ muestras a través de la **API REST de cBioPortal**, que sirve datos TCGA ya limpios y homogeneizados. La transferencia del panel LASSO entrenado en microarray a TCGA RNA-Seq da $\text{AUC} = 0,857$ con IC 95 % [0,812; 0,899].

5 Preprocesado de expresión: normalización

Antes de cualquier análisis estadístico hay tres transformaciones estándar sobre matrices de expresión.

5.1 Transformación logarítmica

Las intensidades de sonda de microarray abarcan varios órdenes de magnitud (10 a 65 000 en escala cruda). Aplicamos $x' = \log_2(x + 1)$:

- Aproxima las distribuciones a gaussianas (requisito de tests paramétricos).
- Convierte diferencias multiplicativas en aditivas: una diferencia de $2\times$ en escala cruda equivale a $+1$ en escala $\log_2$.
- El “ $+1$ ” evita $\log_2(0) = -\infty$.

En RNA-Seq (counts), el estándar equivalente es $\log_2(TPM + 1)$ o transformaciones variance-stabilizing (VST, DESeq2).

5.2 Normalización por cuantiles

Iguala las distribuciones de intensidad entre muestras. Algoritmo:

1. Ordenar cada muestra de menor a mayor intensidad.
2. Reemplazar cada valor por la media de esa posición entre todas las muestras.
3. Devolver los valores a la posición original de cada muestra.

Resultado: todas las muestras tienen exactamente la misma distribución (mismo cuantil, misma media, misma mediana). Asume que la distribución *global* de expresión es comparable entre muestras — razonable cuando la mayoría de genes no cambia entre condiciones.

Alternativas: RMA (Robust Multi-array Average, específica de Affymetrix), MAS5, VSN. En el TFM usamos $\log_2 +$ cuantiles por su simplicidad y aceptación histórica.

5.3 Por qué normalizar dentro de cada estudio y no entre estudios

Normalizar por cuantiles *entre estudios* es una forma implícita de corrección de lote: fuerza a que las cohortes tengan la misma distribución, borrando diferencias técnicas... y biológicas. Si una cohorte está enriquecida en tumores agresivos, cuantilar contra otra menos agresiva puede borrar la señal. Por eso normalizamos *dentro* de cada cohorte y confiamos en la exigencia del consenso multi-cohorte para descartar artefactos.

6 Estadística para expresión génica

6.1 Pruebas de hipótesis: Welch, Mann-Whitney

Comparar la expresión media de un gen entre dos grupos (tumor vs sano):

- **t de Student** asume varianzas iguales y normalidad. Poco robusto.
- **t de Welch**: modificación que no asume varianzas iguales. Es el estándar en expresión génica log-transformada. Usado en el paso 5 del pipeline.
- **Mann-Whitney U**: alternativa no paramétrica. Útil cuando la distribución es muy asimétrica.

Estadístico t de Welch:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Los grados de libertad se calculan con la aproximación de Welch-Satterthwaite:

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

Cuándo cada uno:

- Con $n_i \geq 30$ por grupo y datos log-transformados: t de Welch robusto.
- Con $n_i < 20$ o distribuciones muy sesgadas: Mann-Whitney U más conservador.
- Si se detecta bimodalidad severa: pruebas específicas de mezcla (ejemplo: modelos de mezcla gaussiana).

Nunca se debe seleccionar el test tras mirar los datos y ver cuál da mejor p -valor: eso es *p-hacking*. El TFM prefija Welch como test principal para toda la matriz de expresión, con FDR de Benjamini-Hochberg.

Supuestos, robustez y qué pasa si se violan

Los supuestos de la t de Welch son:

1. Muestras independientes entre y dentro de grupos.
2. Distribución aproximadamente simétrica (no necesariamente gaussiana con n grande, por el TLC).
3. Sin outliers extremos.

Violaciones y consecuencias:

- **Dependencia entre muestras** (ejemplo: réplicas técnicas del mismo paciente): inflan la significancia. Se soluciona con modelos mixtos (`lmer`) o promediando réplicas antes del test.
- **Asimetría severa**: el t -test sigue siendo válido con $n \geq 30$ por grupo pero pierde potencia. Alternativa: Mann-Whitney.
- **Outliers**: el t -test es sensible. En genómica, un outlier de expresión suele ser artefacto técnico. La normalización por cuantiles y el $\log_2$ los reducen; queda como límite conocido.

6.2 Corrección de múltiples pruebas: FDR

Cuando se hacen 20 000 tests (uno por gen), a $\alpha = 0,05$ se esperan 1 000 falsos positivos por azar. Soluciones:

- **Bonferroni**: dividir α por el número de tests. Muy conservador, elimina señal real.
- **Benjamini-Hochberg (BH-FDR)**: controla la *proporción esperada de falsos positivos entre los rechazos*. Menos conservador, estándar en genómica. El TFM usa BH-FDR.

El *q-value* (FDR-adjusted) de un gen se calcula ordenando los p-valores de menor a mayor y multiplicando cada uno por m/i (con m = número total de tests, i = posición en el ranking). Un $q\text{-value} < 0,05$ significa: “en el conjunto de genes con $q < 0,05$, esperamos menos del 5 % de falsos positivos”.

FWER vs FDR

- **FWER** (Family-Wise Error Rate): probabilidad de cometer *al menos un* falso positivo. Controlado por Bonferroni.
- **FDR** (False Discovery Rate): proporción *esperada* de falsos positivos entre los resultados declarados positivos. Controlado por BH.

Cuándo cada uno:

- FWER cuando el coste de un falso positivo es crítico (ensayos clínicos regulatorios).
- FDR cuando se generan hipótesis para investigación posterior (análisis exploratorio de expresión).
Estándar en genómica.

Otros métodos: Holm-Bonferroni (secuencial FWER, más potente que Bonferroni), Storey-Tibshirani q -value (versión más sofisticada de FDR con estimación de π_0).

6.3 Tamaño de efecto: d de Cohen

El p-valor solo dice “la diferencia es estadísticamente significativa”. No dice si la diferencia es **importante**. La d de Cohen mide el tamaño de efecto en unidades de desviación típica:

$$d = \frac{\bar{x}_{\text{grupo A}} - \bar{x}_{\text{grupo B}}}{s_{\text{pooled}}}$$

donde s_{pooled} es la desviación típica combinada. Convenciones: $|d| < 0,2$ trivial, $0,2\text{-}0,5$ pequeño, $0,5\text{-}0,8$ moderado, $> 0,8$ grande.

En el TFM: un gen entra en la firma de consenso sólo si $|d| > 0,5$ y con el mismo signo en las 3 cohortes independientes.

Otras medidas de tamaño de efecto

- **Hedges g** : variante de Cohen d corregida por sesgo para muestras pequeñas. Multiplica d por $J = 1 - 3/(4(n_1 + n_2) - 9)$.
- **Glass Δ** : usa solo la desviación del grupo control. Útil cuando los grupos difieren mucho en dispersión.
- **Log₂ Fold Change (log2FC)**: estándar en RNA-Seq. Simplemente la diferencia de medias en escala log. Equivalente al numerador de d pero sin estandarizar.

Por qué d y no log2FC en el TFM

El log2FC es la cantidad “biológica” (magnitud del cambio) pero no tiene en cuenta la dispersión. Dos genes pueden tener el mismo log2FC pero uno con dispersión pequeña (efecto claro) y otro con dispersión enorme (mero ruido). El d de Cohen combina magnitud y dispersión en un solo número, más robusto para meta-análisis por consenso.

6.4 Correlación de Spearman (ρ)

Mide asociación monótona entre dos variables ordinales:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde d_i es la diferencia de rangos. Rango $[-1, +1]$. Diferencia crucial vs Pearson: Spearman no asume linealidad, solo monotonidad. Útil cuando las escalas no son directamente comparables.

Uso en el TFM: correlacionar el score LASSO con marcadores de composición alvéolo-capilar. $\rho = -0,626$ media (4 cohortes con muestra suficiente), hasta $\rho = -0,858$ en GSE31210 con $p = 1,1 \cdot 10^{-66}$.

Spearman vs Pearson

- **Pearson** r : asume relación *lineal*. Sensible a outliers. Útil cuando las dos variables están en escalas comparables y la relación es lineal.
- **Spearman** ρ : transforma a rangos y aplica Pearson sobre rangos. Captura cualquier relación *monótona*, no sólo lineal. Robusto frente a outliers. **Estándar en genómica**.
- **Kendall** τ : alternativa a Spearman más robusta, computacionalmente más cara.

6.5 Intervalos de confianza y bootstrap

Un **IC 95 %** no significa “hay 95 % de probabilidad de que el valor real esté en el intervalo”. Significa: “si repitiéramos el experimento muchas veces, el 95 % de los intervalos resultantes contendrían el valor verdadero”.

Bootstrap: técnica de remuestreo para estimar la distribución de una métrica sin asumir distribución teórica:

1. Del conjunto original de n muestras, se toma una muestra de n con reemplazo (bootstrap sample).
2. Se calcula la métrica.
3. Se repite B veces (típicamente $B = 1\,000$).
4. El IC 95 % son los percentiles 2,5 y 97,5 de esos B valores.

En el TFM: $B = 1\,000$ bootstraps sobre las predicciones LODO. AUC pooled = 0,943 con IC 95 % [0,925; 0,959]. En TCGA: AUC 0,857 con IC [0,812; 0,899].

7 Aprendizaje automático: fundamentos

7.1 Aprendizaje supervisado

- **Regresión**: predecir una variable continua (ejemplo: supervivencia en meses).
- **Clasificación**: predecir una etiqueta discreta (ejemplo: tumor vs sano, ADC vs SQC).

En el TFM: dos problemas de clasificación binaria.

7.2 Sobreajuste y sesgo-varianza

El dilema fundamental del ML:

- **Sesgo alto (underfitting)**: modelo demasiado simple, no captura la señal.
- **Varianza alta (overfitting)**: modelo demasiado complejo, memoriza el ruido del entrenamiento y falla en datos nuevos.

En expresión génica ($p \gg n$, con $p = 20\,000$ genes y $n = 100$ muestras) el riesgo de sobreajuste es extremo. Toda la metodología del TFM (regularización L1, validación LODO externa, consenso multi-cohorte) está diseñada para *controlar la varianza*.

7.3 Regularización

Modificación de la función de coste para penalizar modelos complejos:

- **L2 (Ridge)**: penaliza suma de coeficientes al cuadrado. Suaviza. Todos los coeficientes se reducen pero ninguno llega a cero.
- **L1 (LASSO)**: penaliza suma de valores absolutos. Fuerza a que muchos coeficientes sean **exactamente cero**: selección de variables automática.
- **Elastic Net**: combinación L1 + L2.

Función de coste LASSO para regresión logística:

$$\mathcal{L} = - \sum_i \log P(y_i | x_i, \beta) + \lambda \sum_j |\beta_j|$$

λ (o su inverso $C = 1/\lambda$) es el hiperparámetro que controla la fuerza de la penalización. Se ajusta por validación cruzada.

Interpretación geométrica L1 vs L2

L1 y L2 son básicamente formas geométricas distintas de la región factible:

- **L2 (Ridge)**: región factible es una *esfera* ($\sum \beta_j^2 \leq t$). El óptimo suele tocarla en un punto donde todos los β_j son pequeños pero no cero.
- **L1 (LASSO)**: región factible es un *rombo* ($\sum |\beta_j| \leq t$). Las esquinas del rombo están sobre los ejes coordenados; el óptimo tiende a tocar en una esquina, **poniendo coeficientes a exactamente cero**.

Por eso L1 hace selección de variables automática y L2 no.

Elección de C : validación cruzada anidada

El hiperparámetro C controla el tamaño del panel:

- C pequeño $\rightarrow$ mucha regularización $\rightarrow$ pocos genes con coeficiente no-cero (panel muy pequeño, quizás sesgado).
- C grande $\rightarrow$ poca regularización $\rightarrow$ muchos genes seleccionados (panel grande, riesgo de sobreajuste).

Se ajusta con **CV anidada**:

1. Bucle externo: LODO (cada cohorte fuera una vez).
2. Bucle interno: sobre las cohortes de entrenamiento, CV k-fold para elegir el mejor C .
3. El C elegido en el bucle interno se aplica al modelo final del bucle externo.

La CV anidada evita usar la cohorte de test para elegir el hiperparámetro (data leakage sutil).

Algoritmo de resolución: coordinate descent

El término $|\beta_j|$ no es diferenciable en cero, por lo que no se puede resolver con Newton-Raphson estándar. La biblioteca **scikit-learn** usa **coordinate descent**: optimiza un coeficiente por vez manteniendo los demás fijos, aprovechando que para un solo coeficiente el subproblema tiene solución cerrada (operador de *soft-thresholding*).

En el TFM: LASSO L1 sobre regresión logística, con C ajustado por CV interna. Produce un panel de 20 genes con coeficientes distintos de cero. Los otros $\sim 1\,150$ genes candidatos se descartan automáticamente.

Interpretar los coeficientes LASSO

Los coeficientes β_j tras entrenar están en escala *estandarizada* (todas las variables escaladas a media 0 y desviación 1). Un coeficiente $\beta_j = +0,45$ significa: por cada desviación típica que aumenta la expresión del gen j , el log-odds de la clase positiva aumenta en 0,45.

Cuidado: en LASSO los coeficientes están sesgados hacia cero por la penalización. Para interpretación cuantitativa fina se recomienda *post-selection inference* (reentrenar OLS sobre las variables seleccionadas) o intervalos de confianza por bootstrap sobre los coeficientes.

7.4 Random Forest

Ensamble de **árboles de decisión** contruidos con dos fuentes de aleatoriedad:

1. **Bagging:** cada árbol se entrena sobre una muestra bootstrap de los datos (subconjunto con reemplazo).
2. **Selección aleatoria de variables:** en cada división interna del árbol, solo se consideran $\sqrt{p}$ variables aleatorias.

Predicción final: voto mayoritario (clasificación) o promedio (regresión). Random Forest ofrece **importancia de variable** (cuántas veces se selecciona cada gen en las divisiones) como complemento a la interpretación.

Hiperparámetros clave

- **n_estimators:** número de árboles. Más = mejor pero con retorno decreciente. 100-500 típico.
- **max_depth:** profundidad máxima de cada árbol. Si **None**, crecen hasta hojas puras (overfitting en algunos casos).
- **min_samples_leaf:** mínimo de muestras por hoja. Regularización efectiva.
- **max_features:** variables consideradas en cada división. Por defecto $\sqrt{p}$ en clasificación.

Error OOB (out-of-bag)

Cada árbol se entrena con una muestra bootstrap (~63 % de las muestras originales). El ~37 % restante son *out-of-bag* para ese árbol. Se puede evaluar el error del bosque promediando predicciones OOB. **Es un estimador insesgado del error de generalización sin necesidad de CV.**

Importancia de variable

Dos métodos principales:

- **Mean Decrease Impurity (MDI, Gini importance):** cuánto reduce la impureza cada variable al usarse en divisiones. Rápida pero *sesgada hacia variables continuas o con muchas categorías*.
- **Permutation importance:** permutar valores de una variable y medir la caída de rendimiento. Más costosa pero no sesgada.

En el TFM: Random Forest se usa como *sanity check* vs LASSO, confirmando que los genes seleccionados por LASSO también aparecen altos en el ranking RF.

7.5 SVM lineal

Support Vector Machine busca el **hiperplano óptimo** que separa dos clases maximizando el margen (distancia a los puntos más cercanos de cada clase). En su versión lineal es esencialmente una regresión logística con otra función de pérdida (*hinge loss*) y otra regularización. En dimensiones altas rinde bien, pero los pesos no son directamente interpretables como “importancia de gen”.

Formulación primal SVM lineal (soft-margin):

$$\min_{w,b,\xi} \quad \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$$

sujeto a $y_i(w \cdot x_i + b) \geq 1 - \xi_i$, $\xi_i \geq 0$.

C controla la tolerancia a errores: C grande $\rightarrow$ margen estrecho, poca tolerancia; C pequeño $\rightarrow$ margen amplio, más tolerancia. Los puntos con $\xi_i > 0$ son *vectores soporte*: definen el hiperplano.

Kernel trick

Para relaciones no lineales, SVM proyecta implícitamente los datos a un espacio de mayor dimensión donde sí son linealmente separables, usando funciones kernel $K(x_i, x_j)$:

- **Lineal:** $K(x, x') = x \cdot x'$. Es SVM lineal.
- **Polinomial:** $K(x, x') = (\gamma x \cdot x' + r)^d$.
- **RBF (Gaussiano):** $K(x, x') = \exp(-\gamma \|x - x'\|^2)$. El más popular.

En el TFM se usa *sólo* SVM lineal por interpretabilidad comparativa (kernel no lineal complica la extracción de importancia de gen).

Por qué LASSO y no SVM en el TFM

Comparativa LODO: LASSO 0,925, RF 0,933, SVM 0,957 (AUC media). SVM gana en rendimiento por 3 puntos, pero: (i) los coeficientes SVM no son directamente interpretables clí-

nicamente, (ii) LASSO ya produce un panel discreto de 20 genes traducible a NanoString / RT-qPCR, (iii) la diferencia de rendimiento es menor que la variabilidad entre cohortes. LASSO se elige por su balance **rendimiento-interpretabilidad**.

8 Validación cruzada, LODO y por qué importa

8.1 Validación cruzada estándar (k-fold)

Se divide el conjunto de datos en k partes iguales (folds). Se entrena con $k - 1$ y se evalúa con la restante. Se rota k veces. Al final se promedia el rendimiento. $k = 5$ o $k = 10$ son comunes.

Problema en genómica multi-cohorte: si mezclas muestras de todas las cohortes en los folds, dos muestras del mismo estudio pueden acabar una en train y otra en test. Como comparten sesgos técnicos (chip, lote, laboratorio), el modelo *aprende* el sesgo técnico y da AUCs inflados.

8.2 Leave-One-Dataset-Out (LODO)

Variante estricta: cada *cohorte completa* se retira una vez del entrenamiento y se usa como test. Si hay 8 cohortes:

- Iteración 1: entrenar con 7, testear con cohorte 1.
- Iteración 2: entrenar con 7 (otra combinación), testear con 2.
- ... 8 iteraciones en total.

Ninguna muestra de la cohorte de test aparece nunca en el entrenamiento. Es el estándar oro de validación externa en meta-análisis transcriptómicos. El AUC bajo LODO es típicamente 5-15 puntos más bajo que bajo CV estándar — porque LODO *no infla* por sesgo compartido de cohorte.

Otras estrategias de partición

- **Hold-out**: dividir 80/20. Rápido pero de alta varianza.
- **Stratified k-fold**: mantiene la proporción de clases en cada fold.
- **Group k-fold**: mantiene grupos (paciente, familia) sin cruzar entre folds.
- **Leave-One-Out (LOO)**: caso extremo con $k = n$. Muy caro y de alta varianza en genómica.
- **Nested CV**: CV externa + CV interna para elegir hiperparámetros. Estándar cuando hay hiperparámetros a ajustar.

En el TFM se combina **LODO externa** (cohorte fuera) con **k-fold interna** sobre las cohortes de train para elegir el C del LASSO. Es CV anidada donde la partición externa respeta grupos de cohorte.

Frase para la defensa

“LODO no corrige el efecto lote entre cohortes: lo mide. Si la firma resulta robusta bajo LODO, es porque los genes seleccionados mantienen su patrón de cambio a pesar del efecto lote, lo que es una propiedad deseable.”

8.3 Batch effect (efecto lote)

Diferencias sistemáticas entre muestras atribuibles al lote técnico (chip usado, reactivos, operador, fecha, laboratorio). En cohortes GEO combinadas, gran parte de la varianza total viene del efecto lote y no de la biología.

ComBat y por qué NO lo usamos

ComBat (Johnson et al., 2007) es un método bayesiano empírico que “corrige” el efecto lote normalizando las cohortes conjuntamente. Problema: si el efecto lote está *confundido* con la variable de interés (ejemplo: un centro solo aporta tumores, otro solo controles), ComBat borra también la señal biológica.

En el TFM: no aplicamos ComBat. En su lugar (i) normalizamos *dentro* de cada cohorte, (ii) exigimos consenso multi-cohorte para seleccionar genes, (iii) usamos LODO como criterio de rendimiento. Estrategia conservadora pero honesta.

9 Métricas y calibración

9.1 Matriz de confusión y métricas base

Para clasificación binaria (positivo/negativo):

	Predicho +	Predicho −
Real +	TP (verdadero positivo)	FN (falso negativo)
Real −	FP (falso positivo)	TN (verdadero negativo)

Métricas:

- **Sensibilidad (recall, TPR):** $TP/(TP + FN)$. De todos los positivos reales, cuántos detecto.
- **Especificidad (TNR):** $TN/(TN + FP)$. De todos los negativos reales, cuántos descarto correctamente.
- **Precisión (PPV):** $TP/(TP + FP)$. De los que predije positivos, cuántos lo son. **Depende de la prevalencia.**
- **Balanced Accuracy:** media de sensibilidad y especificidad. Útil con clases desbalanceadas.
- **Accuracy ingenua:** $(TP + TN)/N$. En clases desbalanceadas puede ser engañosa (predecir siempre la clase mayoritaria puede dar 90 %).

9.2 Curva ROC y AUC

ROC (Receiver Operating Characteristic): representa sensibilidad frente a 1−especificidad para todos los umbrales de decisión. El área bajo esta curva (**AUC**) es una métrica *umbral-independiente*:

- $AUC = 0,5$: modelo al azar.
- $AUC = 1,0$: perfecto.
- $AUC \geq 0,9$: excelente discriminación.
- $AUC \geq 0,8$: buena discriminación.

Interpretación probabilística: AUC es la probabilidad de que el modelo ordene una muestra positiva por encima de una negativa. Útil para comparar modelos independientemente del umbral, pero *no dice* si las probabilidades están calibradas.

Curva Precision-Recall (PR)

Alternativa a ROC especialmente útil en **clases muy desbalanceadas**. Representa precisión vs recall.

- ROC puede parecer “buena” incluso con clasificador inútil si hay mucho desbalance (TNR alto por defecto).
- PR es más informativa cuando la clase positiva es rara.

En el TFM: las clases están moderadamente balanceadas en las cohortes evaluables (ratio tumor:sano suele estar entre 1:1 y 3:1), por lo que ROC es adecuada. Cuando la desviación es extrema (GSE31210 tiene 226 tumores vs 20 sanos), reportamos también balanced accuracy y sensibilidad/especificidad por separado.

DeLong test para comparar AUCs

Para comparar dos AUCs sobre el mismo conjunto de test (por ejemplo LASSO vs SVM), no se puede simplemente comparar los valores puntuales. El test de DeLong (1988) da un p -valor para $H_0 : AUC_1 = AUC_2$ teniendo en cuenta la correlación entre los rankings.

En el TFM no aplicamos DeLong formalmente porque nos apoyamos en los IC bootstrap para comparar modelos.

9.3 Calibración de probabilidades

Un modelo con AUC alto puede tener probabilidades **descalibradas**: predice 0,9 y en realidad la clase real ocurre el 60 % de las veces. La calibración es distinta de la discriminación:

- **Platt scaling**: ajusta una regresión logística sobre la puntuación cruda del modelo. Asume forma sigmoidea.
- **Regresión isotónica**: aprende una función *monótona no paramétrica*. Más flexible pero requiere más datos.

En el TFM: se aplican ambas sobre las predicciones LODO. Isotónica mejora BalAcc de 0,772 $\rightarrow$ 0,810 y AUC de 0,925 $\rightarrow$ 0,953. Platt degrada el modelo (BalAcc 0,772 $\rightarrow$ 0,639). Por eso se selecciona isotónica.

Brier score: métrica de calibración. Media del cuadrado del error entre probabilidad predicha p_i y etiqueta real $y_i \in \{0, 1\}$:

$$BS = \frac{1}{n} \sum_i (p_i - y_i)^2$$

Menor es mejor. $BS = 0$: perfecta calibración y discriminación.

Diagrama de fiabilidad (reliability plot)

Herramienta visual de calibración:

1. Se dividen las muestras en bins según su probabilidad predicha (ejemplo: 10 bins de ancho 0,1).
2. Para cada bin se calcula la *frecuencia observada* de la clase positiva.
3. Se representa probabilidad predicha (x) vs frecuencia observada (y).
4. Un modelo perfectamente calibrado cae sobre la diagonal $y = x$.

Otras métricas: ECE (Expected Calibration Error), MCE (Maximum Calibration Error).

Por qué isotónica ganó a Platt en el TFM

- Platt scaling asume que la relación score-probabilidad es sigmoidea. Si no lo es, no puede corregirla.
- Isotónica es no paramétrica: solo asume monotonidad. En cohortes heterogéneas, la relación real puede no ser sigmoidea y isotónica la captura mejor.
- Riesgo de isotónica: puede sobreajustar con pocas muestras. Con $n < 100$ Platt suele ser preferible.

En el TFM los conjuntos LODO por cohorte son suficientes ($n \geq 100$ en la mayoría) para que isotónica sea robusta.

Manejo del desbalance de clases

Cuando las clases están muy desbalanceadas ($> 1 : 5$), el modelo tiende a predecir la clase mayoritaria. Estrategias:

- **Pesos de clase:** multiplicar la pérdida por $w_c = n/(K \cdot n_c)$. **Estrategia por defecto en el TFM** (`class_weight="balanced"` en scikit-learn).
- **Oversampling:** duplicar la clase minoritaria (ejemplo: SMOTE, que genera muestras sintéticas por interpolación).
- **Undersampling:** submuestrear la clase mayoritaria. Pierde información.
- **Ajustar el umbral de decisión:** si el AUC es bueno pero el modelo predice todo como mayoritario, bajar el umbral.

10 Decisiones de diseño del pipeline

Anticipación a preguntas del tribunal “por qué X y no Y”.

10.1 Por qué microarrays y no sólo RNA-Seq

- Hay muchas más cohortes de microarray en GEO con metadatos ricos para ADC vs SQC.
- RNA-Seq es plataforma más reciente; combinar decenas de cohortes RNA-Seq con metadatos consistentes es difícil.
- La firma se valida después en RNA-Seq (TCGA), demostrando transferibilidad.

10.2 Por qué consenso multi-cohorte y no ComBat

Cubierto arriba: ComBat puede borrar señal biológica cuando el lote confunde con la variable de interés. Consenso es más conservador.

10.3 Por qué $|d| > 0,5$ y no otro umbral

Umbral clásico de Cohen para efecto “moderado”. Es un compromiso:

- $|d| > 0,2$: demasiado permisivo, entran genes con efecto pequeño que pueden ser artefacto.
- $|d| > 0,8$: demasiado exigente, se pierden genes con efecto moderado pero muy reproducible.
- $|d| > 0,5$: convención estándar, filtra ruido sin descartar biología legítima.

10.4 Por qué 3 cohortes de consenso y no 5 o 8

Trade-off entre reproducibilidad y disponibilidad:

- Exigir 8 cohortes reduce dramáticamente el número de genes que pasan y perdería señal clínicamente relevante.
- Exigir 3 cohortes independientes ya es más estricto que la mayoría de firmas publicadas (que validan en 0 o 1 cohorte independiente).
- El resto de cohortes (5) se usan como test LODO, no como entrenamiento, para validación externa adicional.

10.5 Por qué panel mínimo de 20 genes y no 5 o 50

Curva panel vs AUC (PANEL_MINIMO_CURVA.csv):

- Con 5 genes: $AUC \approx 0,91$. Muy compacto pero pierde redundancia biológica.
- Con 20 genes: $AUC \approx 0,966$. Plateau: añadir más no mejora significativamente.
- Con 50 genes: $AUC \approx 0,97$. Rendimiento prácticamente idéntico al panel completo.

20 es el “codo” de la curva y coincide con el tamaño del panel OMS IHC, lo que facilita la interpretación comparativa.

10.6 Por qué recalibración isotónica y no Platt

Cubierto arriba: isotónica ganó experimentalmente en el TFM (BalAcc $0,772 \rightarrow 0,810$ vs Platt $0,772 \rightarrow 0,639$).

10.7 Por qué bootstrap y no otro método de IC

- **IC analíticos** (asumen normalidad): AUC no tiene una distribución cerrada simple.
- **Jackknife**: variante de bootstrap con leave-one-out. Más barato pero de mayor sesgo.
- **Bootstrap percentil**: estándar oro para métricas no lineales como AUC. **Elegido en el TFM.**

11 Modelos de lenguaje aplicados a bioinformática

11.1 Qué es un LLM

Un modelo de lenguaje grande (LLM) es una red neuronal profunda entrenada con enormes cantidades de texto para predecir la siguiente palabra dado un contexto. Arquitectura dominante: **transformer** (Vaswani et al., 2017), basado en el mecanismo de *atención*.

Escalas modernas: 1–700 mil millones de parámetros. Modelos representativos: GPT-4 (OpenAI, cerrado), Claude (Anthropic, cerrado), Gemini (Google), Llama (Meta, abierto), Mistral (europeo, abierto).

11.2 Llama 3.3-70b

Publicado por Meta AI a finales de 2024. 70 mil millones de parámetros. Rendimiento comparable a GPT-4o en benchmarks académicos. Ventaja clave: es **open weights**, se puede desplegar donde uno quiera, sin depender de una API cerrada ni exponer datos sensibles.

11.3 Groq

Empresa que desarrolla hardware específico (**LPU**, *Language Processing Unit*) optimizado para inferencia de LLMs. Consigue latencias 5–10× más rápidas que GPU tradicionales para el mismo modelo. Ofrece API pública que sirve Llama con costes muy bajos y velocidad de decenas de tokens por segundo.

11.4 Rol del LLM en el TFM

Tarea única y bien delimitada: leer una descripción de muestra GEO (texto libre) y devolver una etiqueta canónica del grupo experimental.

Prompt estructurado:

- Rol: “eres un experto anotador de datos biomédicos”.
- Contexto: descripción de la muestra + metadatos del estudio.
- Instrucción: elige entre lista cerrada de etiquetas.
- Regla de escape: si no encaja ninguna, devuelve **unknown**.

Tasa de éxito global: 82,8 % (curados sobre descargados). Las muestras que el LLM no puede clasificar se descartan, no se fuerzan.

11.5 Alucinaciones y cómo se controlan

Alucinación: el LLM inventa información que no está en el prompt. Es un modo de fallo conocido.

Mitigaciones en el TFM:

- Tarea de clasificación cerrada, no generación abierta.
- Lista de etiquetas explicitada; “unknown” permitido.
- El LLM no participa en el análisis estadístico ni en la selección de genes.

- Auditoría manual sobre un subconjunto para verificar la precisión real.

El uso de LLMs en bioinformática todavía levanta escepticismo. Si te preguntan “no le estás dando poder al modelo?” responde con claridad: el LLM **sólo cura metadatos**. Todo el análisis estadístico, la selección de genes, la clasificación y la validación son determinísticos, reproducibles con `random_state=42` y no dependen del LLM.

12 Consenso multi-cohorte y meta-análisis

12.1 Por qué integrar cohortes

Un solo estudio tiene poder estadístico limitado, sesgos particulares y puede detectar señales que no replican. Integrar varios estudios aumenta el tamaño muestral efectivo y permite distinguir señales reproducibles de artefactos.

Dos estrategias generales:

- **Combinación con corrección de lote** (ejemplo: ComBat). Simple pero arriesgado si el lote confunde con la variable de interés.
- **Meta-análisis por consenso**. Cada cohorte se analiza por separado; se combinan los resultados con criterios estadísticos.

El TFM adopta la segunda.

12.2 Consenso en el TFM

Para cada gen g y cada cohorte c :

- Se calcula el d de Cohen entre grupos (ejemplo: ADC vs SQC).
- Se registra el signo y la magnitud.

Un gen *sobrevive* al consenso si en **las 3 cohortes independientes**:

- Mantiene el *mismo signo* (misma dirección de cambio).
- Alcanza $|d| > 0,5$ (efecto moderado o mayor).

Resultado: de $\sim 22\,880$ genes evaluados, sobreviven **1 174**. Es un filtro exigente que garantiza reproducibilidad biológica.

13 Interpretabilidad: ejes biológicos

Una firma de 1 174 genes puede parecer una caja negra. En el TFM se analiza la estructura interna con dos preguntas:

1. **Los genes seleccionados coinciden con marcadores clínicos ya conocidos?** Sí: 18 de 20 marcadores IHC del panel OMS aparecen en la firma sin haberse declarado.
2. **Existen ejes biológicos coherentes en la firma?** Sí, dos:

Eje 1: pérdida alvéolo-capilar

Genes como *SFTPC*, *SFTPB*, *AGER*, *CLDN18*, *FABP4*, marcadores canónicos de neumocitos y capilares alveolares. En muestras tumorales la expresión de estos marcadores cae. La firma correlaciona negativamente con estos marcadores ($\rho = -0,626$ media en 4 cohortes con muestra suficiente). Biológicamente coherente: el tumor sustituye al parénquima alveolar sano.

Eje 2: proliferación tumoral

Genes como *MKI67*, *TOP2A*, *CCNB1*, *BIRC5*, *AURKA*. Marcadores clásicos de proliferación que el patólogo usa en clínica (Ki-67 en biopsias). Un score alto en este eje correlaciona con tumores más agresivos.

Frase para el tribunal

“La firma no es una caja negra. Captura la transición biológica del pulmón sano al tejido tumoral en dos ejes que un patólogo reconoce: pérdida de arquitectura alveolar y ganancia de actividad proliferativa.”

14 Transferibilidad clínica

14.1 NanoString nCounter

Tecnología que mide expresión de un panel pequeño de genes (decenas a cientos) directamente sobre tejido fijado en formalina (**FFPE**). El tejido FFPE es el estándar clínico en anatomía patológica (se conserva años, es barato). NanoString no requiere RT-PCR y da lecturas cuantitativas robustas. Ideal para paneles diagnósticos multiplexados.

14.2 RT-qPCR

PCR cuantitativa a tiempo real. Estándar clínico para paneles muy pequeños (1-20 genes). Alta sensibilidad, coste bajo, resultado en horas. Requiere ARN de buena calidad (más exigente que NanoString).

14.3 Por qué importa al TFM

Los 20 genes del panel mínimo son *traducibles* a estas plataformas. Podrían construirse ensayos NanoString / qPCR para uso diagnóstico. Diferencia clave respecto a firmas basadas en RNA-Seq completo, que no son viables en flujo clínico rutinario.

15 Reproducibilidad

15.1 Principios

Una investigación reproducible cumple: cualquier persona con acceso al código y a los datos originales puede regenerar todas las cifras y figuras publicadas.

Elementos del TFM que garantizan reproducibilidad:

- **Semilla aleatoria fija:** `random_state=42` en todos los pasos aleatorizados.
- **Código público:** repositorio Git público con historial completo.
- **Datos públicos:** cohortes GEO y TCGA descargables por cualquiera.
- **Artefactos intermedios versionados:** cada paso escribe CSV/JSON que se pueden auditar.
- **Especificación de entorno:** `requirements.txt` con versiones exactas.

15.2 Data leakage

Data leakage (fuga de datos): información del conjunto de test se filtra al entrenamiento. Es el error más común en ML aplicado a genómica.

Fuentes típicas:

- Selección de features en todo el conjunto antes de dividir.
- Normalización aplicada al conjunto completo.
- Uso de la misma cohorte en train y test (por descuido).

En el TFM: la selección de genes y la calibración se hacen *dentro* de cada iteración LODO, usando sólo las cohortes de entrenamiento. Ninguna muestra de la cohorte test se ve nunca durante el ajuste.

En TCGA: las 408 muestras TCGA se aplican *después* de entrenar todo el pipeline en microarray. Ninguna muestra TCGA participó en la selección de features ni en la calibración.

16 Glosario rápido

ADC

Adenocarcinoma. Subtipo de NSCLC de origen glandular.

ARN mensajero (mRNA)

Copia funcional de un gen, sustrato de la traducción.

AUC

Area Under the ROC Curve. Discriminación de un clasificador.

Balanced accuracy

Media de sensibilidad y especificidad.

Batch effect

Diferencias técnicas sistemáticas entre lotes.

Bootstrap

Remuestreo con reemplazo para estimar incertidumbre.

cBioPortal

Portal público que sirve datos TCGA vía API.

Cohen (d)

Tamaño de efecto estandarizado.

ComBat

Algoritmo bayesiano de corrección de efecto lote.

Data leakage

Contaminación inadvertida train-test.

 d de Cohen

Ver “Cohen”.

FDR

False Discovery Rate. Corrección por múltiples tests (BH).

FFPE

Tejido fijado en formalina y embebido en parafina. Estándar clínico.

Firma génica

Conjunto de genes cuya expresión caracteriza un fenotipo.

GEO

Gene Expression Omnibus. Repositorio público del NCBI.

GPL

Identificador de plataforma tecnológica en GEO.

Groq

Empresa de inferencia LLM sobre hardware LPU.

GSE

Identificador de estudio en GEO.

GSM

Identificador de muestra individual en GEO.

HGNC

Human Genome Organisation. Nomenclatura génica oficial.

IHC

Inmunohistoquímica. Técnica anatomopatológica.

Isotónica (regresión)

Método de calibración no paramétrico.

Ki-67 (MKI67)

Marcador clásico de proliferación.

k-fold CV

Validación cruzada en k particiones.

LASSO

Regresión con penalización L1. Selecciona variables.

Llama

Familia de LLMs abiertos de Meta.

LODO

Leave-One-Dataset-Out. Validación externa por cohorte.

LPU

Hardware específico de Groq para inferencia LLM.

LUAD / LUSC

Nombres TCGA para adenocarcinoma / escamoso de pulmón.

Microarray

Chip que mide expresión por hibridación.

NanoString

Plataforma comercial para paneles de genes en FFPE.

NCBI

National Center for Biotechnology Information (EE.UU.).

NSCLC

Non-Small Cell Lung Cancer.

OMS

Organización Mundial de la Salud. Publica clasificación de tumores.

Panel OMS 2015

20 marcadores IHC estándar para NSCLC (Travis et al., 2015).

Pipeline

Cadena de pasos automatizados que produce resultados.

Platt scaling

Calibración sigmoidea con regresión logística.

Random Forest

Ensamble de árboles de decisión con bagging.

Reproducibilidad

Capacidad de regenerar todas las cifras publicadas.

RNA-Seq

Secuenciación del transcriptoma.

ROC

Curva sensibilidad vs 1-especificidad.

RSEM

Estimador estadístico para cuantificar RNA-Seq. Usado por TCGA.

SCLC

Small Cell Lung Cancer. Subtipo minoritario y agresivo.

Sensibilidad (recall, TPR)

$TP / (TP + FN)$.

Spearman (ρ)

Correlación por rangos, mide monotonía.

SQC / LUSC

Squamous Cell Carcinoma (escamoso).

SVM

Support Vector Machine. Clasificador de máximo margen.

TCGA

The Cancer Genome Atlas. Consorcio NIH de caracterización tumoral.

TNM

Sistema de estadificación tumor-ganglios-metástasis.

TPM

Transcripts Per Million. Unidad de normalización RNA-Seq.

Transcriptoma

Conjunto de mRNAs presentes en una muestra.

Transformer

Arquitectura de red neuronal base de los LLMs.

TTF-1 (NKX2-1)

Marcador IHC de adenocarcinoma.

Welch (t de)

Test t para varianzas desiguales.

Este manual cubre los fundamentos que sostienen el TFM. Si te preguntan algo que no está aquí, la respuesta honesta “no lo sé con precisión, pero mi trabajo se apoya en . . . ” es preferible a inventar. La memoria está bien construida y los resultados son reproducibles: no necesitas defender más de lo que ya has hecho.