

COHORTES GEO

11

8 EVALUABLES

MUESTRAS CURADAS

1157

82,8 % LLM

PANEL MÍNIMO

20

DE 1174 GENES

AUC LODO SUBTIPO

0,968

3 COHORTES INDEP.

AUC TCGA RNA-SEQ

0,857

IC 95 [0,812; 0,899]

PROBLEMA

El cáncer de pulmón es la primera causa de muerte oncológica mundial: **2,48 M casos/año**, supervivencia a 5 años **< 20 %**. En NSCLC, distinguir adenocarcinoma de carcinoma escamoso es crítico: pemetrexed y bevacizumab están **contraindicados en escamoso** por riesgo de hemorragia mortal. Existen cientos de estudios en GEO, pero integrarlos es difícil: plataformas heterogéneas, metadatos en texto libre y firmas publicadas que **rara vez replican** en cohortes independientes.

OBJETIVO

Construir un **framework reproducible extremo a extremo** que integre cohortes públicas de expresión génica mediante (i) curación automática de metadatos con LLM, (ii) meta-análisis por consenso multi-cohorte, y (iii) clasificación supervisada con validación externa LODO. Producir una firma génica interpretable, clínicamente traducible y validada contra el panel diagnóstico IHC de la OMS.

METODOLOGÍA

Pipeline de 9 pasos en 4 fases:

- **Ingesta:** 11 cohortes GEO ($n = 1,397$), normalización $\log_2$ + cuantiles dentro de cada estudio (sin ComBat).
- **Curación clínica:** Llama 3.3-70b vía Groq sobre metadatos textuales. Tarea acotada con lista cerrada.
- **Consenso:** d de Cohen por cohorte; gen valida si mantiene signo y $|d| > 0,5$ en 3 cohortes.
- **Clasificación:** LASSO L1 en regresión logística, LODO externa, recalibración isotónica, validación TCGA RNA-Seq vía cBioPortal.

RESULTADOS

Firma completa	1 174 g.
Cohortes de consenso	3 indep.
Umbral $ d $	$> 0,5$
Panel mínimo	20 g.
AUC panel	0,966
AUC firma completa	0,974
Subtipo (LODO)	
AUC media	0,968
BalAcc	0,940
Tumor vs sano (LODO)	
AUC sin recalibración	0,925
AUC con isotónica	0,953
BalAcc 0,772	→ 0,810
Sensibilidad	0,988
Especificidad	0,632
Comparativa ML	AUC
LASSO L1	0,925
Random Forest	0,933
SVM lineal	0,957
TCGA RNA-Seq	
n total (LUAD + LUSC)	408
AUC transferido	0,857
IC 95 % (bootstrap)	[0,812; 0,899]
Panel IHC OMS	
Recuperación total	18/20
Escamoso	12/12
Adenocarcinoma	6/8

HALLAZGOS

Validación biológica sin datos clínicos. La firma seleccionada de forma puramente estadística recupera **18 de los 20 marcadores IHC del panel OMS 2015** sin declararlos. Coincidencia entre selección automática y práctica clínica.

Dos ejes biológicos coherentes. (Eje 1) Pérdida alvéolo-capilar: $\rho = -0,626$ media (hasta $-0,858$ en GSE31210, $p = 1,1 \cdot 10^{-66}$); (Eje 2) Proliferación tumoral (*MKI67*, *TOP2A*, *CCNB1*, *BIRC5*, *AURKA*). Ambos emergen sin declararlos.

Transferibilidad entre plataformas. Panel LASSO entrenado en microarray Affymetrix → RNA-Seq TCGA con AUC 0,857. Ninguna muestra TCGA participó en selección de genes ni en calibración. Señal biológica, no artefactual.

CONCLUSIONES

La combinación de LLM para curación clínica, meta-análisis por consenso y validación LODO produce firmas génicas *reproducibles, interpretables y transferibles*. Los 20 genes son medibles con NanoString o RT-qPCR sobre FFPE, viables como test diagnóstico complementario.

TRABAJO FUTURO

- Validación clínica prospectiva sobre biopsias frescas.
- Ampliación a subtipos neuroendocrinos y otros tumores.
- Sustitución del LLM externo por modelo local.
- Firmas pronósticas con Cox sobre TCGA.